arXiv:2603.19312v2 [cs.LG] 24 Mar 2026

LeWorldModel: 基于像素的稳定端到端联合嵌入预测架构

Lucas Maes*Quentin Le Lidec*Damien ScieurYann LeCunRandall Balestriero

[1]Mila & Université de Montréal New York University Samsung SAIL Brown University

网址 § 代码

摘要

联合嵌入预测架构（JEPAs）为在紧凑的潜在空间中学习世界模型提供了一个引人入胜的框架，然而现有方法仍然脆弱，依赖于复杂的多元损失、指数移动平均、预训练编码器或辅助监督来避免表示崩溃。在这项工作中，我们引入了 LeWorldModel（LeWM），这是第一个能够仅使用两个损失项从原始像素端到端稳定训练的 JEPA：一个下一嵌入预测损失和一个强制高斯分布潜在嵌入的正则化项。与唯一现有的端到端替代方案相比，可调损失超参数从六个减少到一个。在单个 GPU 上只需几个小时即可训练 1500 万个参数，LeWM 计划比基于基础模型的世界模型快高达 48 倍，同时在各种 2D 和 3D 控制任务中保持竞争力。除了控制之外，我们展示了 LeWM 的潜在空间通过物理量的探测编码了有意义的物理结构。惊喜评估证实该模型能够可靠地检测物理上不可能发生的事件。

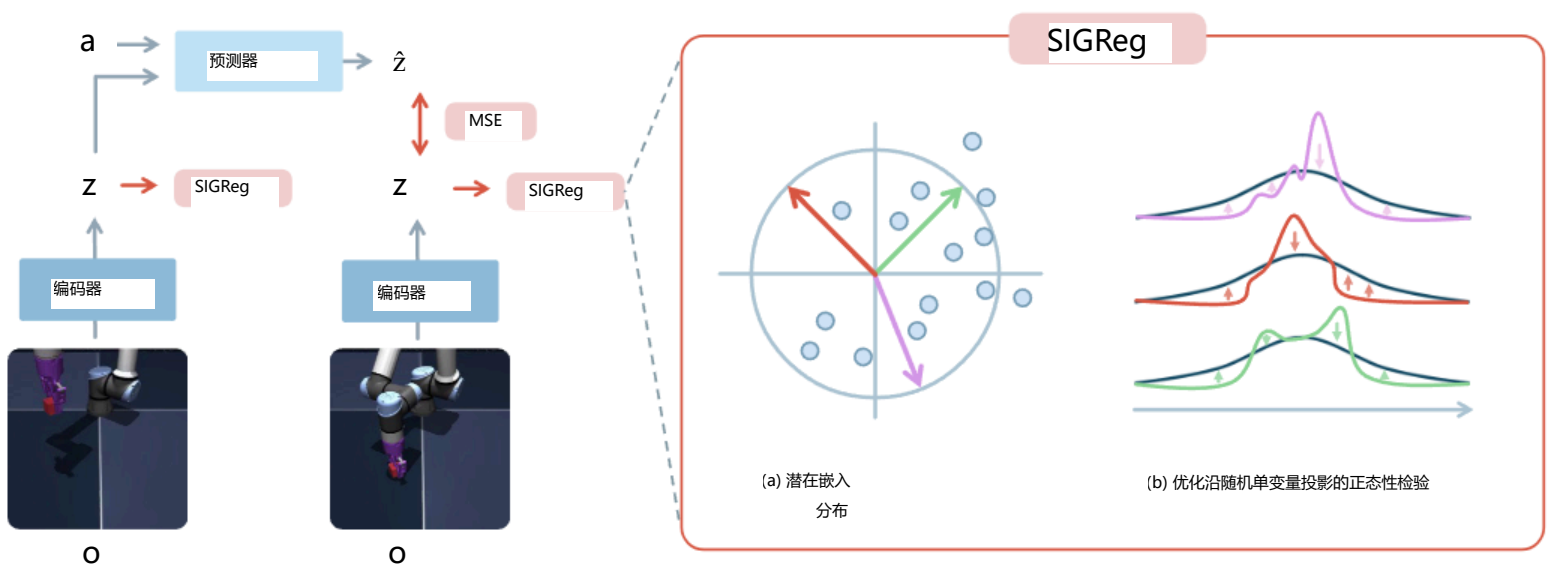

图 1：LeWorldModel 训练流程。给定帧观测值 o 和动作 a，编码器将帧映射到低维潜在表示 z。预测器通过自回归地预测当前潜在状态 z 和动作 a 来模拟环境动态，生成下一个潜在状态 z。编码器和预测器使用均方误差（MSE）预测损失联合优化。LeWM 不依赖任何训练启发式方法，如停止梯度、指数移动平均或预训练表示。为防止平凡崩溃，SIGReg 正则化项强制潜在嵌入呈高斯分布，促进特征多样性。具体而言，潜在嵌入被投影到多个随机方向上，并对每个一维投影应用正态性测试。汇总这些统计数据鼓励整个嵌入分布匹配各向同性高斯分布。

* 同等贡献。通讯作者：lucas.maes@mila.quebec

预印本。

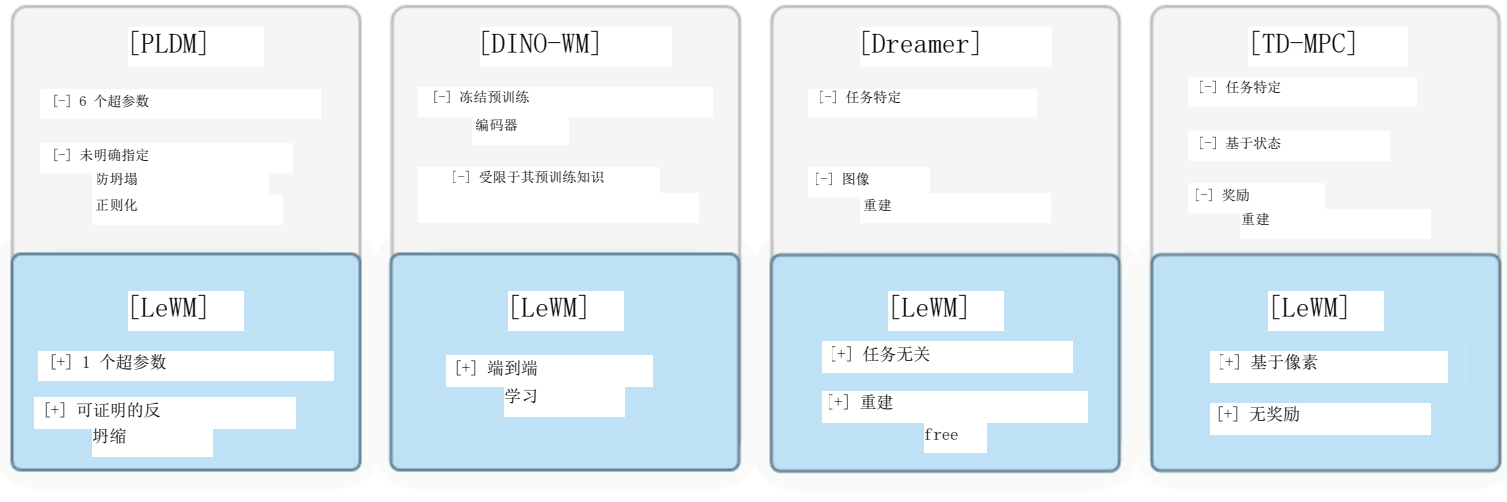

图 2：潜在世界模型方法的特征。方法按训练范式分组。端到端方法（PLDM）从像素中联合学习编码器和预测器，不依赖于预训练表示或启发式技巧（如停止梯度或指数移动平均），但需要许多超参数且缺乏正式的崩溃保证。基于基础的方法（DINO-WM）通过冻结预训练的基础视觉编码器来避免崩溃，放弃了端到端学习。特定任务方法（Dreamer、TD-MPC）在训练期间需要奖励信号或特权状态访问。LeWM 解决了每个类别的局限性：它是端到端的、任务无关的、基于像素的、无重建和无奖励的，并且只需要一个超参数，具有可证明的反崩溃保证。

1 引言

人工智能的一个核心目标是开发能够在不同任务和环境中使用单一、统一的 学习范式来获取技能的智能体——这种范式直接从周围环境的感官输入中运行，而不需要手工设计的状态表示或特定领域的校准。视觉非常适合这个目标：相机既经济又可扩展，而从像素中学习可以实现从原始感官输入到动作的完全端到端训练[1]。世界模型（WMs）是一类强大的方法[2]，它们学习预测环境中动作的后果。当成功时，世界模型允许智能体仅凭其世界模型（即想象空间）来规划和改进自身。这在离线环境中尤其有价值，智能体必须从固定数据集中学习而没有环境交互——利用模型生成合成经验并评估反事实动作序列[3,4]。

一种近期流行的学习世界模型的方法是联合嵌入预测架构（JEPA）[5]。JEPA 并非试图模拟环境的各个方面，而是专注于捕捉预测未来状态所需的最相关特征。具体而言，JEPA 学习将观察编码到一个紧凑的低维潜在空间中，并通过预测未来观察的潜在表示来模拟时间动态。

然而，尽管概念上简单，现有的 JEPA 方法极易发生崩溃。在这种失效模式下，模型将所有输入映射到几乎相同的表示，以轻易满足时间预测目标，从而导致不可用的表示。因此，防止崩溃是训练 JEPA 模型的核心挑战之一。许多有影响力的工作提出了解决此问题的方法。然而，这些方法通常依赖于启发式正则化、多目标损失函数、外部信息源或架构简化（如预训练编码器）。在实践中，这些策略往往会引入额外的稳定性问题或显著增加训练复杂性。

为了克服这些限制，我们提出了 LeWorldModel（LeWM），这是首个无需启发式、基于原理且简单的从原始像素端到端学习稳定联合嵌入预测架构（JEPA）的方法（参见图 2）。此外，LeWM 可以在单个 GPU 上训练，降低了研究的入门门槛。我们在 2D 和 3D 环境中对 LeWM 在多种操控、导航和运动任务上进行了评估。此外，我们通过潜在空间中的目标探测和惊喜量化评估来探究其直观的物理理解能力。总体而言，我们的关键发现和贡献如下：

- 我们提出了一种在单个 GPU 上从原始像素端到端学习潜在世界模型的 JEPA 方法。该方法依赖于一个简单且稳定的两项式目标，该目标在不同的架构和超参数选择下保持稳健，同时支持高效的逻辑时间超参数搜索。

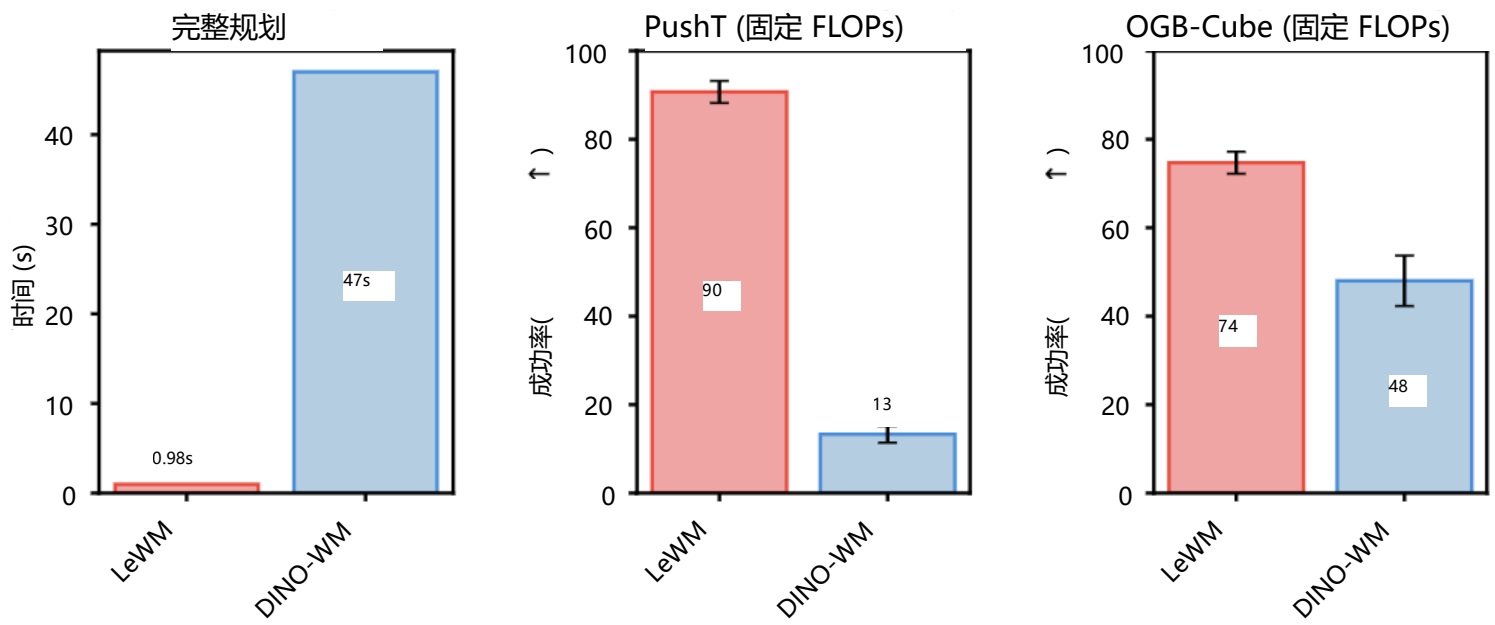

图 3：固定计算量下的规划时间和性能。左：50 次运行的平均规划时间比较。使用比 DINO-WM 少约 200 倍的 token 编码观测结果，LeWM 能够实现与 PLDM 相当的规划速度，同时比 DINO-WM 快高达约 50 倍。中-右：在相同的计算预算（固定 FLOPs）下的规划性能。LeWM 在 Push-T（中）和 OGBench-Cube（右）上显著优于 DINO-WM。有关规划设置详情，请参见附录 D。

- LeWM 使用一个紧凑的 1500 万参数模型，在多种 2D 和 3D 任务中实现了强大的控制性能，超越了现有的端到端 JEPA 方法，同时与基于基础模型的世界模型保持竞争力，成本大幅降低，能够实现高达 48 倍的规划速度提升。

- 我们通过探测物理量以及对检测非物理轨迹的期望违背测试，在潜在空间中评估物理理解能力。

2　相关工作

世界模型旨在从数据中学习环境动态的预测模型，使智能体能够在想象中推理未来状态。一类突出的世界模型是生成式方法，它们在像素空间中显式地建模环境动态。这些动作条件生成模型通过根据过去的状态和动作生成未来的观察结果，充当学习型模拟器。生成式世界模型已成功应用于模拟现有的游戏化环境。例如，IRIS [3]、DIAMOND [6]、Δ-IRIS [7]、OASIS [8] 和 DreamerV4 [4] 模拟了 Minecraft、反恐精英和 Crafter 等环境，提高了强化学习中的策略样本效率。其他方法生成全新的交互式模拟器，例如 Genie [9] 和 HunyuanWorld [10]，而学习型模拟器也已应用于机器人策略评估 [11]。重要的是，许多生成式世界模型假设可以访问包含奖励信号的数据集，从而能够联合建模动态和与下游强化学习相关的价值信息。 相比之下，我们关注无奖励设置，这对应于 JEPA 系列工作中的考虑设置，其旨在学习通用、无需依赖奖励监督，从观测数据中生成任务无关的世界模型。

JEPA 是一个用于学习世界模型的框架，该模型能够在紧凑的低维潜在空间中预测系统的动态演化。自从 LeCun [5]提出以来，JEPA 方法已经取得了显著的发展，主要区别在于其目标任务以及用于学习非折叠表示的策略。一条突出的发展路线是将 JEPA 应用于自监督表示学习，通过预测掩码输入块的潜在嵌入。例如，I-JEPA [12]用于图像，V-JEPA [13, 14]用于视频，以及 Echo-JEPA 和 Brain-JEPA [15, 16]用于医学数据。这些方法通常采用目标编码器的指数移动平均（EMA）以及停止梯度（SG）更新来稳定训练并防止表示折叠。然而，EMA 和 SG 的理论理解仍然有限，因为它们通常不对应于一个明确定义目标的极小化 [17]。另一条路线使用 JEPA 配方进行动作条件潜在世界建模。一些方法依赖于预训练编码器来获取表示 [14, 18-20]。这避免了折叠，但限制了表示的表达能力。

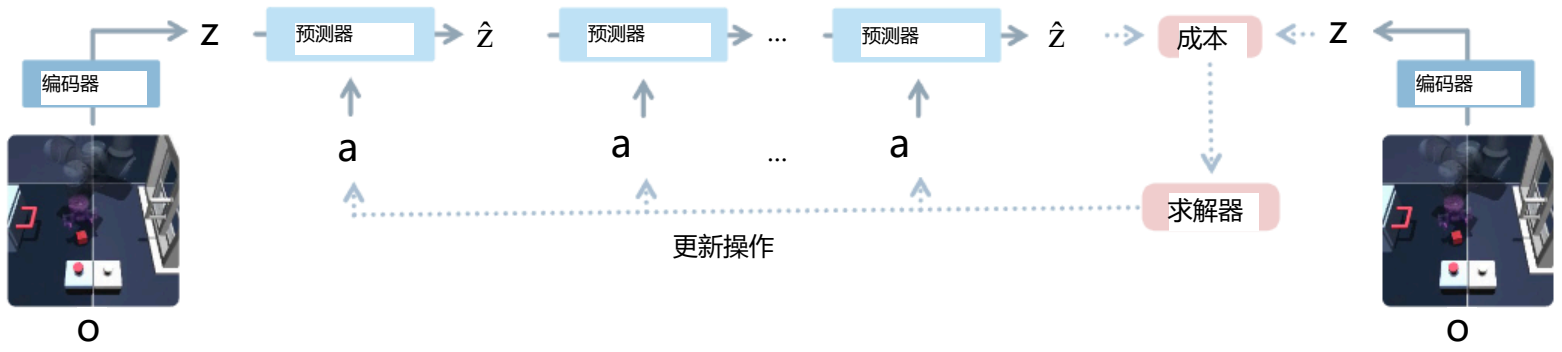

图 4：LeWorldModel 潜在规划。给定初始观测值 o 和目标 o，图 2 中学习到的世界模型在 LeWM 潜在空间中进行规划。初始状态嵌入 z 和目标嵌入 z 由编码器获得。预测器随后展开未来潜在状态直到视野 H。最终预测状态与目标嵌入之间的潜在成本指导求解器优化动作序列。这个预测-优化循环重复进行，直到收敛到一个好的计划候选。

与预训练编码器使用的相比。相反，PLDM [21 , 22] 使用 VICReg [23] 以附加正则化项的方式端到端学习表示，代价是已知的训练不稳定性以及可扩展性限制 [24]。一些工作通过结合辅助信号或架构组件进一步提高了稳定性，例如本体感觉输入或动作解码器 [18, 19]。在这项工作中，我们提出了一种直接从原始像素中训练端到端 JEPAs 的稳定方法，使用一个简单的两项损失：一个针对未来嵌入的预测目标和一个正则化目标，该目标强制执行高斯分布的嵌入 [25]。

使用潜在动态规划。世界模型[26]开创了直接从高维观测的紧凑潜在表示中学习策略的方法。一些工作利用学习的潜在动态模型，通过强化学习[27-29, 4]训练策略。在这些方法中，生成式世界模型充当模拟器，在想象中展开轨迹，允许策略优化主要在潜在空间中发生。一旦训练完成，策略直接执行，测试时不再需要世界模型。

较新的工作则使用模型预测控制（MPC）[30-33, 18, 22]在测试时直接在潜在空间中进行规划。与基于想象的策略学习不同，这些方法使用在线世界模型来预测候选动作序列的结果，并在执行过程中迭代优化它们。因此，模型在运行时仍然是控制循环的一部分，能够实现自适应决策，但增加了计算需求。

3　方法：LeWorldModel

在本节中，我们介绍了 LeWorldModel（LeWM）。我们首先描述了用于从离线数据中学习潜在世界模型的简化训练流程，包括数据集、模型架构和训练目标。然后，我们解释了如何通过使用模型预测控制（MPC）进行潜在规划，来利用学习到的模型进行决策。

3.1　学习潜在世界模型

离线数据集。我们考虑一个完全离线且无奖励的设置。LeWorldModel 仅从未标记的观察和动作轨迹中进行训练，而无需访问奖励信号或任务规范。这种设置与 JEPA 系列工作[18 , 14]一致，该工作旨在从观察数据中学习通用、任务无关的世界模型。我们的目标不是针对特定任务优化行为，而是学习能够捕捉环境动态的表示，以便稍后可以控制或适应一系列不同的任务。

训练数据由长度为 T 的轨迹组成，这些轨迹由原始像素观测值 o 和相关的动作 a 构成。这些轨迹通过无最优性要求的策略离线收集；只要它们充分覆盖了环境动态，可以是伪专家或探索性的。额外的实现细节（批量大小、分辨率和子轨迹构建）在附录 D 中提供。

Model Architecture. LeWM is built upon two components: an encoder and a predictor. The encoder maps a given frame observation ointo a compact, low-dimensional latent representation z. The predictor models the environment dynamics in latent space by predicting the embedding of the next frame observation ˆzgiven the latent embedding zand

Encoder: z= enc(o) Predictor: ˆz= pred(z, a)
重试 错误原因

(LeWM)重试 错误原因

The encoder is implemented as a Vision Transformer (ViT) [34]. Unless otherwise specified, we use the tiny configuration (∼5M parameters) with a patch size of 14, 12 layers, 3 attention heads, and hidden dimensions of 192. The observation embedding zis constructed from the [CLS] token embedding of the last layer, followed by a projection step. The projection step maps the [CLS] token embedding into a new representation space using a 1-layer MLP with Batch Normalization [35]. This step is necessary because the final ViT layer applies a Layer Normalization [36], which prevents our anti-collapse objective from being optimized effectively.重试 错误原因

The predictor is a transformer with 6 layers, 16 attention heads, and 10% dropout (∼10M parameters). Actions are incorporated into the predictor through Adaptive Layer Normalization (AdaLN) [37] applied at each layer. The AdaLN parameters are initialized to zero to stabilize training and ensure that action conditioning impacts the predictor training progressively. The predictor takes as input a history of N frame representations and predicts the next frame representation auto-regressively with temporal causal masking to avoid looking at future embeddings. The predictor is also followed by a projector network with the same implementation as the one used for the encoder. All components of our world model are learned jointly using the loss described in the following paragraph.重试 错误原因

Training Objective. Our objective is to learn latent representations useful for predicting the future, i.e., modeling the environment dynamics. LeWorldModel training objective is the sum of two terms: a prediction loss and a regularization loss. The prediction loss L(teacher-

$$L \triangleq \| \hat{z} - z \|, \quad \hat{z} = \text{pred}(z, a). \tag{1}$$

重试 错误原因 重试 错误原因

Through the prediction loss, the encoder is incentivized to learn a predictable representation for the predictor.重试 错误原因

However, this loss alone leads to representation collapse, yielding a trivial solution in which the encoder maps all inputs to a constant representation. To prevent this behavior, we introduce an anti-collapse regularization term that promotes feature diversity in the embedding space. Specifically, we adopt the Sketched-Isotropic-Gaussian Regularizer (SIGReg) [25] due to its simplicity, scalability, and stability. SIGReg encourages the latent embeddings to match an isotropic Gaussian target distribution.重试 错误原因

Let Z ∈ Rdenote the tensor of latent embeddings collected over the history length N , the batch size B, and where d demotes the embedding dimension. Assessing normality directly in high-dimensional spaces is challenging, as most classical normality tests are designed for univariate data and do not scale reliably with dimensionality. SIGReg circumvents this limitation by projecting embeddings onto M random unit-norm directions u∈ Sand optimizing the univariate Epps– Pulley [38] test statistic T (·) along the resulting one-dimensional projections h= Zu, as illustrated in Fig.1. By the Cramér–Wold theorem [39], matching all one-dimensional marginals is equivalent to matching the full joint distribution.

$$\text{SIGReg}(Z) \triangleq \frac{1}{M} \sum_{m=1}^{M} T(h_m). \tag{2}$$

重试 错误原因 重试 错误原因

Additional details on SIGReg and the definition of the Epps–Pulley statistical test are provided in appendix A.重试 错误原因

The complete LeWM training objective is defined as:重试 错误原因

$$L \triangleq L + \lambda \, \text{SIGReg}(Z). \tag{3}$$

重试 错误原因

Algorithm 1. Pseudo-code for the training procedure of LeWorldModel. Pixel observations are encoded into latent embeddings, and a predictor estimates the dynamics by predicting the next-step embedding conditioned on actions. The model is optimized end-to-end using a next-embedding prediction loss together with a step-wise SIGReg regularization term to prevent representation collapse.重试 错误原因

```
def LeWorldModel(obs,actions,lambd=0.1):重试 错误原因
    """ obs: (B, T, C, H, W) raw pixels sequence actions:
    (B, T, A) action sequence lambd: (float) SIGReg loss
    weight """重试 错误原因


    emb = encoder(obs) # (B, T, D) next_emb =
    predictor(emb,actions) #(B, T, D)重试 错误原因

    # -- LeWorldModel training loss重试 错误原因
    # next-embedding prediction loss重试 错误原因
    pred_loss = F.mse_loss(emb[:, 1:] - next_emb[:, :-1])重试 错误原因

    # step-wise sigreg (anti-collapse)重试 错误原因
    sigreg_loss = mean(SIGReg(emb.transpose(0, 1))重试 错误原因

    return pred_loss + lambd * sigreg_loss重试 错误原因
```

The method introduces only two training hyperparameters: the number of random projections M used in SIGReg and the regularization weight λ. Unless otherwise specified, we use M = 1024 projections and λ = 0.1. In practice, we observe that the number of projections has negligible impact on downstream performance (see Sec. 4 and App. G), making λ the only effective hyperparameter to tune. This greatly simplifies hyperparameter selection, as λ can be efficiently optimized using a simple bisection search with logarithmic complexity. We do not employ stop-gradient, exponential moving averages, or additional stabilization heuristics. Gradients are propagated through all components of the loss, and all parameters are optimized jointly in an end-to-end manner, resulting in a streamlined and easy-to-implement

3.2 Latent Planning重试 错误原因

At inference time, we perform trajectory optimization in our world model latent space, as illustrated in Fig.4. Given an initial observation o, we initialize a candidate action sequence randomly and iteratively rollout predicted latent states up to a planning horizon H. The model predicts latent transitions according to重试 错误原因

$$\hat{z} = \text{pred}(\hat{z}, a), \quad \hat{z} = \text{enc}(o),$$重试 错误原因

Planning is performed by optimizing the action sequence to minimize a terminal latent goal-matching objective:重试 错误原因

$$C(\hat{z}) = \| \hat{z} - z \|, \quad z = \text{enc}(o),$$重试 错误原因 (4)

where $\hat{z}$is the predicted latent state at the end of the rollout and zis the latent embedding of the goal observation o. The world model parameters remain fixed during planning. This procedure corresponds to a finite-horizon optimal control problem:重试 错误原因

$$a = \arg\min_{a}$$重试 $C(\hat{z})$, 重试 错误原因 (5)

which we solve using the Cross-Entropy Method (CEM) [40], a sampling method that iteratively selects the best plan and updates the parameters of the sampling distribution with the statistics of the best plans. The planning horizon H trades off long-term lookahead against increased computational cost and model bias. In particular, auto-regressive rollouts accumulate prediction errors as the horizon grows, which can deteriorate the quality of the

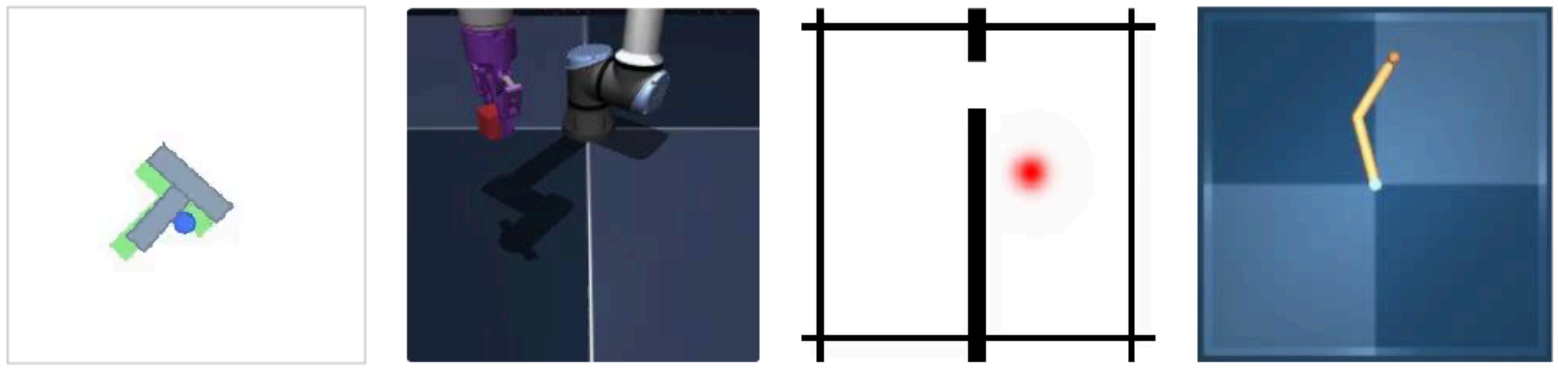

Figure 5: Environments used for evaluation. Left: Push-T, a 2D manipulation task where the agent must push a block toward a target configuration, commonly used as a robotics benchmark. Center (1): OGBench-Cube, a visually richer 3D manipulation environment where a robotic arm interacts with a cube to reach a target position. Center (2): Two-Room, a simple 2D navigation environment where an agent moves between rooms to reach target positions. Right: Reacher, a task where a 2-joint arm needs to reach a target configuration in a 2D plane. All environments have a continuous action space. More details on environment and datasets are available in appendix E.重试 错误原因

we adopt a Model Predictive Control (MPC) strategy: only the first K planned actions are executed before replanning from the updated observation. We provide more details on the planning strategy in appendix D.重试 错误原因

4 Latent Planning Performance重试 错误原因

4.1 Planning evaluation setup重试 错误原因

Environments. We evaluate LeWM on a diverse set of tasks, including navigation, motion planning and manipulation, in both two- and three-dimensional environments, all illustrated in Fig. 5. We provide more details on dataset generation and environments in App. E.

Baselines. We compare the performance of LeWM against several baselines: DINO-WM and PLDM, two state-of-the-art JEPA-based methods; a goal-conditioned behavioral cloning policy (GCBC); and two goal-conditioned offline reinforcement learning algorithms, GCIVL and GCIQL. Among these baselines, PLDM is the closest to our setup, as it also learns a world model end-toend directly from pixel observations. However, it relies on a seven-term training objective derived from the VICReg criterion, which introduces training instability and increases the complexity of hyperparameter tuning. DINO-WM, in contrast, models dynamics using DINOv2 [41] as feature encoder to mitigate representation collapse, but its original formulation additionally incorporates other modalities, such as proprioceptive inputs; for a fair comparison, unless specified otherwise, we exclude proprioceptive information from DINO-WM. Additional implementation details for the baselines (App. C) and evaluation settings (App. F.1) are provided in the appendix. For each method, we keep the

4.2 Towards Efficient Planning with WMs重试 错误原因

We report planning performance in Fig. 6. LeWM improves over PLDM on the more challenging planning tasks, achieving an 18% higher success rate on PushT while remaining competitive with DINO-WM. Notably, on PushT, LeWM (pixels-only) surpasses DINO-WM, even when DINO-WM has access to additional proprioceptive information, demonstrating LeWM’ s ability to capture underlying task-relevant quantities. Moreover, when comparing planning speedups (Fig. 3), LeWM achieves a 48× faster planning time, with the full planning completing in under one second while preserving competitive performance across tasks. This planning time is consistent across environments for a fixed planning setup, narrowing gap with real-time control.重试 错误原因

We report planning performance in Fig. 6. LeWM outperforms PLDM on the more challenging planning tasks, achieving an 18% higher success rate on PushT, while remaining competitive with DINO-WM. Notably, on PushT, LeWM (pixels-only) surpasses DINO-WM even when DINOWM has access to additional proprioceptive information, demonstrating

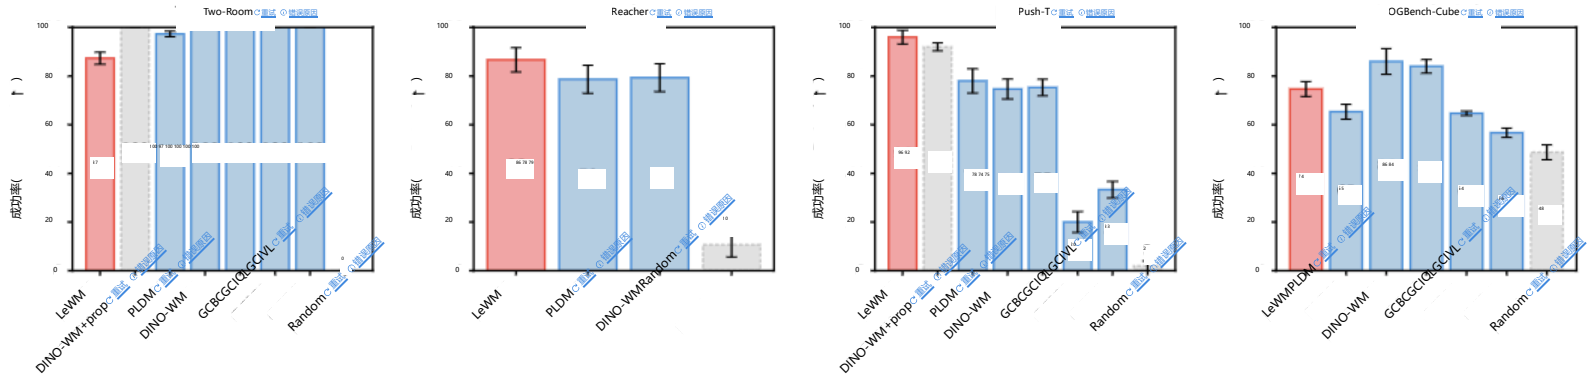

Figure 6: Planning performance across environments. Results are shown for Two-Room (left), Reacher (center 1), PushT (center-2) and OGBench-Cube (right). LeWM consistently outperforms PLDM and DINO-WM on Push-T and Reacher. On OGBench-Cube, DINO-WM slightly outperforms LeWM, possibly due to the higher visual complexity and the 3D nature of the environment, which makes encoder training more challenging. In the simpler Two-Room environment, PLDM and DINO-WM outperform LeWM, which may be explained by the SIGReg regularization encouraging a Gaussian distribution in a high-dimensional latent space, while the intrinsic dimensionality of the environment is much lower.重试 错误原因

Two-Room. A possible explanation is that the low diversity and low intrinsic dimensionality of this dataset make it difficult for the encoder to match the isotropic Gaussian prior enforced by SIGReg in a high-dimensional latent space, which may lead to a less structured latent representation. This highlights a potential limitation of the SIGReg regularization in very low-complexity environments.重试 错误原因

Moreover, when comparing planning speedups (Fig. 3), LeWM achieves a 48× faster planning time, with the full planning completing in under one second while preserving competitive performance across tasks. This planning time remains consistent across

4.3 Towards Stable Training of World Models重试 错误原因

Ablations. We perform ablations on several design choices of LeWM. First, we analyze the sensitivity of SIGReg to its internal parameters, namely the number of random projections and the number of integration knots. The performance is largely unaffected by these quantities, indicating that they do not require careful tuning. As a result, the regularization weight λ remains the only effective hyperparameter. Since only a single hyperparameter needs to be tuned, grid search can be performed efficiently using a simple bisection strategy ($O(\log n)$), whereas PLDM requires search in polynomial time ($O(n)$). We also study the effect of the embedding dimensionality. While the representation dimension must be sufficiently large for the method to perform well, performance quickly saturates beyond a certain threshold, suggesting that the approach is robust to the precise choice of encoder capacity. Additionally, we examine the impact of the encoder architecture by replacing the default ViT encoder with a ResNet-18 backbone (Tab. 8). LeWM achieves competitive performance with both architectures, indicating that it is largely agnostic to the choice of vision encoder. Details

Training Curves. We report the training loss curves on PushT for LeWM in Fig. 18 and PLDM in Fig. 19. The two-term objective of LeWM exhibits smooth and monotonic convergence: the prediction loss decreases steadily while the SIGReg regularization term drops sharply in the early phase of training before plateauing, indicating that the latent distribution quickly approaches the isotropic Gaussian target. In contrast, PLDM's seven-term objective displays noisy and non-monotonic behavior across several of its loss components. These observations highlight a key advantage of LeWM: by reducing the training objective to only two well-behaved terms, the training becomes significantly more stable, removing the need to balance

5 Quantifying Physical Understanding in LeWM重试 错误原因

In this section, we evaluate the quality of the dynamics captured by LeWM's latent space, either by learning to extract physical quantities from latent embeddings or by measuring the world model's ability to detect changes in physics.重试 错误原因

5.1 潜在空间的物理结构

探测物理量。作为对物理理解的第一项测量，我们评估了哪些物理量可以从 LeWM 的潜在表示中恢复。我们训练了线性和非线性探针，以从给定的嵌入中预测感兴趣的物理量。Push-T 环境的结果报告在表 1 中。我们的方法始终优于 PLDM，同时与由大型预训练模型（如 DINOv2）生成的表示保持竞争力。

我们在附录 F.2 中提供了其他环境上的探测结果。

表 1：Push-T 上的物理潜在探测结果。LeWM 始终优于 PLDM，同时与 DINO-WM 保持竞争力。DINO-WM 在某些属性上的强大探测性能可能源于其基础模型预训练：DINOv2 编码器在两个数量级更多的数据（~124M 张图像）上训练，覆盖了远更多样化的分布，这可能使其能够通过默认的方式在其嵌入中捕获某些物理属性。

		线性		MLP	
属性	模型	MSE ↓	r ↑	MSE ↓	r ↑
Agent Location	DINO-WM	1.888 ± 0.500	0.977	0.003 ± 0.022	0.999
	PLDM	0.090 ± 0.311	0.955	0.014 ± 0.119	0.993
	LeWM	0.052 ± 0.149	0.974	0.004 ± 0.056	0.998
块位置	DINO-WM	0.006 ± 0.007	0.997	0.002 ± 0.003	0.999
	PLDM	0.122 ± 0.341	0.938	0.011 ± 0.066	0.994
	LeWM	0.029 ± 0.073	0.986	0.001 ± 0.006	0.999
块角度	DINO-WM	0.050 ± 0.101	0.979	0.009 ± 0.052	0.995
	PLDM	0.446 ± 0.625	0.745	0.056 ± 0.184	0.972
	LeWM	0.187 ± 0.359	0.902	0.021 ± 0.139	0.990

解码潜在空间。为了进一步评估潜在表示中捕获的信息，我们在图 8 中报告了由一个解码器生成的图像，该解码器在训练期间被训练用于从单个潜在嵌入（192 维）重建像素观测值。尽管重建在训练期间从未使用，但解码器能够从学习到的表示中恢复视觉场景，证实低维和紧凑的潜在空间保留了关于底层物理状态的大量信息。解码器架构的详细信息在附录 D 中提供。

可视化潜在空间。我们进一步使用 t-SNE 可视化潜在空间的结构。图 9 提供了 PushT 环境中潜在空间的定性可视化。可视化表明，学习到的表示捕获了环境的空间结构，保留了潜在空间中的邻域关系和相对位置。

时间潜在路径拉直。受神经科学中时间拉直假说[42]的启发，我们在整个训练过程中测量连续潜在速度向量之间的余弦相似度（公式 9）。我们发现，LeWM 的潜在轨迹在 PushT 上随着训练的进行变得越来越直，这是一种纯粹的自发现象，没有任何显式的正则化鼓励这种行为，参见图 17。值得注意的是，尽管 PLDM 采用了专门的时间平滑正则化项，LeWM 的时间直线性仍然优于 PLDM。我们在附录 H 中详细说明了我们的发现。

5.2 违反预期框架

量化物理理解的另一种方法是检测学习到的世界模型的违反情况。受发展心理学中使用的违反预期（VoE）范式以及最近在机器学习中采用的范式[43-45]的启发，该框架评估模型是否对与学习到的物理规律相悖的事件赋予更高的惊讶度。

在先前工作的基础上，我们通过测量模型预测的未来观测值与实际观测到的未来的差异来量化惊讶程度。我们在这个框架上进行了三个方面的评估。

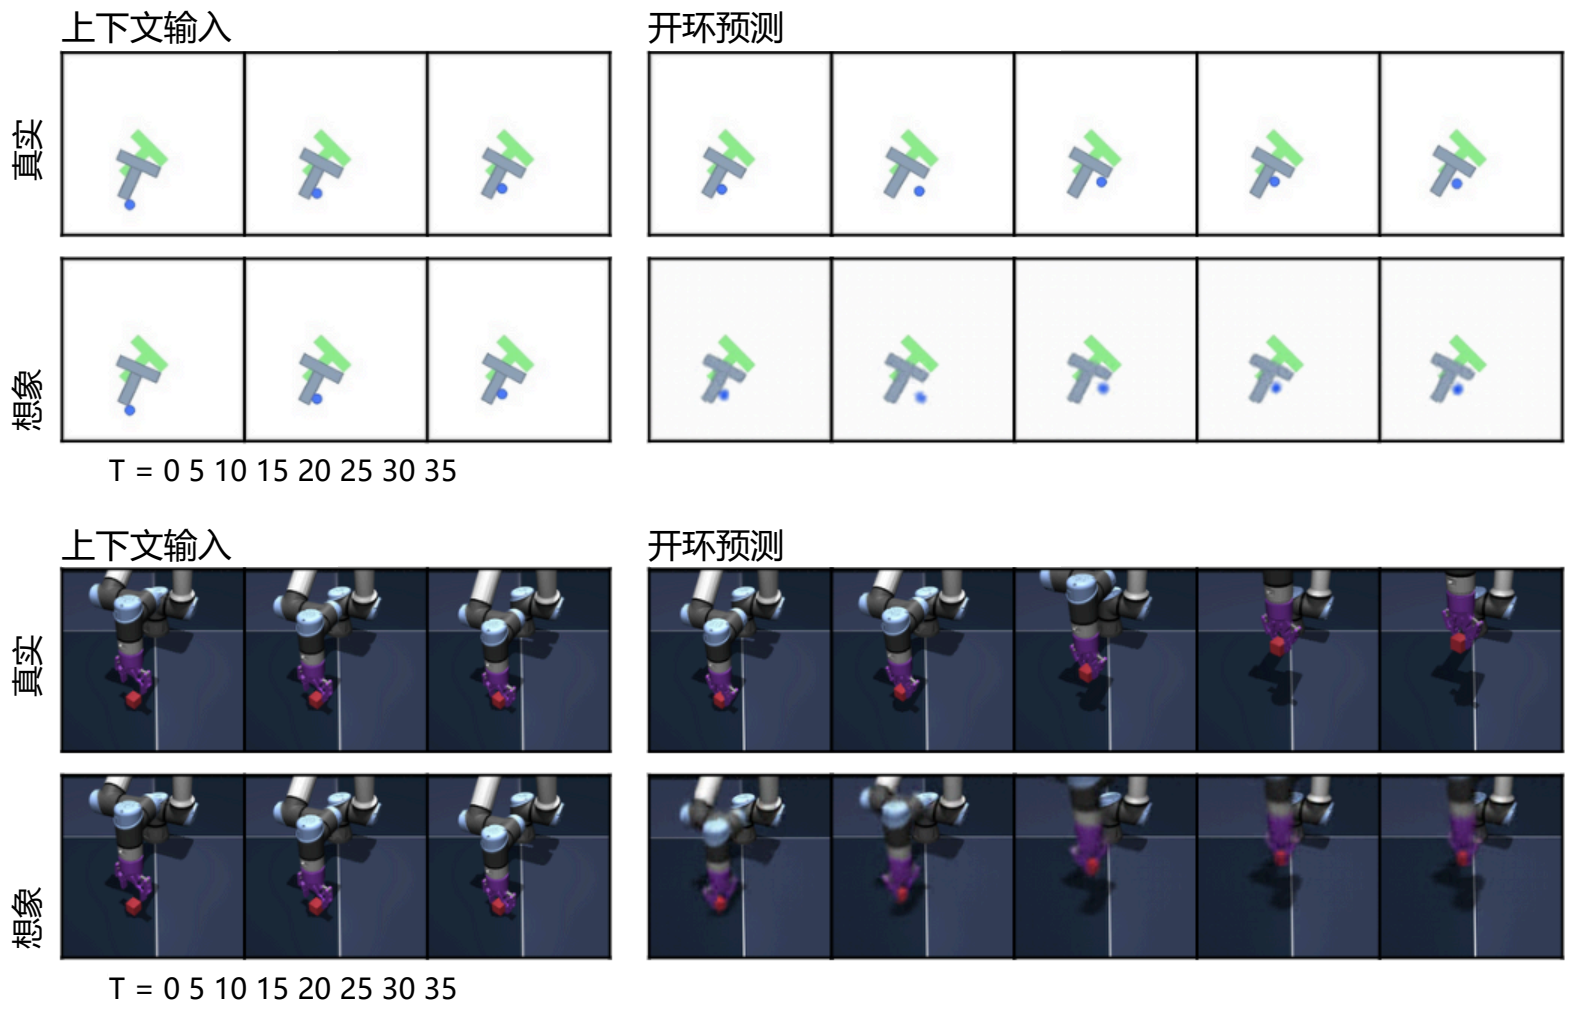

图 7：PushT 和 OGBench-Cube 上的预测器展开。我们可视化了解码后的潜在计划 LeWM 在给定上下文和动作序列的情况下生成结果。每个 rollout 使用三张图像作为上下文，这些图像被编码为潜在表示。基于动作序列，预测器以开环方式自回归地生成未来的潜在状态。所有预测的潜在状态都使用在训练过程中未使用的解码器解码为图像。生成的想象 rollout 与真实观察非常接近，表明潜在表示有效地捕捉了整体场景结构和关键环境动态。然而，LeWM 并未完全捕捉到一些更精细的细节；例如，OGBench-Cube 中末端执行器的角度。额外的 rollout 展示在图 11 中。

环境：TwoRoom、PushT 和 OGBench Cube。对于每个环境，我们引入两种类型的扰动。第一种是视觉扰动，其中物体在轨迹中的颜色发生突变。第二种是物理扰动，其中一个或多个物体被传送到随机位置，违反了场景的预期物理连续性。图 10 显示 LeWM 始终对包含物理违规的帧分配比其未扰动版本更高的惊讶度。我们在附录 F.3 中提供了更多关于 VoE 的细节。

6 结论

这项工作介绍了 LeWorldModel（LeWM），一种用于学习环境潜在世界模型的稳定端到端方法。LeWM 是一种联合嵌入预测架构，它使用编码器将图像观测映射到潜在空间，并使用预测器通过根据动作预测未来嵌入来对嵌入空间中的时间动态进行建模。在各种连续控制环境中，仅使用原始像素输入，LeWM 在数据效率、规划时间、训练时间和稳定性方面优于先前方法，同时保持了具有竞争力的最终任务性能。其训练的稳定性和简单性源于明确鼓励潜在嵌入遵循各向同性高斯分布以避免崩溃。总体而言，LeWM 为现有的潜在世界模型方法提供了一种可扩展的替代方案，同时提供了原则性的训练动态以及可解释和涌现的表示特性。

局限性与未来工作。尽管取得了这些有前景的结果，但一些局限性突出了重要的研究方向。首先，使用当前的潜在世界模型进行规划仍然局限于短期。分层世界建模代表了一个有前景的方向，用以解决长时程问题。

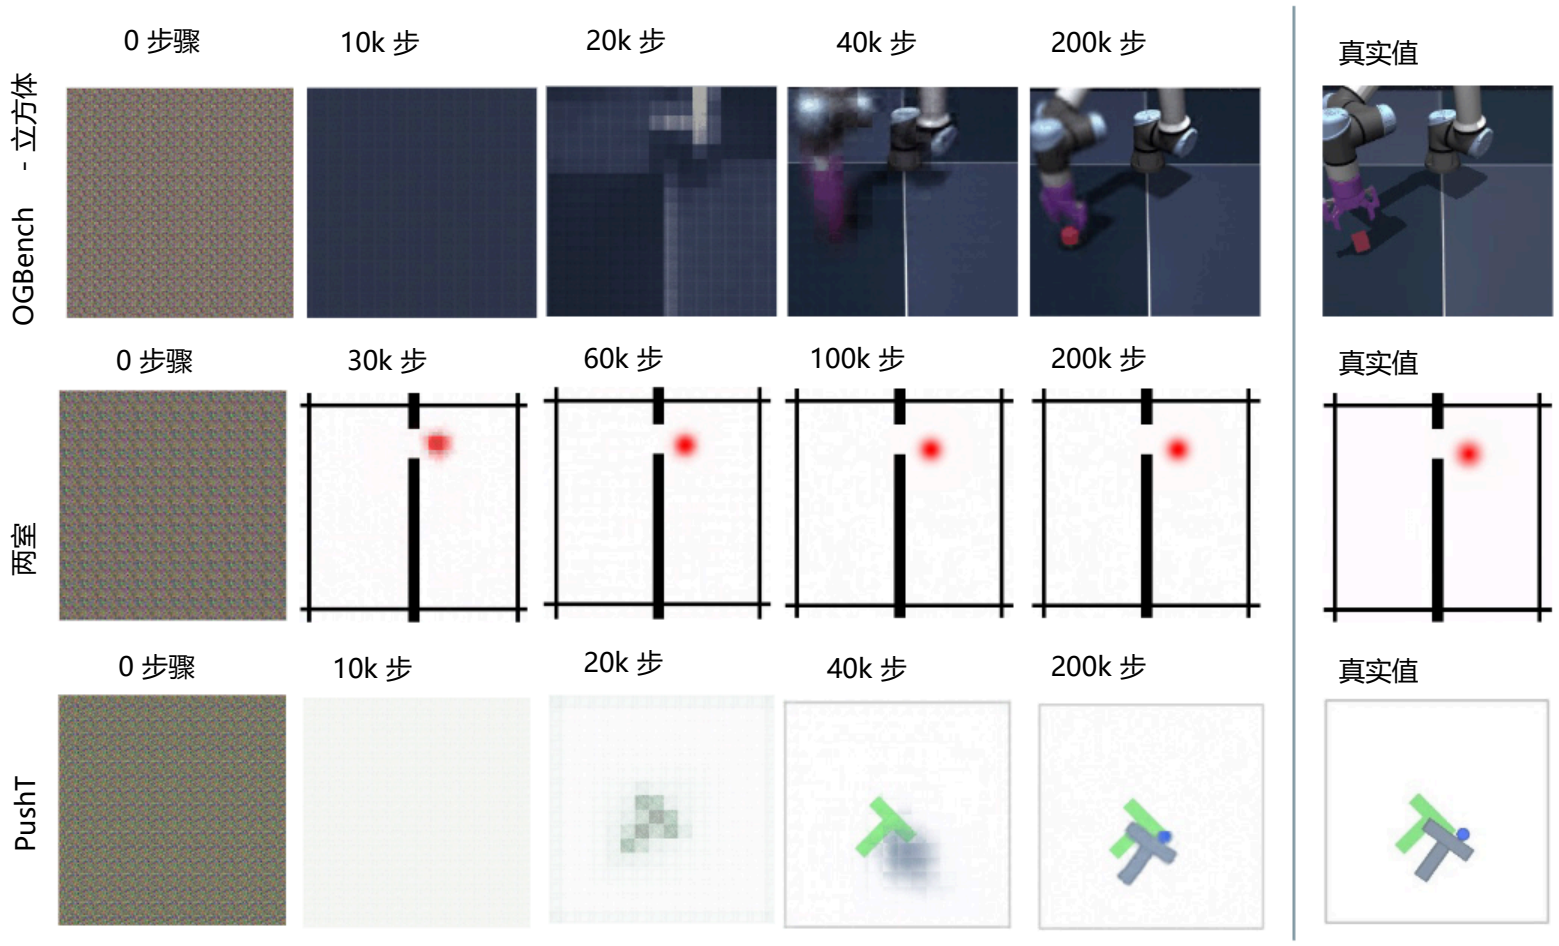

图 8：训练过程中的解码器可视化。随着训练的进行，潜在表示越来越多地捕获了重建视觉场景所需的信息，尽管在训练过程中没有使用重建损失。在训练初期，解码图像对应于慢特征，这一现象之前已被报道[21]。

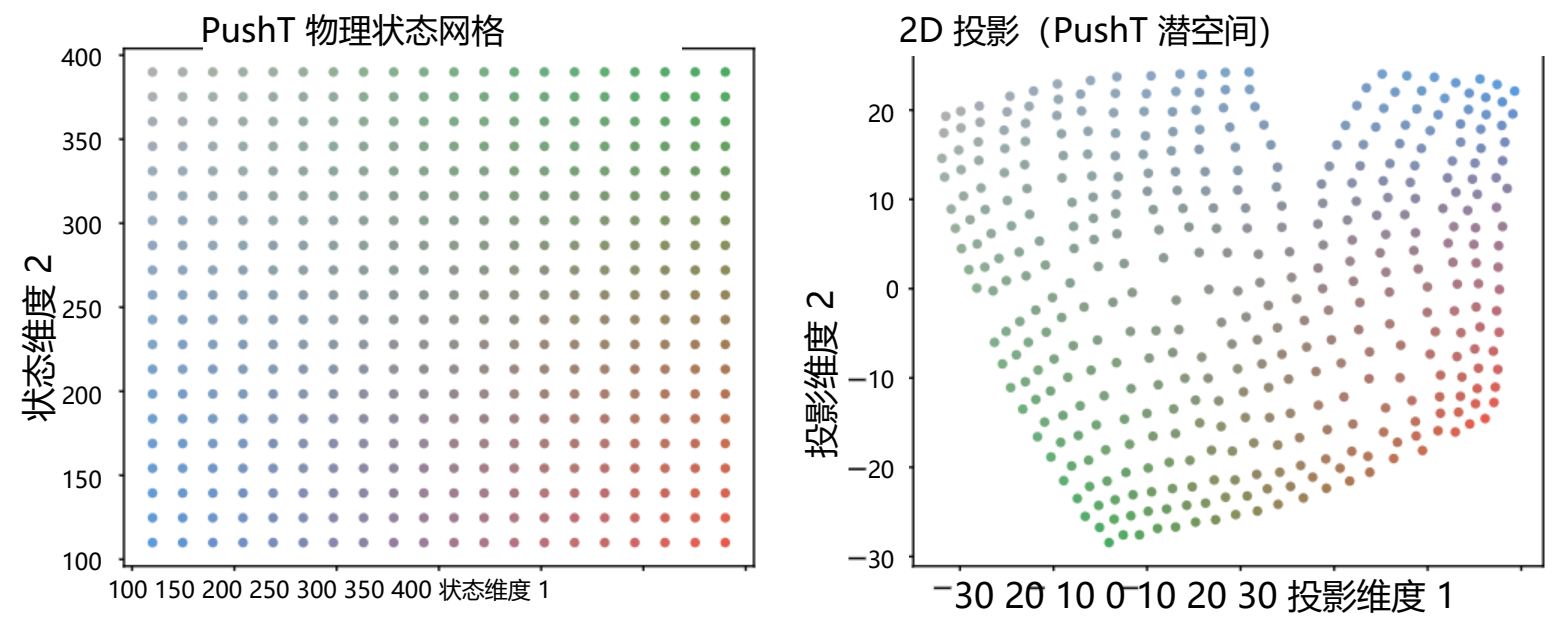

图 9：使用 LeWM 在 PushT 环境中获得的潜空间的可视化。左侧，通过在 x-y 平面移动智能体和方块获得状态网格。右侧，使用 t-SNE 可视化这些状态的嵌入。

推理和规划。其次，我们的方法仍然依赖于具有足够交互覆盖的离线数据集，这可能既昂贵又难以收集。特别是，有限的数据多样性可能会影响 SIGReg 正则化在具有低固有维度的非常简单的环境中的有效性，在这些环境中，在高维潜空间中匹配各向同性高斯先验变得具有挑战性。在大型且多样化的自然视频数据集上进行预训练可以提供强大的表示先验，并减少对特定领域数据的依赖。最后，当前的端到端潜空间世界模型依赖于动作标签来预测未来状态，这同样可能既昂贵又难以获得。一个有前景的方向是通过逆动力学建模学习未来动作表示，这有可能减少对明确动作标注的需求。

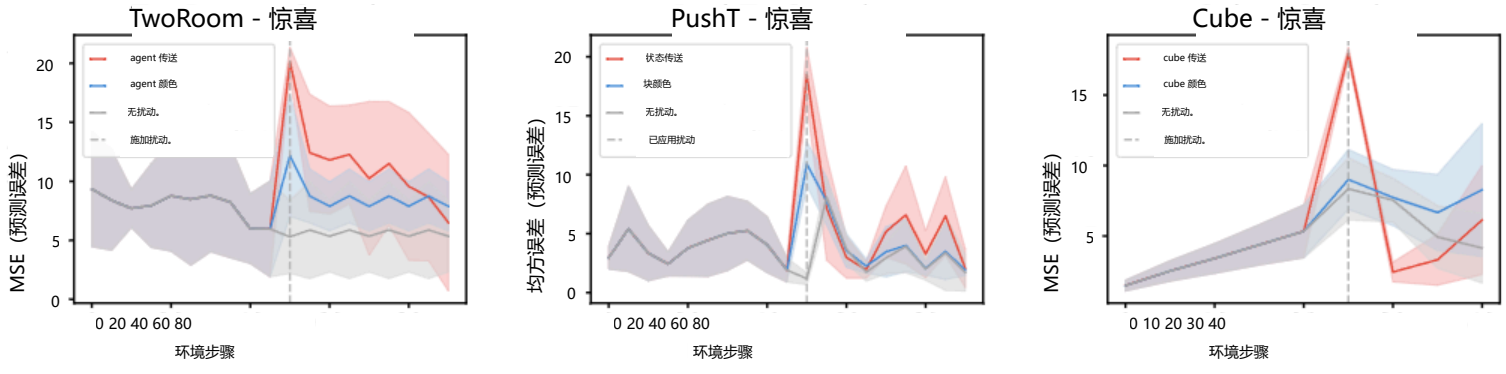

图 10：跨三种环境的预期违背评估。每个图展示了模型在三条轨迹上的惊讶程度：一条未扰动的参考轨迹、一条视觉扰动轨迹（其中物体的颜色突然变化）和一条物理扰动轨迹（其中一个或多个物体被传送到随机位置）。传送违反了物理连续性，并在惊讶值上产生明显的峰值，而未扰动轨迹则保持较低的基线。在所有三种环境中，传送扰动引起的惊讶值显著更高（配对 t 检验，$p < 0.01$），而立方体颜色扰动引起的增加较弱且不显著，表明模型对物理扰动比视觉扰动更敏感。从左到右，环境依次是 TwoRoom、PushT 和 OGBench Cube。

参考文献

[1] Sergey Levine, Chelsea Finn, Trevor Darrell, 和 Pieter Abbeel. 深度视觉运动策略的端到端训练. 机器学习研究杂志, 17(39):1–40, 2016.

[2] David Ha 和 Jürgen Schmidhuber. 世界模型. arXiv 预印本 arXiv:1803.10122, 2(3), 2018.

[3] Vincent Micheli、Eloi Alonso 和 François Fleuret。Transformer 是样本高效的模型模型。在第十一届学习表示国际会议，2023 年。URL https://openreview.net/forum?id=vhFu1Acb0xb.

[4] Danijar Hafner、Wilson Yan 和 Timothy Lillicrap。在可扩展的世界模型中训练智能体，2025 年。URL https://arxiv.org/abs/2509.24527。

[5] Yann LeCun。自主机器智能之路版本 0.9。2，2022-06-27。Open Review，62(1):1–62，2022。

[6] Eloi Alonso、Adam Jelley、Vincent Micheli、Anssi Kanervisto、Amos Storkey、Tim Pearce 和 François Fleuret。用于世界建模的扩散：在 Atari 中视觉细节很重要。在第 38 届神经信息处理系统大会，2024 年。URL https://openreview.net/forum?id=NadTwTODgC.

[7] Vincent Micheli, Eloi Alonso, 和 François Fleuret. 基于上下文的效率世界模型aware tokenization. 在第 41 届国际机器学习会议上，2024 年. URL https://openreview.net/forum?id=BiWIERWBFX.

[8] Decart，Julian Quevedo，Quinn McIntyre，Spruce Campbell，Xinlei Chen 和 Robert Wachen。Oasis：一个存在于 Transformer 中的宇宙。2024 年。URL https://oasis-model.github.io/。

[9] Jake Bruce, Michael Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, Yusuf Aytar, Sarah Bechtle, Feryal Behbahani, Stephanie Chan, Nicolas Heess, Lucy Gonzalez, Simon Osindero, Sherjil Ozair, Scott Reed, Jingwei Zhang, Konrad Zolna, Jeff Clune, Nando de Freitas, Satinder Singh，以及 Tim Rocktäschel。Genie：生成式交互环境，2024 年。URL https://arxiv.org/abs/2402.15391。

[10] 团队 HunyuanWorld. Hunyuanworld 1.0: 从文字或像素生成沉浸式、可探索和交互式 3D 世界. arXiv 预印本, 2025.

[11] Julian Quevedo, Ansh Kumar Sharma, Yixiang Sun, Varad Suryavanshi, Percy Liang, 和 Sherry Yang. Worldgym: 将世界模型作为策略评估环境, 2025. URL https://arxiv.org/abs/2506.00613.

[12] 马赫穆德·阿斯兰，昆汀·杜瓦尔，伊尚·米斯拉，皮奥特·博亚诺夫斯基，帕斯卡尔·文森特，迈克尔 Rabbat、Yann LeCun 和 Nicolas Ballas。从图像中进行自监督学习，采用联合-嵌入预测架构。在 IEEE/CVF 计算机视觉与模式识别会议论文集中，第 15619-15629 页，2023 年。

[13] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mido Assran 和 Nicolas Ballas. V-jepa：用于视觉表征学习的潜在视频预测。2023.

[14] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zholus, 等. V-jepa 2: 自监督视频模型实现理解、预测和规划. arXiv 预印本 arXiv:2506.09985, 2025.

[15] Zijian Dong, Li Ruilin, Yilei Wu, Thuan Tinh Nguyen, Joanna Su Xian Chong, Fang Ji, Nathanael Ren Jie Tong, Christopher Li Hsian Chen, 和 Juan Helen Zhou. Brain-JEPA: 基于脑动力学的梯度定位和时空掩码基础模型. 在第 38 届神经信息处理系统年度会议，2024 年。URL https://openreview.net/forum?id=gtU2eLSAmO.

[16] Alif Munim, Adibvafa Fallahpour, Teodora Szasz, Ahmadreza Attarpour, River Jiang, Brana Sooriyakanthan, Maala Sooriyakanthan, Heather Whitney, Jeremy Slivnick, Barry Rubin, Wendy Tsang, 和 Bo Wang. Echojepa: 一种用于超声心动图的潜在预测基础模型，2026 年。URL https://arxiv.org/abs/2602.02603.

[17] Jean Ponce，Basile Terver，Martial Hebert 和 Michael Arbel。双重视角下的非对比自监督学习。在第十四届学习表示国际会议，2026 年。URL https://openreview.net/forum?id=f5MC1G6XhB.

[18] 高岳周，潘恒凯，亚南·勒库恩，和莱雷尔·皮诺。Dino-wm：像素世界的模型预训练的视觉特征支持零样本规划。在《第 42 届国际机器学习会议论文集》（ICML 2025）中，2025 年。

[19] Raktim Gautam Goswami, Prashanth Krishnamurthy, Yann LeCun, 和 Farshad Khorrami. Osvi-wm: 基于世界模型引导轨迹生成的单次视觉模仿，用于未见过任务，2025 年。URL https://arxiv.org/abs/2505.20425.

[20] Heejeong Nam, Quentin Le Lidec, Lucas Maes, Yann LeCun, 和 Randall Balestriero. Causal-jepa: 通过对象级潜在干预学习世界模型，2026 年。URL https://arxiv.org/abs/2602.11389.

[21] 弗拉德·索巴尔，乔蒂尔·S·V，西迪哈特拉·贾拉加姆，尼古拉斯·卡里昂，金洪均·乔，以及扬 LeCun. 联合嵌入预测架构专注于慢特征，2022 年。URL https://arxiv.org/abs/2211.10831.

[22] 弗拉德·索巴尔，万丛张，金洪均·乔，兰德尔·巴莱斯特里罗，蒂姆·G·J·鲁德纳，以及扬 LeCun. 对无离线奖励强化学习的压力测试：使用潜在动态模型的规划案例。在第七届机器人学习研讨会：迈向具有人类水平能力的机器人，2025 年。URL https://openreview.net/forum?id=iON7H6A9UU.

[23] Adrien Bardes, Jean Ponce, 和 Yann LeCun. VICReg: 方差不变性-协方差正则化用于自监督学习的模型。在 2022 年国际学习表示会议上发表。URL https://openreview.net/forum?id=xm6YD62D1Ub.

[24] Randall Balestriero 和 Yann LeCun. 对比和非对比自监督学习恢复全局和局部光谱嵌入方法。神经信息处理系统进展，35:26671–26685，2022。

[25] Randall Balestriero 和 Yann LeCun. Lejepa: 可证明且可扩展的无启发式自监督学习，2025. URL https://arxiv.org/abs/2511.08544.

[26] David Ha 和 Jürgen Schmidhuber. 循环世界模型促进策略进化. 神经信息处理系统进展，31，2018.

[27] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, 和 Mohammad Norouzi. 梦想控制：通过潜在想象学习行为。在 2020 年国际学习表示会议。URL https://openreview.net/forum?id=S1lOTC4tDS。

[28] Danijar Hafner, Timothy Lillicrap, Mohammad Norouzi, 和 Jimmy Ba. 使用离散世界模型掌握 Atari。arXiv 预印本 arXiv:2010.02193, 2020。

[29] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, 和 Timothy Lillicrap. 通过世界模型掌握多样化领域。arXiv 预印本 arXiv:2301.04104, 2023。

[30] J Testud, J Richalet, A Rault, 和 J Papon. 模型预测启发式控制：应用于工业过程。Automatica, 14(5):413–428, 1978。

[31] Nicklas Hansen, Xiaolong Wang, 和 Hao Su. 基于时序差分学习的模型预测控制。在机器学习国际会议（ICML），2022 年。

[32] Nicklas Hansen、Hao Su 和 Xiaolong Wang。TD-MPC2：可扩展、鲁棒的世界模型连续控制。在第十二届学习表示国际会议，2024 年。URL https://openreview.net/forum?id=Oxh5CstDJU.

[33] Amir Bar, Gaoyue Zhou, Danny Tran, Trevor Darrell, 和 Yann LeCun. 导航世界模型，2025 年。URL https://arxiv.org/abs/2412.03572.

[34] Alexey Dosovitskiy. 一幅图像值 16x16 个词：用于大规模图像识别的 Transformer。arXiv 预印本 arXiv:2010.11929，2020 年。

[35] Sergey Ioffe 和 Christian Szegedy. 批归一化：通过减少内部协变量偏移来加速深度网络训练，2015 年。URL https://arxiv.org/abs/1502.03167.

[36] Jimmy Lei Ba, Jamie Ryan Kiros, 和 Geoffrey E Hinton. 层归一化。arXiv 预印本 arXiv:1607.06450，2016 年。

[37] William Peebles 和 Saining Xie. 基于 transformer 的可扩展扩散模型。在 IEEE/CVF 国际计算机视觉会议论文集中，第 4195–4205 页，2023 年。

[38] Thomas W Epps 和 Lawrence B Pulley. 基于经验特征函数的正态性检验。Biometrika，70(3):723–726，1983 年。

[39] Harald Cramér 和 Herman Wold. 关于分布函数的一些定理。伦敦数学学会杂志，1(4):290–294，1936 年。

[40] Reuven Y Rubinstein 和 Dirk P Kroese. 交叉熵方法：一种统一的方法。组合优化、蒙特卡洛模拟和机器学习。Springer Science & Business Media, 2004。

[41] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel HAZIZA, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Herve Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: 无监督学习鲁棒视觉特征。机器学习研究交易, 2024。ISSN 2835-8856。URL https://openreview.net/forum?id=a68SUt6zFt. 特色认证。

[42] Olivier J Hénaff, Robbe LT Goris, 和 Eero P Simoncelli. 自然视频的感知校正. Nature neuroscience, 22(6):984–991, 2019.

[43] Francesco Margoni, Luca Surian, 和 Renée Baillargeon. 预期违背范式：概念概述. Psychological Review, 131(3):716, 2024.

[44] Quentin Garrido, Nicolas Ballas, Mahmoud Assran, Adrien Bardes, Laurent Najman, Michael Rabbat, Emmanuel Dupoux, 和 Yann LeCun. 从自然视频的自监督预训练中涌现出直观的物理理解. arXiv preprint arXiv:2502.11831, 2025.

[45] Florian Bordes, Quentin Garrido, Justine T Kao, Adina Williams, Michael Rabbat, and Emmanuel Dupoux. Intphys 2: 在复杂合成环境中基准测试直观物理理解, 2025. URL https://arxiv.org/abs/2506.09849.

[46] Ilya Kostrikov、Ashvin Nair 和 Sergey Levine. 基于隐式 Q 学习的离线强化学习. arXiv 预印本 arXiv:2110.06169, 2021.

[47] Seohong Park, Kevin Frans, Benjamin Eysenbach, 和 Sergey Levine. OGBench: Bench 标记离线目标条件强化学习。在第十三届学习表示国际会议，2025 年。URL https://openreview.net/forum?id=M992mjgKzI.

[48] Dibya Ghosh, Abhishek Gupta, Ashwin Reddy, Justin Fu, Coline Devin, Benjamin Eysenbach, 和 Sergey Levine. 通过迭代监督学习学习实现目标. arXiv 预印本 arXiv:1912.06088, 2019.

[49] Randall Balestriero, Hugues Van Assel, Sami BuGhanem, 和 Lucas Maes. stable-pretraining-v1: 使基础模型研究变得简单, 2025. URL https://arxiv.org/abs/2511.19484.

[50] Lucas Maes, Quentin Le Lidec, Dan Haramati, Nassim Massaudi, Damien Scieur, Yann LeCun, 和 Randall Balestriero. stable-worldmodel-v1: 可复现的建模研究及评估, 2026. URL https://arxiv.org/abs/2602.08968.

[51] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zach DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, 和 Soumith Chintala. Pytorch: 一种命令式风格的高性能深度学习库, 2019. URL https://arxiv.org/abs/1912.01703.

[52] Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, 等. Gymnasium: 强化学习环境的标准接口. arXiv 预印本 arXiv:2407.17032, 2024.

[53] Yuval Tassa, Yotam Doron, Alistair Muldal, Tom Erez, Yazhe Li, Diego de Las Casas, David Budden, Abbas Abdolmaleki, Josh Merel, Andrew Lefrancq, 等. Deepmind 控制套件. arXiv 预印本 arXiv:1801.00690, 2018.

[54] Christian Internò, Robert Geirhos, Markus Olhofer, Sunny Liu, Barbara Hammer, and David Klindt. 基于感知校正的 AI 生成视频检测. 在第 39 届年度神经信息处理系统大会，2025。URL https://openreview.net/forum?id=LsmUgStXby.

[55] Ying Wang, Oumayma Bounou, Gaoyue Zhou, Randall Balestriero, Tim GJ Rudner, Yann LeCun, and Mengye Ren. Temporal straightening for latent planning. arXiv preprint arXiv:2603.12231, 2026.

A SIGReg

SIGReg 提出使嵌入的分布匹配到各向同性高斯目标分布。在高维空间中实现这种匹配是通过结合两个统计成分（i）Cramer-Wold 定理，以及（ii）单变量 Epps-Pulley 检验统计量来优雅地完成的。简而言之，SIGReg 首先产生 M 个单位范数方向 u，并将嵌入 Z 投影到这些方向上，表示为

$$h \triangleq Zu,\ u \in S, \tag{6}$$

其中方向在超球面上均匀采样。然后，SIGReg 执行单变量分布匹配，表示为

$$\mathrm{SIGReg}(Z) \triangleq \frac{1}{M}\sum_{m=1}^{M} T, \tag{SIGReg}$$

with T 为单变量 Epps-Pulley 检验统计量

$$T = \int_{-\infty}^{Z} w(t)\,\phi(t;h) - \phi(t)\,\Big|^{2} dt, \qquad \text{(EP)}$$

其中经验特征函数（ECF）定义为 $\phi(t;h) = \frac{1}{n}\sum_{n=1}^{P} e$, w 是加权函数，例如 $w(t) = e$。根据 Cramér–Wold 定理，匹配所有 1D 边缘分布意味着匹配联合分布，即在 M 的渐近极限下，我们有以下弱收敛结果

$$\mathrm{SIGReg}(Z) \to 0 \iff P \to N(0, I)。 \qquad \text{(Cramer-Wold)}$$

实际上，方程 EP 中的积分采用求积方案，例如使用 T 个节点均匀分布在[0.2, 4]区间内的梯形求积法。

B 交叉熵方法

交叉熵方法（CEM）[40]是一种基于采样的（零阶）优化算法。直观上，CEM 是一种迭代采样过程，在每次迭代中逐步优化一个计划，该计划定义为一组动作的序列。

在每次迭代中，算法从分布中采样一组候选计划，通常是高斯分布（初始参数为μ = 0 和σ = I）。接下来，使用世界模型评估每个候选计划，并为其关联一个成本。然后，算法选择成本最低的前 k 个计划，称为精英计划。这些精英计划用于计算统计数据，以更新下一轮迭代的采样分布参数。通过这种迭代过程，该方法探索动作空间，同时逐渐使采样分布集中在与较低成本相关的区域。最终的动作计划是从最后一次迭代的采样分布均值中获得的。

然而，在非凸设置中，没有保证 CEM 收敛到的解是全局最优解。此外，CEM 受到维数灾难的影响，当动作空间较大时，应用难度越来越大。

在我们的实验中，我们使用一个 CEM 求解器，每个迭代采样 300 个动作序列，并执行 30 次优化步骤。在每个步骤中，选择成本最低的前 30 个候选作为精英来更新采样分布。我们在算法 2 中提供了该算法的伪代码。

算法 2 用于动作序列优化的交叉熵方法（CEM）

需求：世界模型 f，规划范围 H，样本数量 N，精英数量 K，迭代次数 T 1: 初始化采样分布参数μ= 0, Σ= I 2: for t = 1 to T do 3: 采样 N 个候选动作序列{a}~ N (μ, Σ) 4: for i = 1 to N do 5: 在世界模型 f 中展开 ai 6: 计算成本 J 7: end for 8: 选择成本最低的 K 个序列（精英） 9: 使用精英集更新分布参数： 10: μ←

$$\sum_{i\in E} a$$

11: Σ← Var a

12: end for

13: 返回找到的最佳动作序列或μ的第一个动作

C 基线

C.1 DINO-WM

DINO 世界模型（DINO-WM）专注于通过利用 DINOv2 冻结的预训练表示来学习预测器，以避免崩溃。由于未进行端到端训练，损失仅仅是使预测的下一个嵌入与 DINOv2 产生的真实下一个状态嵌入最小化。

$$L_{\text{DINO-WM}} = \frac{1}{BT} \sum_{i}^{B} \sum_{t}^{T} \| \hat{z} - z \| \tag{7}$$

我们使用与原始论文[18]相同的环境设置（包括架构、超参数等）

C.2 PLDM

PLDM [22] 提出了一种学习端到端联合嵌入预测架构（JEPA）的方法。为了避免崩溃，他们的方法借鉴了方差不变性协方差正则化（VICReg，[23]），并增加了额外项来考虑下一状态预测的时间性。PLDM 的目标函数如下：

$$L = L + \alpha L + \beta L + \gamma L + \zeta L + \nu L + \mu L \tag{8}$$

其中，

$$L = \frac{1}{BT} \sum_{i}^{B} \sum_{t}^{T} \| \hat{z} - z \|$$

$$L = \frac{1}{TD} \sum_{t}^{T} \sum_{d}^{D} \max\left(0, 1 - q\left(\frac{}{\text{Var}(z) + \epsilon}\right)\right)$$

$$L = \frac{1}{T} \sum_{t}^{T} \frac{1}{D} \sum_{i \neq j}^{D} [\text{Cov}(Z)]$$

$$L = \frac{1}{BT} \sum_{i}^{B} \sum_{t}^{T} \| z - z \|$$

$$L_{\text{time-var}} = \frac{1}{BD} \sum_{i}^{B} \sum_{d}^{D} \max\left(0, 1 - q\left(\frac{}{\text{Var}(z) + \epsilon}\right)\right)$$

$$L = \frac{1}{B} \sum_{b}^{B} \frac{1}{D} \sum_{i \neq j}^{D} [\text{Cov}(Z)]$$

$$L = \frac{1}{BT} \sum_{i}^{B} \sum_{t}^{T} \| \hat{a} - a \|$$

其中 $z \in R$ 对应于轨迹 $i \in [B]$中属于$[T]$的步骤 t，T 是轨迹长度，B 是批次大小，$Z \in R$ 表示其第 i 行是 z 的矩阵，即

$$Z = \begin{bmatrix} (zt) \\ \vdots \\ (zt) \end{bmatrix},$$

让 $\bar{Z}$be Z 的行中心版本：

$$\bar{Z} = Z - \frac{1}{B} 11 Z.$$

然后，对于每个时间步 t 和特征维度 d，批次的方差是

$$\mathrm{Var}(z) = \frac{1}{B-1} \sum_{i=1}^{B} \left(z - \frac{1}{B} \sum_{i=1}^{B} z_{t,d} \right)^{!},$$

以及特征维度上的协方差矩阵是

$$\mathrm{Cov}(Z) = \frac{1}{B-1} \bar{Z}^{\top} \bar{Z} \in R.$$

类似地，对于时间正则化，设 $Z \in R$ 表示其第 t 行是 z 的矩阵，设 $\bar{}Z$ 为其行中心化版本：

$$\bar{Z} = Z - \frac{1}{T} 11 Z.$$

那么，时间上的方差是

$$\mathrm{Var}(z) = \frac{1}{T-1} \sum_{t=1}^{T} \left(z - \frac{1}{T} \sum_{t=1}^{T} z \right)^{!},$$

以及时间协方差矩阵是

$$\text{协方差矩阵}(\mathrm{Cov}(Z)) \in \frac{1}{T-1} \bar{Z}^{\top} \bar{Z} \in R.$$

$\hat{z} \in R$ 是在第 t 步使用预测器对轨迹 i 预测的嵌入。$a \in R$ 是与第 t 步相关的动作，$\hat{}a \in R$ 是逆动力学模型 (IDM) idm(z, z) 对的预测动作。

我们通过在损失系数上进行网格搜索来选择 PLDM 超参数。由于整体目标包括六个可调权重 (α, β, γ, ζ, ν, μ)，对所有组合进行穷举搜索是不切实际的 (O(n))。此外，原始 PLDM 研究报告了针对每个环境和数据集进行广泛调整的系数，这限制了它们的可迁移性。我们从他们开源代码库中提供的超参数集开始。我们选择这一做法的理由是原始论文中没有提到时间变分和时序协方差正则化项。然后我们对每个初始损失系数在 Push-T 上进行 256 次配置的网格搜索，并保留在保留集上表现最好的那个。我们在表 2 中报告了找到的最佳超参数。我们为所有训练将这些系数保持固定。

损失系数	初始值
α	18.0
β	12
γ	0.2
ζ	0.7
ν	0.0
μ	0.0

表 2：网格搜索找到的最佳系数。

C.3 GC-RL

为了评估下游控制，我们使用带离线训练的目标条件强化学习（GC-RL）。具体来说，我们考虑了隐式 Q 学习（IQL）和隐式值学习（IVL）的目标条件变体。在这两种情况下，观察值和目标都使用 DINOv2 补丁嵌入进行编码，策略从离线数据集进行训练。训练分为两个阶段：首先学习值函数（可选地学习 Q 函数），然后通过优势加权回归进行策略提取。

GCIQL 隐式 Q 学习 (IQL) [46] 是一种离线强化学习算法，通过期望回归学习价值函数来避免查询分布外动作。在目标条件设置中，该算法学习在目标 g 条件下的 Q 函数 Q(s, a, g) 和价值函数 V(s, g)。

Q 函数使用贝尔曼回归进行训练，从目标值网络 V 进行自举：

$$L = E\left[(Q(s, a, g) - (r(s, g) + \gamma m V(s, g))) \right],$$

其中，如果 s=g（终止转换），则 m=0，否则 m=1。

值网络使用期望回归针对目标 Q 网络 Q 中的目标进行训练

$$L = E\left[L\left(Q(s, a, g) - V(s, g) \right) \right],$$

期望损失定义为

$$L(u) = |\tau - 1(u < 0)|u.$$

总评论家损失由

$$L = L + L.$$

GCIVL 隐式值学习 (IVL) [47] 通过移除 Q 函数，直接通过引导目标学习值函数来简化 IQL。值网络 V(s, g) 通过对目标网络 V 的期望回归进行训练：

$$L = E\left[L(r(s, g) + \gamma V(s, g) - V(s, g)) \right].$$

与 IQL 类似，L 表示非对称期望损失，γ 是折扣因子。

策略提取。对于 GCIQL 和 GCIVL，策略π(s, g)通过优势加权回归（AWR）进行训练。策略目标为

$$L = E\left[\exp\left(\beta A(s, a, g)\right) \| \pi(s, g) - a \| \right],$$

其中优势的计算方式为

$$A(s, a, g) = r(s, g) + \gamma V\left(s, g\right) - V\left(s, g\right),$$

β是一个逆温度参数，用于控制优势加权的强度。

C.4 GCBC

作为简单的模仿学习基线，我们考虑目标条件行为克隆（GCBC）[48]。GCBC 训练一个目标条件策略π(s, g)，在给定当前观测值 s 和目标观测值 g 的情况下，复制专家动作。在我们的实现中，观测值和目标都使用 DINOv2 patch embedding 进行编码，然后再提供给策略网络。
该策略通过在状态-动作-目标元组离线数据集 D 上进行监督学习进行训练。具体而言，目标是最小化预测动作与数据集中采取的动作之间的均方误差：

$$L = E\left[\| \pi(s, g) - a \| \right],$$

其中 s 表示观察嵌入，g 表示目标嵌入，a 表示相应的专家动作。

D 实现细节

我们采用 5 帧跳跃，将连续帧之间的动作分组为一个动作块。这一选择能够在保持信息丰富的时序转换的同时，实现计算高效的长期预测。我们使用 128 的批量大小，对应于 4 帧和 4 个包含 5 个动作的块，每个子轨迹大小为 4。每帧为 224 × 224 像素。所有训练脚本均使用稳定预训练[49]制作。

编码器架构。编码器是 Hugging Face 库中的 Vision Transformer Tiny (ViT-Tiny)模型，使用 14 的块大小。
预测器架构。预测器实现为一个具有学习位置嵌入和观察历史因果掩码的 ViT-S 主干网络。对于 PushT 和 OGBench-Cube 环境，历史长度设置为 3，对于 TwoRoom 设置为 1。在规划过程中，预测器被自回归地用于生成未来潜在状态的轨迹。

解码器（仅用于可视化）。为了可视化，我们使用轻量级 Transformer 解码器将最后一个编码器层的[CLS]标记嵌入（192 维）解码为图像。首先将[CLS]表示投影到隐藏维度，并用作交叉注意力的键和值。一组固定的可学习查询标记（每个目标图像的一个补丁对应一个标记）通过多个带有残差 MLP 块的交叉注意力层与这个全局表示交互。对于大小为 224×224、补丁大小为 16 的图像，这对应于 P = (224/16)= 196 个可学习查询标记。生成的补丁嵌入然后线性投影到 16×16×3 像素的补丁，并重新排列以生成 224×224 RGB 图像。这个解码器仅用作诊断工具，以可视化[CLS]表示中保留了哪些视觉信息。
规划求解器。在规划过程中，我们使用交叉熵方法（CEM）。在每个规划步骤中，CEM 采样 300 个候选动作序列，并在 PushT 环境中最多进行 30 次迭代，在其他环境中最多进行 10 次迭代进行优化。每次迭代中，保留前 30 条轨迹来更新采样分布，初始采样方差设置为 1。规划范围设置为 5 步，由于使用了 5 帧跳跃，这对应于 25 个环境时间步。我们采用一个 5 步的回退范围模型预测控制（MPC）方案，这意味着整个优化的动作序列在重新规划之前被执行。此配置遵循文献[18]中使用的设置。

实现和硬件。所有实验均使用 stable-worldmodel [50]框架实现。训练依赖于 stable-pretraining [49]库，而评估则使用 PyTorch [51]和 Gymnasium [52]进行。训练和规划均在单个 NVIDIA L40S GPU 上执行。

E 环境 & 数据集

a) TwoRoom 是由 Sobal 等人[22]引入的一个简单的连续 2D 导航任务。该环境由两间由一堵墙隔开的房间组成，墙上一扇门连接着它们。智能体（以红点表示）必须从一个房间的随机起始位置导航到另一个房间中随机采样的目标位置，这需要通过门。我们收集了 10,000 个场景，平均轨迹长度为 92 步。数据是使用一个简单的带噪声启发式策略生成的，该策略首先引导智能体沿直线路径朝向门，一旦智能体进入另一间房间后，再引导其朝向目标位置。每个世界模型都在这个数据集上训练 10 个 epoch。

b) PushT 是一个连续的 2D 操作任务，其中代理（以蓝色点表示）必须将 T 形方块推到匹配目标配置，且交互仅限于推挤动作。我们遵循 Zhou 等人[18]的相同设置和数据集，其中包含 20,000 个专家轨迹，平均长度为 196 步。然而，我们仅对每个世界模型进行 10 个 epoch 的训练。经验上，我们发现 10 个 epoch 足以达到最佳性能，与 DINO-WM 论文中报告的结果相匹配。

c) OGBench-Cube 是一个连续的 3D 机器人操作任务，其中带有末端执行器的机械臂必须捡起一个方块并将其放置在目标位置。该任务最初由

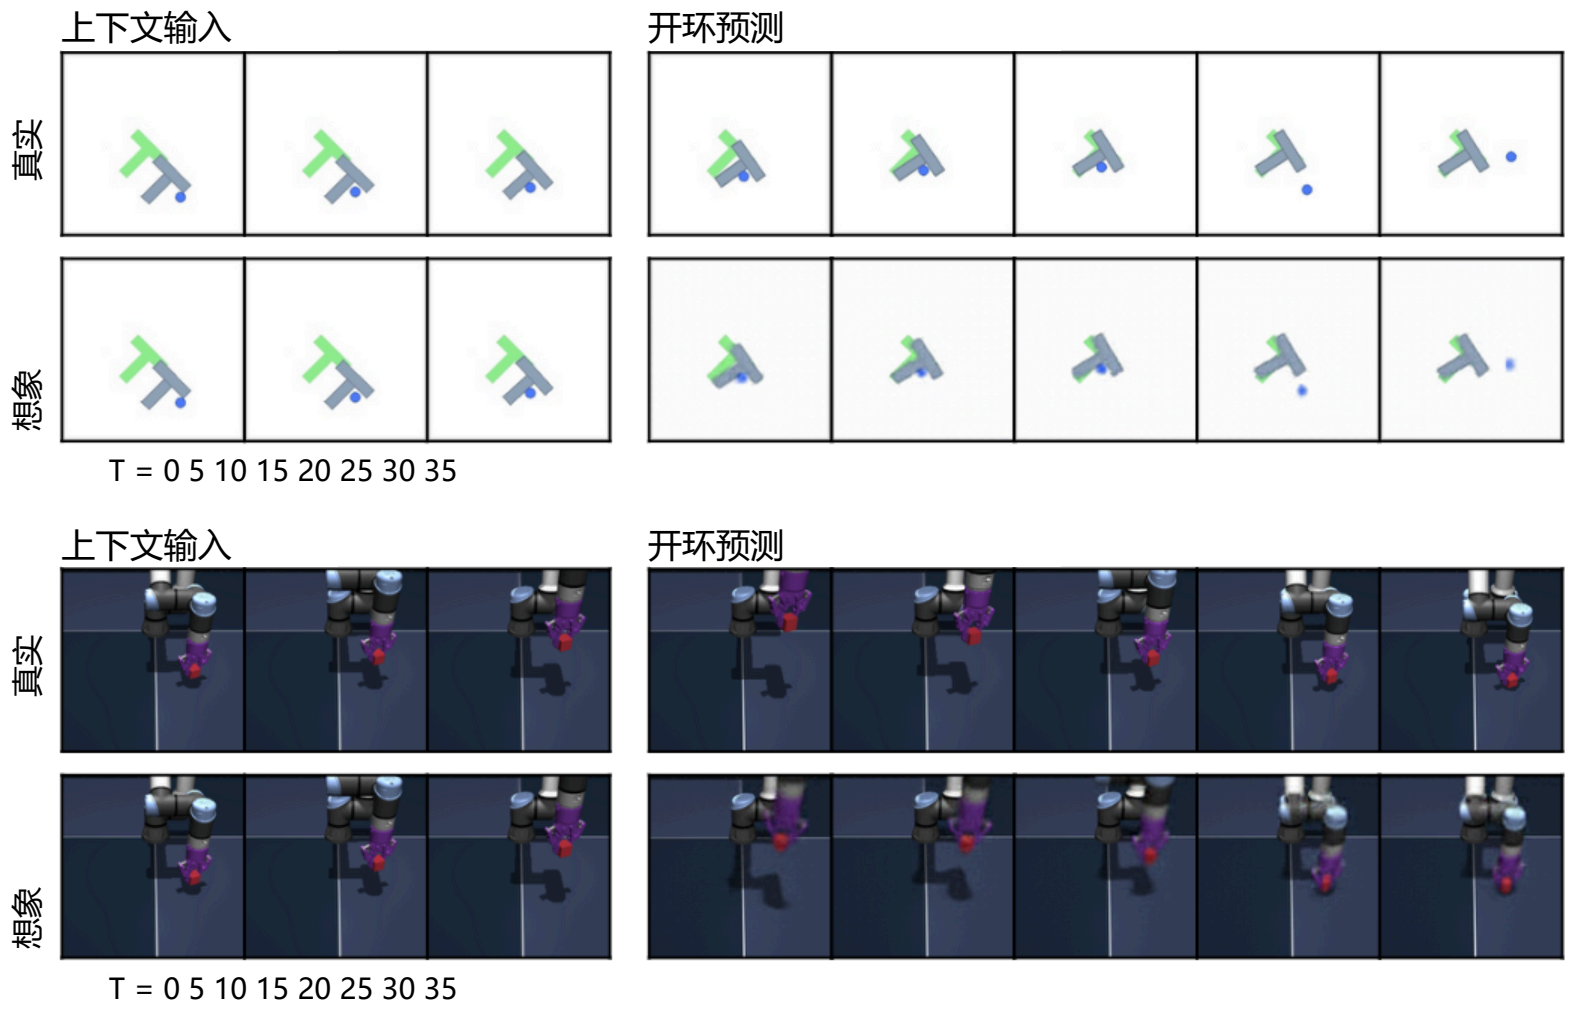

图 11：PushT（上）和 OGBench-Cube（下）的额外预测器展开。与图 7 相同的设置：三个上下文帧被编码为潜在表示，预测器根据动作序列自回归地生成未来的潜在状态。所有预测都使用在训练期间未使用的解码器进行解码。在 PushT 上，想象的轨迹紧密跟踪真实轨迹，准确捕捉了智能体和积木的运动。在 OGBench-Cube 上，模型保留了整体场景布局和积木位移，但在较长的范围上丢失了更精细的细节，例如末端执行器的方向，这与表 4 中报告的旋转量探测精度较低一致。

在 Park 等人 [47] 中，我们仅考虑单积木变体。我们收集了 10,000 个场景，每个场景包含 200 步。数据使用基准库中提供的数据收集启发式方法生成。每个世界模型在这个数据集上训练 10 个 epoch。

d) Reacher 是 DeepMind 控制套件[53]中的一个连续控制环境。该任务包括控制一个双关节机械臂，使其在 2D 平面上到达目标位置。遵循 DINO-WM 中使用的设置，我们考虑成功定义为机械臂关节与目标位置所需的目标配置完美对齐的变体。我们在一个包含 10,000 个场景的数据集上训练每个世界模型，每个场景包含 200 步。数据是使用 Soft Actor-Critic 策略收集的。

F 评估细节

F.1 控制

我们在之前介绍的三种环境中对 LeWM 在目标条件控制任务上的表现进行了评估。控制性能通过两个参数进行衡量：评估预算和目标距离。评估预算对应于智能体在环境中被允许执行的最大动作数量。目标距离决定了相对于初始状态，目标状态在未来被采样的时间步长。在评估过程中，从离线数据集中采样轨迹。初始状态通过随机从数据集中的某条轨迹中采样一个状态来选择，而目标状态则对应于同一条轨迹中发生时间步长稍后的状态。这确保了目标是可达的，并且与数据集的动态特性一致。在 TwoRoom 中，评估预算设置为 150 步，目标状态在未来 100 步时采样。在 PushT 中，评估预算为 50 步，目标在未来 25 步时采样。在 OGBench-Cube 和 Reacher 中，评估预算为 50 步，目标在未来 25 步时采样。

F.2 探测

我们使用探测方法来分析三个环境中学习到的潜在表示所包含的信息。具体来说，我们训练线性和非线性探测器，从潜在嵌入中预测物理量。线性探测器评估信息是否在潜在空间中是线性可访问的，而非线性探测器评估信息是否存在但可能存在纠缠。
对于每个探测器，我们报告预测量与真实量之间的均方误差（MSE）和皮尔逊相关系数。

探测的变量在不同的环境中有所不同。在 TwoRoom 中，我们探测智能体的二维位置（表 3）。在 PushT 中，我们探测智能体的状态和方块的状态（表 1）。在 OGBench-Cube 中，我们探测立方体的位置和机器人末端执行器的位置（表 4）。

表 3：TwoRoom 环境下的物理潜在探针结果。尽管 LeWM 在这个环境下的下游规划表现不如 PLDM，但在所有探针指标上，LeWM 均与 PLDM 持平或优于 PLDM，并且两种方法在线性探针上均显著优于 DINO-WM。这表明学习到的潜在空间同样有效地捕捉了底层物理状态，而规划差距并非由于表示信息量不足，而是由于其他因素，如动态模型或规划过程本身。

	智能体位置			
	线性		MLP	
模型	MSE ↓	r ↑	MSE ↓	r ↑
DINO-WM	0.488 ± 0.451	0.824	0.000 ± 0.000	0.999
PLDM	0.008 ± 0.041	0.996	0.000 ± 0.000	1.000
LeWM	0.008 ± 0.018	0.996	0.000 ± 0.000	1.000

F.3 违反预期

我们使用违反预期（VoE）框架在三个环境中评估物理理解能力。在每个环境中，我们生成三种类型的轨迹：一个未受干扰的参考轨迹，一个包含视觉干扰的轨迹，以及一个包含物理干扰的轨迹。视觉干扰对应于物体颜色的突然变化，而物理干扰对应于将物体传送到随机位置，从而违反物理连续性。轨迹的示例显示在图 12 中。

TwoRoom. 在 TwoRoom 环境中，智能体由一个专家策略控制，导航至目标位置。我们生成了三条轨迹：（1）未受干扰的轨迹，（2）在回合中途智能体颜色发生变化的轨迹，以及（3）智能体在同一时间步被传送到随机位置的轨迹。PLDM 和 DINO-WM 的意外信号分别显示在图 13 和图 14 的左侧面板中。

PushT. 在 PushT 环境中，智能体由一个偏向与积木交互的随机策略控制。与前文一样，我们构建了三条轨迹：（1）未受干扰的轨迹，（2）在回合期间积木颜色突然变化的轨迹，以及（3）智能体和积木在同一扰动时间步被传送到随机位置的轨迹。PLDM 和 DINO-WM 的对应意外信号分别显示在图 13 和图 14 的中间面板中。

OGBench-Cube。在 OGBench-Cube 环境中，智能体遵循专家策略，捡起立方体并将其放置在目标位置。我们再次考虑三种轨迹：（1）未受干扰的轨迹，（2）立方体颜色在回合期间发生变化的轨迹，以及（3）立方体在轨迹中途被传送到随机位置的轨迹。PLDM 和 DINO-WM 产生的意外信号分别显示在图 13 和图 14 的右图中。

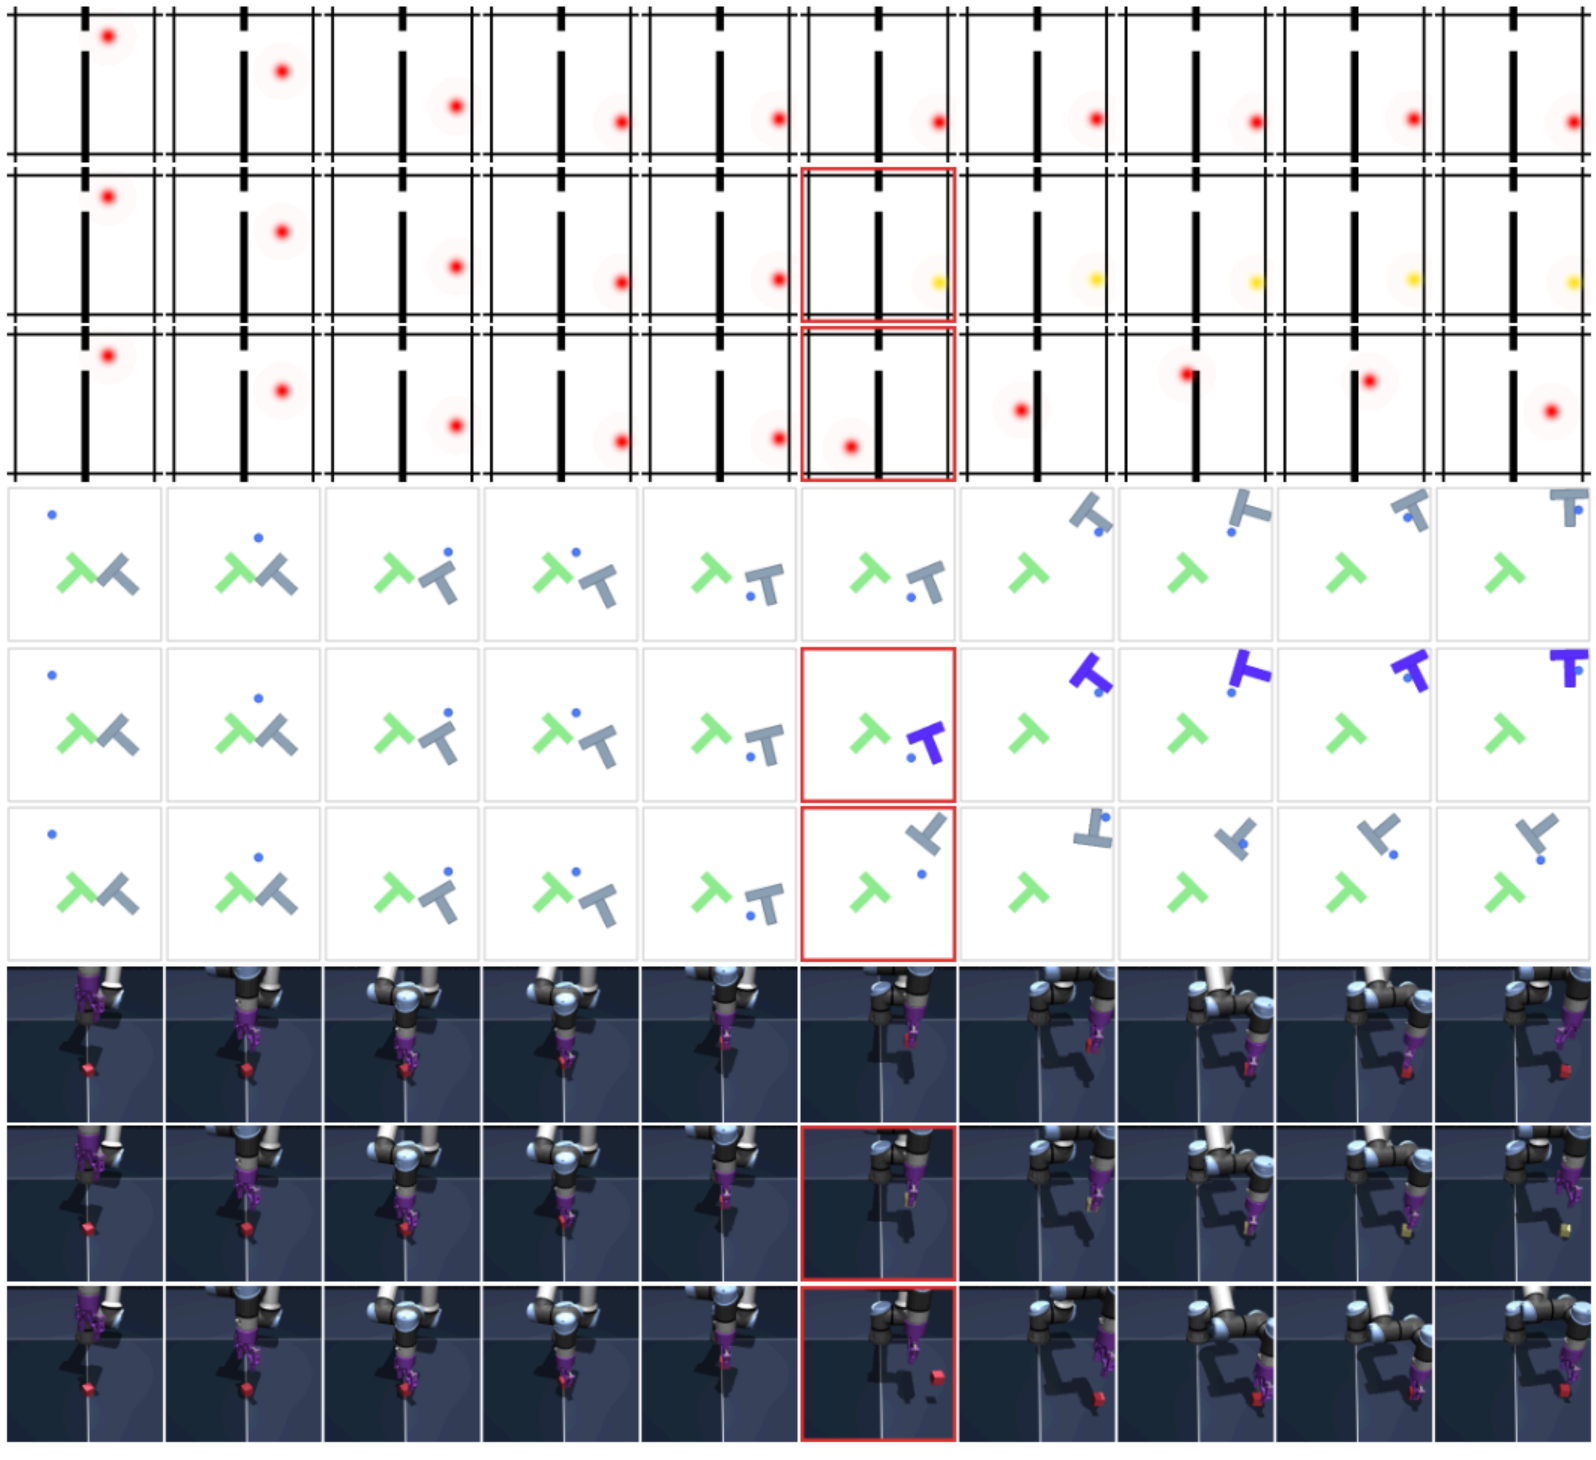

图 12：用于违反期望实验（第 5.2 节）的轨迹示例。对于每个环境，第一行对应于未受干扰的轨迹，第二行对应于发生视觉干扰的轨迹，第三行显示轨迹中系统状态在中途随机重置的轨迹。干扰发生的帧用红色突出显示。

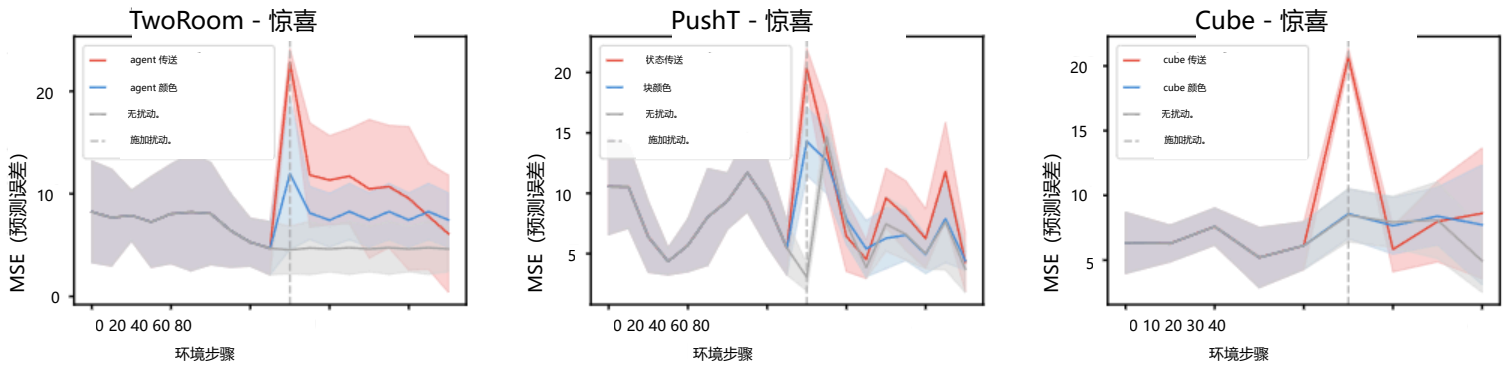

图 13：使用 PLDM 的期望违背评估。从左到右：TwoRoom，PushT，以及 OGBench-Cube。对于未扰动、视觉扰动和物理扰动的轨迹，其惊喜度随时间变化的情况被绘制出来。在 TwoRoom 和 PushT 中，模型对视觉和物理扰动都赋予了显著更高的惊喜度。在 OGBench-Cube 中，惊喜度的增加较弱，且并不始终显著。

表 4：OGBench-Cube 上的物理潜在探针结果。LeWM 在大多数属性上与 PLDM 相当或表现更优，并在位置量（如块位置和末端执行器位置）上取得了最佳结果。DINO-WM 在动态和旋转属性（关节速度、末端执行器偏航）上仍保持明显优势，这可能是由于这些量受益于在大规模预训练过程中学习到的更丰富的视觉先验。三种方法都难以恢复块方向（四元数和偏航），表明无论训练策略如何，细粒度的旋转信息在紧凑的潜在空间中仍然难以编码。

		线性		MLP	
属性	模型	MSE ↓	r ↑	MSE ↓	r ↑
联合位置	DINO-WM	0.960 ± 1.150	0.808	0.200 ± 0.967	0.870
	PLDM	0.372 ± 1.172	0.695	0.340 ± 1.164	0.728
	LeWM	0.352 ± 1.173	0.706	0.330 ± 1.157	0.742
关节速度	DINO-WM	0.792 ± 0.748	0.763	0.263 ± 0.683	0.852
	PLDM	1.016 ± 0.905	0.115	0.661 ± 0.830	0.536
	LeWM	1.021 ± 0.902	0.095	0.818 ± 0.899	0.386
末端执行器位置	DINO-WM	0.024 ± 0.010	0.996	0.004 ± 0.003	0.999
	PLDM	0.052 ± 0.073	0.974	0.013 ± 0.029	0.993
	LeWM	0.018 ± 0.025	0.991	0.003 ± 0.004	0.998
末端执行器偏航角	DINO-WM	3.317 ± 1.016	0.828	0.167 ± 0.168	0.917
	PLDM	0.996 ± 0.165	0.056	0.985 ± 0.207	0.117
	LeWM	0.980 ± 0.295	0.124	0.952 ± 0.369	0.213
夹爪	DINO-WM	0.114 ± 0.095	0.943	0.038 ± 0.060	0.982
	PLDM	0.234 ± 0.169	0.876	0.066 ± 0.111	0.967
	LeWM	0.121 ± 0.111	0.938	0.048 ± 0.079	0.976
块位置	DINO-WM	0.085 ± 0.029	0.991	0.007 ± 0.007	0.998
	PLDM	0.031 ± 0.023	0.985	0.003 ± 0.004	0.999
	LeWM	0.007 ± 0.010	0.997	0.002 ± 0.003	0.999
Block Quaternion	DINO-WM	1.596 ± 10.457	0.257	0.769 ± 8.046	0.411
	PLDM	1.021 ± 12.600	0.066	0.989 ± 12.140	0.218
	LeWM	1.019 ± 12.596	0.087	0.963 ± 11.450	0.224
Block Yaw	DINO-WM	4.223 ± 2.530	0.176	0.916 ± 0.278	0.304
	PLDM	0.996 ± 0.088	0.061	0.989 ± 0.140	0.106
	LeWM	0.996 ± 0.094	0.062	0.973 ± 0.199	0.164
总体	DINO-WM	1.162 ± 1.579	0.725	0.290 ± 1.202	0.799
	PLDM	0.611 ± 1.875	0.464	0.503 ± 1.809	0.600
	LeWM	0.592 ± 1.874	0.477	0.525 ± 1.714	0.584

G 消融实验。

训练方差。为了评估训练的稳定性，我们使用多个随机种子重新训练模型。如表 5 所示，运行结果表现出始终如一的高成功率与低方差，表明训练过程是稳定且可复现的。

嵌入维度。我们研究了嵌入维度对性能的影响。如图 15 所示，当嵌入维度低于某个阈值（约 184）时，性能会下降；而将维度增加到该值以上则会产生边际效益递减，导致性能饱和。

SIGReg 中的投影数量。我们研究了 SIGReg 中使用的投影数量对性能的影响。如图 15 所示，改变投影数量对下游控制任务的性能影响甚微。这表明该方法对这一超参数的敏感性较低。

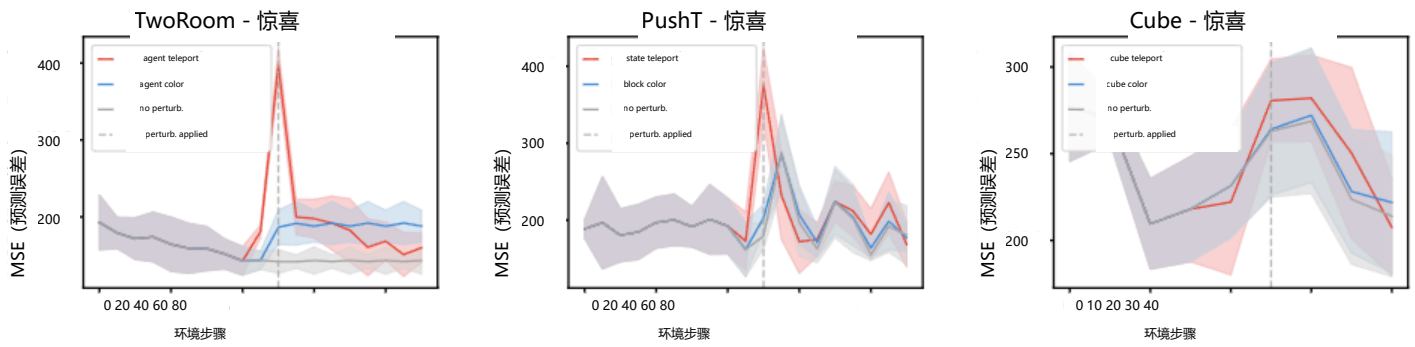

图 14：使用 DINO-WM 的期望违背评估。从左到右：TwoRoom, PushT 和 OGBench-Cube。对未扰动、视觉扰动和物理扰动的轨迹，其惊喜度随时间变化的情况进行了绘制。虽然模型在 TwoRoom 和 PushT 中检测到了两种扰动，但在 OGBench-Cube 中，无论哪种扰动，惊喜度都没有显著增加。

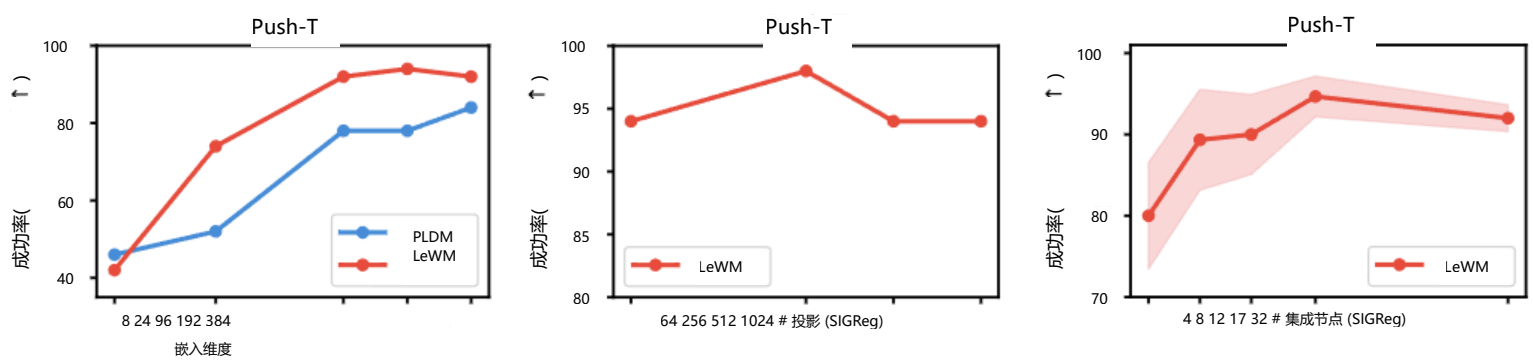

图 15：LeWM 中关键设计选择的消融研究。左：嵌入维度的效果；性能随着嵌入维度的增大而提高，但在某个阈值后迅速饱和。中：SIGReg 中使用的随机投影数量的效果；性能保持稳定，表明该参数不是关键因素。右：用于计算 SIGReg 损失的积分结点数量的效果；结果同样对该参数不敏感。

因此它不需要仔细调整。在实践中，这留下了λ作为唯一有效的超参数来优化。

SIGReg 正则化的权重。我们分析了 SIGReg 正则化权重λ的效果。如图 16 所示，该方法在广泛的λ值范围内都能实现高性能。特别是对于λ ∈ [0.01, 0.2]，成功率保持在 80%以上。这表明该方法对该参数的选择具有鲁棒性。此外，由于λ是唯一有效的超参数，它可以被高效地调整，例如通过简单的二分搜索。

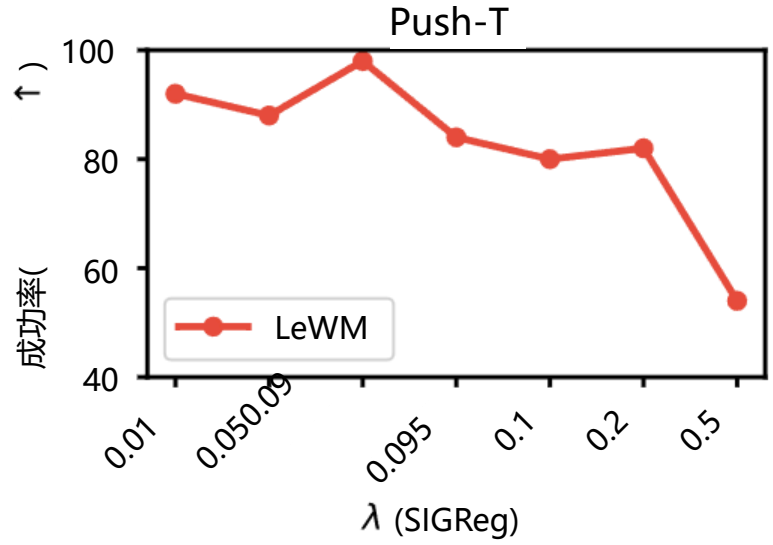

图 16：SIGReg 正则化权重λ对 Push-T 规划性能的影响。成功率在较宽的范围内（λ ∈ [0.01, 0.2]）始终保持在 80%以上，在λ = 0.09 附近达到峰值。只有在λ = 0.5 时性能急剧下降，此时正则化项主导预测损失并阻碍动态建模。由于λ是 LeWM 唯一的有效超参数，SIGReg 损失系数可通过简单的二分搜索轻松调整。

表 5：训练方差。我们报告了在 Push-T 上对 50 条轨迹进行评估的三个训练种子的平均成功率及其对应方差。目标配置可在 25 步内到达，我们允许 50 步的规划预算。PLDM 的方差高于 DINO-WM 和 LeWM。

模型	Push-T (SR ↑)
DINO-WM	92.0 ± 1.63
PLDM	78.0 ± 5.0
LeWM (我们)	96.0 ± 2.83

表 6：在 Push-T 环境中预测器大小对规划性能的影响。我们报告了成功率 (SR)。ViT-S 预测器实现了最佳性能。

预测器大小	Push-T (SR ↑)
tiny	80.67 ± 6.54
small	96.0 ± 2.83
base	86.7 ± 3.06

预测器大小。我们分析了预测器大小对性能的影响。如表 6 所示，使用 ViT-S 预测器获得最佳结果。将预测器减小为 ViT-T 模型会导致性能下降，而将大小增加到 ViT-B 并不会带来额外收益，反而略微降低了性能。这表明 ViT-S 在模型容量和优化稳定性之间为这项任务提供了最佳权衡。

解码器。我们研究了在训练过程中添加重建损失的影响。如表 7 所示，加入解码器和重建目标并没有提高下游控制性能。事实上，与未使用解码器训练的模型相比，性能略有下降。这表明 JEPA 训练目标已经捕获了规划所需的信息，而重建损失可能会促使模型编码与控制无关的额外视觉细节。

架构。我们通过用 ResNet-18 主干网络替换 ViT 编码器来研究编码器架构对 LeWM 性能的影响。如表 8 所示，LeWM 在两种架构下均实现了具有竞争力的性能，表明它在训练过程中使用的视觉编码器选择上具有无关性，尽管 ViT 仍保持微弱优势。

预测器 Dropout。我们分析了在训练过程中对预测器应用 dropout 的影响。如表 9 所示，引入少量 dropout 显著提升了下游控制性能。特别是 dropout 率为 0.1 时达到了最高成功率，而较低和较高的值均导致性能下降。这表明适度的 dropout 有助于正则化预测器并提高泛化能力，而过多的 dropout 会降低学习动态的质量。

H 时间潜在路径直线化。

时间直线化假设由 Hénaff 等人[42]提出，该假设认为我们将复杂的时序动态表示为在表示中平滑、近似直线的轨迹。

表 7：训练过程中添加重建损失的效果。我们在 Push-T 规划任务上报告了成功率（SR）。未训练解码器损失的模型实现了更高的性能。

	Push-T (SR ↑)
LeWM w/o decoder loss	96.0 ± 2.83
LeWM with decoder loss	86.0 ± 7.54

表 8：编码器架构效果。我们在 Push-T 规划任务上报告了成功率（SR）。LeWM 在编码器架构上实现了具有竞争力的性能，ViT 略有优势。

	Push-T (SR ↑)		
LeWM ViT	96.0 ± 2.83	LeWM ResNet-18	94.0 ± 3.27

表 9：训练过程中预测器 dropout 对 Push-T 规划性能的影响。我们报告了成功率（SR）。少量的 dropout（p = 0.1）产生了最佳结果。

p	Push-T (SR ↑)
0.0	78 ± 6.54
0.1	96.0 ± 2.83
0.2	85.33 ± 5.74
0.5	66.67 ± 4.11

空间。这一原理此后被应用于神经科学之外：Internò等人[54]利用从 DINOv2 特征中测量的时间直线性来区分 AI 生成的视频和真实视频，证明这一几何特性携带着关于底层动力学的有意义信号，Wang 等人[55]也表明它对规划有益。

在 PushT 训练期间，出于好奇，我们记录了 LeWM 的潜在轨迹的时间直线性。给定一个潜在嵌入序列 z∈ R，我们将时间速度向量定义为 v= z− z。路径直化度量定义为连续速度之间的平均成对余弦相似度：

$$S = \frac{1}{B(T-2)} \sum_{i=1}^{B} \sum_{t=1}^{T-2} \frac{\langle v, v \rangle}{\|v\| \, \|v\|}. \tag{9}$$

Sstraight 接近 1 的值表明连续速度几乎共线，这意味着潜在轨迹接近直线。有趣的是，我们发现时间直线化在训练过程中自然出现，没有任何明确鼓励它的训练项（图 17）。

我们假设这是因为 SIGReg 在每个时间步独立应用，但未在时间维度上应用，导致时间结构不受约束。这使得编码器趋于一种时间崩溃的形式，其中连续的嵌入沿着越来越线性的路径演化。这种隐式偏差并非有害，反而似乎有利于下游性能，如图 6 所示。值得注意的是，尽管 LeWM 没有显式正则化器鼓励这种时间直线性，但它比 PLDM 实现了更高的时间直线性，而 PLDM 则对连续潜在状态应用正则化器，直接促进时间平滑性。

I 训练曲线

我们可视化了几条训练曲线，比较 LeWM（图 18）和 PLDM（图 19）的优化动态。与 PLDM（其目标包含多个正则化项）不同，LeWM 除了预测损失外只使用一个正则化项，这使得训练动态更容易解释和分析。

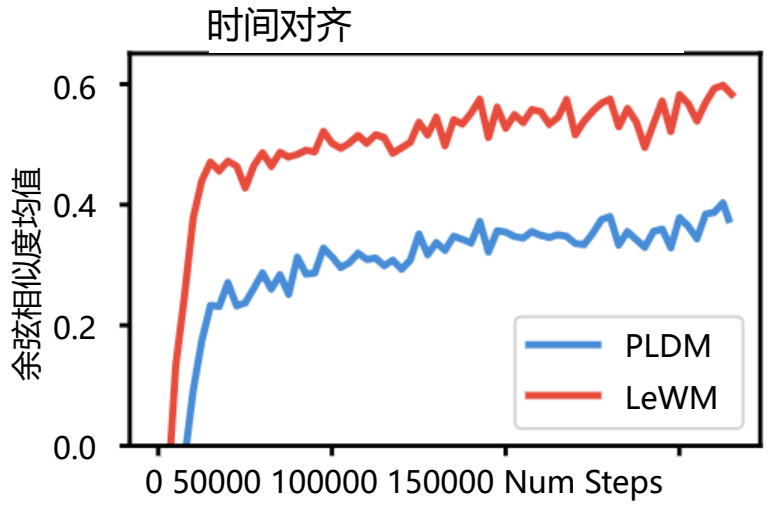

图 17：时间潜在对齐在 Push-T 上的表现。连续潜在速度向量之间的余弦相似度均值（公式 9）在训练过程中的变化。更高的值表示更直线的潜在轨迹。PLDM 通过专门的时序平滑损失（L）明确鼓励时序规律性，而 LeWM 在没有时序正则化项的情况下，通过纯粹的自发现象实现了显著更直线的潜在路径。

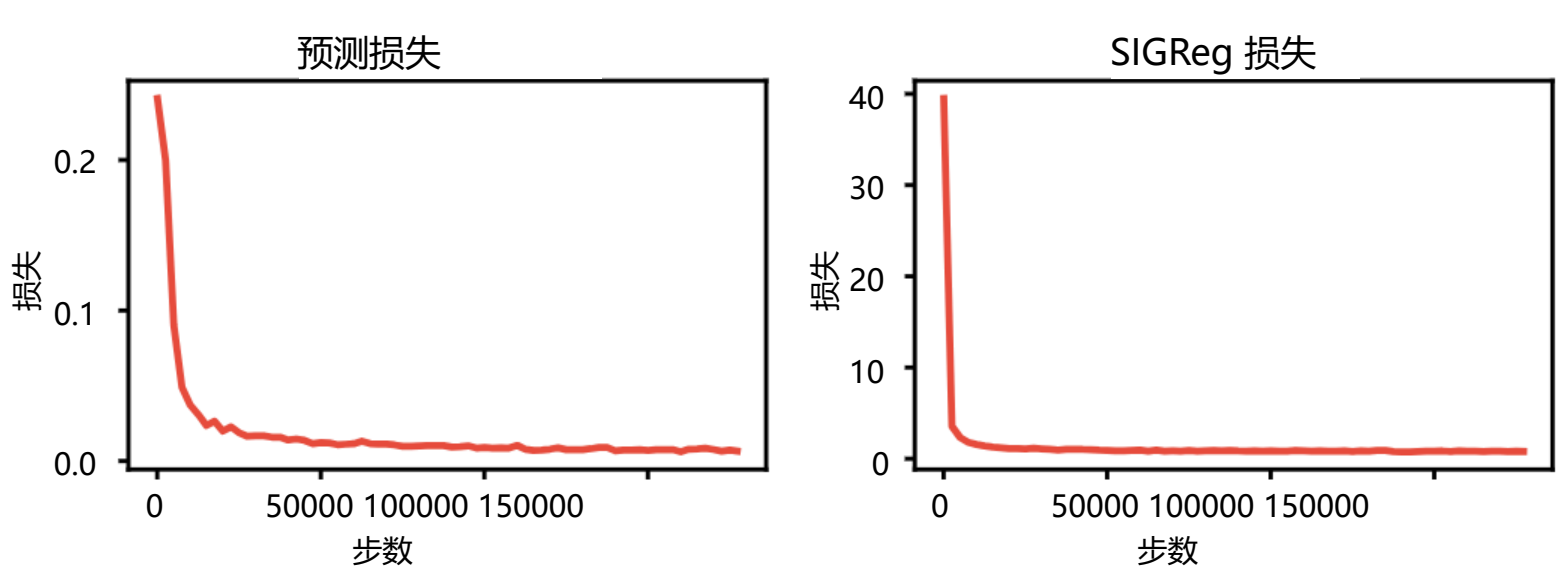

图 18：LeWM 的 Push-T 训练曲线

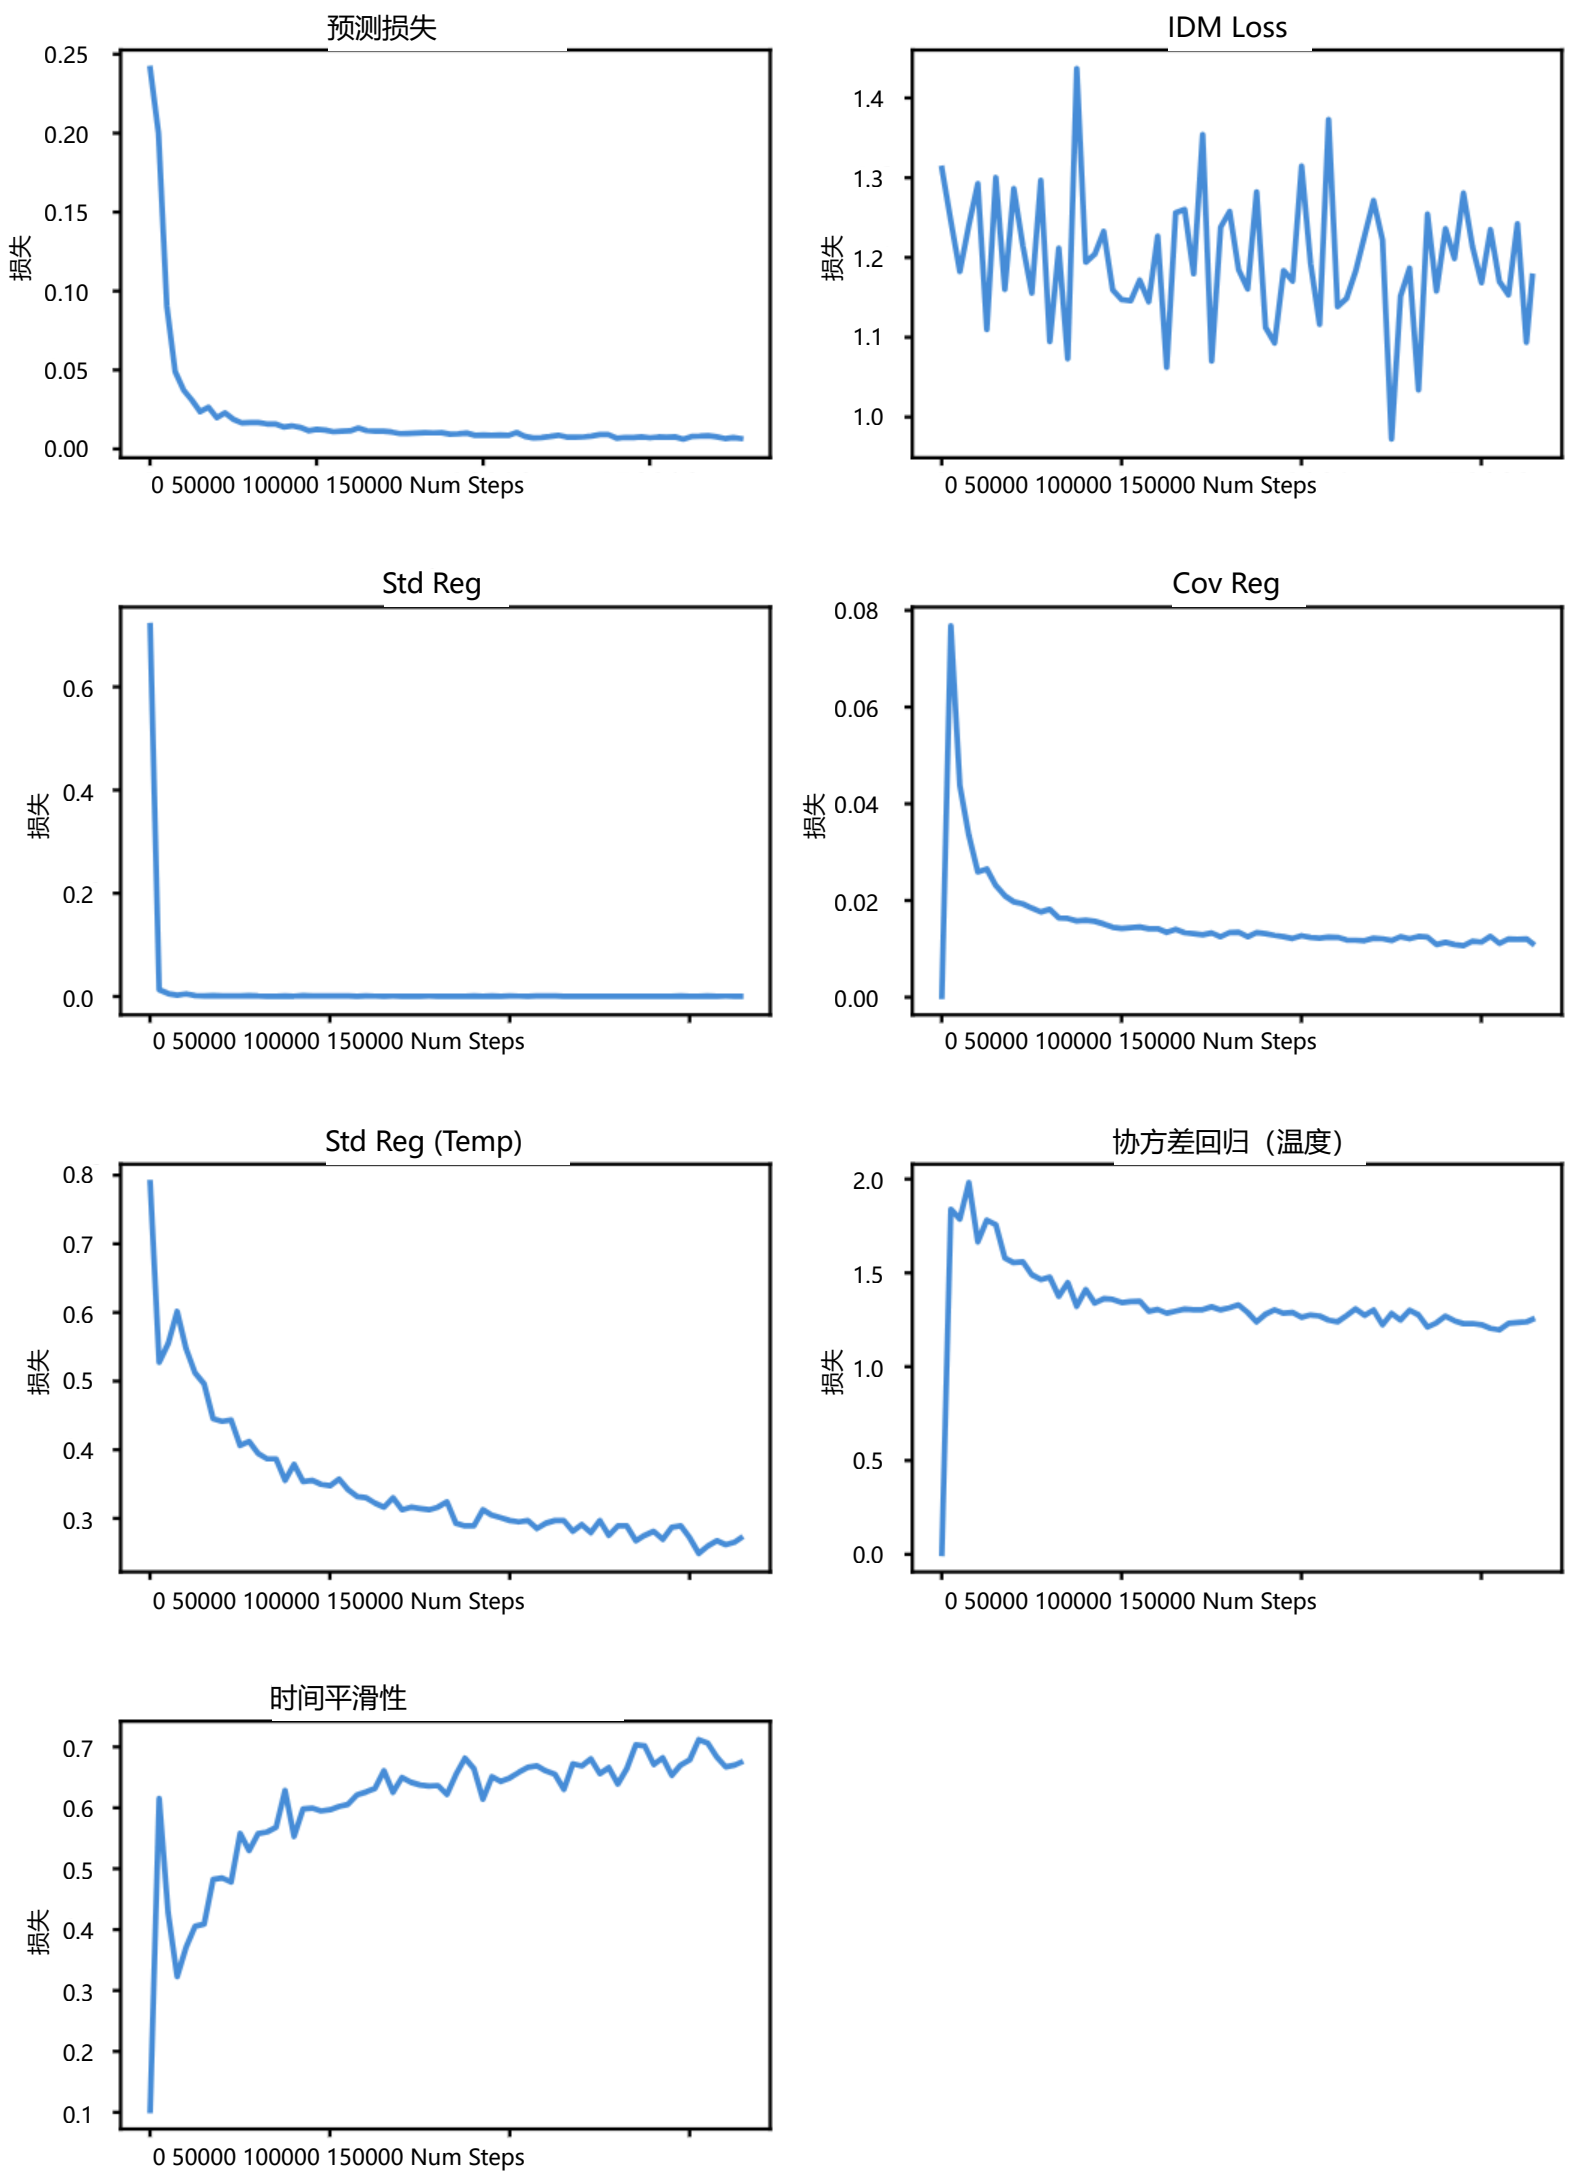

图 19：PLDM 的 Push-T 训练曲线