本文档由 funstory.ai 的开源 PDF 翻译库自动翻译生成，并非官方翻译。我们正在积极的建设当中，欢迎 star 和关注。

arXiv:2003.08934v2 [cs.CV] 3 Aug 2020

NeRF：将场景表示为神经辐射场以实现视图合成

Ben Mildenhall[1⋆] Pratul P. Srinivasan[1⋆] Matthew Tancik[1⋆]
Jonathan T. Barron[2] Ravi Ramamoorthi[3] Ren Ng[1]

[1]加州大学伯克利分校 [2]谷歌研究 [3]加州大学圣地亚哥分校

摘要。 我们提出了一种方法，通过优化底层连续体积场景函数，利用稀疏的输入视图合成复杂场景的新颖视图，并取得了最先进的结果。我们的算法使用全连接（非卷积）深度网络表示场景，其输入是一个单一的连续五维坐标（空间位置(x, y, z)和观察方向(θ, ϕ)），其输出是该空间位置的体积密度和视点相关发射辐射。我们通过沿着相机光线查询五维坐标来合成视图，并使用经典的体积渲染技术将输出颜色和密度投影到图像中。由于体积渲染是自然可微分的，优化我们表示所需的唯一输入是一组具有已知相机姿态的图像。我们描述了如何有效地优化神经辐射场，以渲染具有复杂几何形状和外观场景的照片级真实感新颖视图，并展示了优于现有神经渲染和视图合成工作的结果。视图合成结果最好以视频形式查看，因此我们敦促读者观看我们的补充视频以获得令人信服的比较。

关键词： 场景表示、视图合成、基于图像的渲染、体积渲染、3D深度学习

1 引言

在本工作中，我们通过直接优化连续5D场景表示的参数来解决这个问题，以最小化渲染一组捕获图像时的误差，从而以新的方式处理视图合成问题。

我们将静态场景表示为一个连续的五维函数，该函数在每个空间点（x, y, z）处输出每个方向（θ, ϕ）发出的辐射度，并在每个点处提供一个密度，该密度类似于微分不透明度，控制通过该点的射线累积的辐射度（x, y, z）。我们的方法通过从单个五维坐标（x, y, z, θ, ϕ）回归到单个体积密度和依赖于视角的RGB颜色来优化一个深度全连接神经网络（通常称为多层感知机或MLP），以表示该函数。为了渲染这个神经辐射场 (NeRF)

⋆ 作者对这项工作贡献相同。

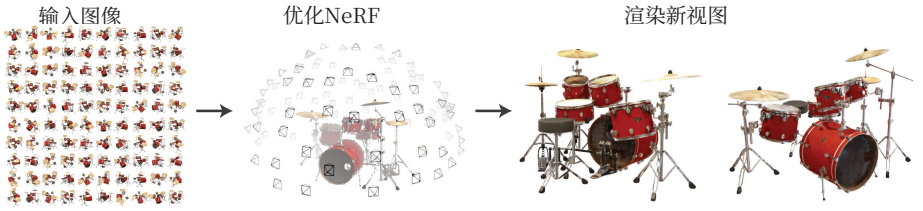


图1：我们提出了一种方法，该方法从一组输入图像中优化场景的连续5D神经辐射场表示（任何连续位置的体积密度和视点相关颜色）。我们使用体积渲染技术沿射线累积该场景表示的样本，以从任何视点渲染场景。在这里，我们可视化了围绕半球随机捕获的合成<样式 id='1'>鼓</样式>场景的100组输入视图，并展示了从我们优化的NeRF表示中渲染的两个新视图。

从特定视点来看，我们：1）通过场景中的相机光线生成一个采样集的3D点，2）使用这些点和它们对应的2D观察方向作为神经网络的输入，以产生一组颜色和密度的输出，3）使用经典的体积渲染技术将这些颜色和密度累积成一个2D图像。由于这个过程是可微分的，我们可以使用梯度下降来通过最小化每个观测图像与从我们的表示中渲染的对应视点之间的误差来优化该模型。通过多个视图最小化此误差，可以鼓励网络为包含真实场景内容的区域分配高体积密度和准确的颜色，从而预测场景的连贯模型。图2可视化了整个流程。

我们发现，对复杂场景的神经辐射场表示进行优化的基本实现无法收敛到足够高分辨率的表示，并且在每个相机射线所需的样本数量上效率低下。我们通过使用位置编码转换输入5D坐标，使MLP能够表示更高频率的函数，并通过提出一种分层采样程序来减少为充分采样该高频场景表示所需的查询数量来解决这些问题。

我们的方法继承了体积表示的优势：两者都能表示复杂的现实世界几何形状和外观，并且非常适合使用投影图像进行基于梯度的优化。关键在于，我们的方法克服了在以高分辨率建模复杂场景时对<样式 id='1'>离散化</样式>体素网格的过高的存储成本。总之，我们的技术贡献包括：— 一种将具有复杂几何形状和材料的连续场景表示为5D神经辐射场的方法，该方法是作为基本多层感知机网络参数化的。— 一种基于经典体积渲染技术的可微分渲染过程，我们使用它从标准RGB图像中优化这些表示。这包括一种分层采样策略，用于将多层感知机的能力分配到具有可见场景内容的空间。

— 一种位置编码，用于将每个输入的五维坐标映射到更高维度的空间，这使我们能够成功优化神经辐射场，以表示高频场景内容。

我们证明了我们的神经辐射场方法在定性和定量上均优于最先进的视图合成方法，包括将神经3D表示拟合到场景中的工作，以及训练深度卷积神经网络以预测采样体积表示的工作。据我们所知，本文提出了第一个能够从自然环境中捕获的RGB图像中渲染真实物体和场景的高分辨率照片级新视图的连续神经场景表示。

2 相关工作

计算机视觉中一个有前景的近期方向是在MLP的权重中编码物体和场景，该MLP直接将3D空间位置映射到形状的隐式表示，例如该位置处的符号距离 [6]。然而，迄今为止，这些方法尚无法以与使用三角形网格或体素网格等离散表示来表示场景的技术相同的保真度来重现具有复杂几何形状的真实场景。在本节中，我们回顾了这两条工作线，并将它们与我们的方法进行了对比，该方法增强了神经场景表示的能力，以生成用于渲染复杂真实场景的最先进结果。

一种使用多层感知机将低维坐标映射到颜色空间的类似方法也被用于表示其他图形函数，例如纹理材料 [44], 和间接照明值 [12,31,36,37],。

神经***3D***形状表示近期研究调查了通过优化将连续3D形状表示为水平集的深度网络，这些网络将 xyz 坐标映射到符号距离函数 [15,32] 或占用场 [11,27]。然而，这些模型受限于对真实3D几何形状的访问需求，通常从ShapeNet [3]等合成3D形状数据集获取。后续研究通过制定可微分的渲染函数放宽了这一对真实3D形状的要求，允许仅使用2D图像优化神经隐式形状表示。Niemeyer 等人 [29] 将表面表示为3D占用场，并使用数值方法为每条射线找到表面交点，然后通过隐式微分计算精确导数。每条射线交点位置被作为输入提供给一个神经3D纹理场，该场预测该点的漫反射颜色。Sitzmann 等人 [42] 使用一种不太直接的神经3D表示方法，该方法在每个连续3D坐标处简单地输出一个特征向量和RGB颜色，并提出了一种由循环神经网络组成的可微分渲染函数，该网络沿每条射线行进以确定表面位置。

尽管这些技术理论上可以表示复杂且高分辨率的几何形状，但迄今为止它们仅限于几何复杂度低的简单形状，导致渲染结果过度平滑。我们证明了一种替代策略：通过优化网络来编码5D辐射场（3D体积，具有2D视点相关的外观），这种策略可以表示更高分辨率的几何形状和外观，从而渲染复杂场景的照片级真实感新视角。

使用 2D 视角相关的外观) 可以表示更高分辨率的几何形状和外观，以渲染照片级真实感的复杂场景的新颖视角。

视图合成与基于图像的渲染给定密集的视图采样，通过简单的光场采样插值技术即可重建照片级真实感的全新视图 [21,5,7]。对于采用稀疏视图采样的全新视图合成，计算机视觉与图形学领域通过从观测图像中预测传统几何形状和外观表示，取得了显著进展。一类流行的技术使用基于网格的场景表示，这些表示可以是漫反射 [48] 或视点相关的 [2,8,49] 外观。可微分光栅化器 [4,10,23,25] 或路径追踪器 [22,30] 可以直接通过梯度下降优化网格表示，以重现一组输入图像。然而，基于图像重投影的基于梯度的网格优化通常很困难，可能是因为局部最小值或损失景观的病态性。此外，该策略需要在优化 [22],之前提供一个具有固定拓扑结构的模板网格作为初始化，这对于无约束的真实世界场景通常是不存在的。

另一类方法使用体积表示来处理从一组输入RGB图像生成高质量照片级真实感视图合成的任务。体积方法能够逼真地表示复杂形状和材料，适合基于梯度的优化，并且与基于网格的方法相比，产生的视觉干扰伪影较少。早期的体积方法使用观测图像直接为体素网格着色 [19,40,45]。最近，一些方法 [9,13,17,28,33,43,46,52] 使用包含多个场景的大数据集来训练深度网络，该网络可以从一组输入图像预测采样体积表示，然后在测试时使用alpha合成 [34]或沿射线学习的合成来渲染新视图。其他工作优化了卷积网络（CNNs）和每个特定场景的采样体素网格的组合，以便CNN可以补偿低分辨率体素网格 [41] 的离散化伪影，或允许预测的体素网格根据输入时间或动画控制 [24]变化。虽然这些体积技术在新视图合成方面取得了令人印象深刻的结果，但由于其离散采样导致时间和空间复杂度差，它们扩展到更高分辨率图像的能力从根本上受到限制——渲染更高分辨率的图像需要更精细的3D空间采样。我们通过在深度全连接神经网络的参数中编码一个<样式 id='6'>连续</样式>体积来绕过这个问题，这不仅比先前的体积方法产生显著更高质量的渲染效果，而且只需要这些<样式 id='8'> 采样 </ 样式 > 体积表示的一小部分存储成本。

3 神经辐射场场景表示

我们将连续场景表示为一个5D向量值函数，其输入是一个3D位置 $\mathbf{x} = (x, y, z)$ 和2D观察方向 (θ, ϕ)，其输出是一个发射颜色 $\mathbf{c} = (r, g, b)$ 和体积密度 σ。在实践中，我们表示

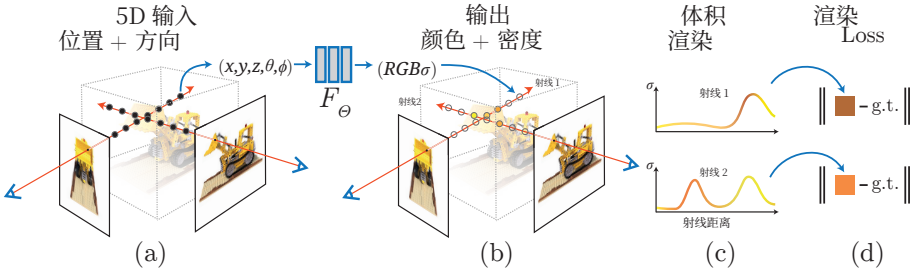


图2：我们神经辐射场场景表示和可微渲染过程的概述。我们通过沿相机光线（a）采样五维坐标（位置和观察方向），将那些位置输入到多层感知机中以产生颜色和体积密度（b），并使用体积渲染技术将这些值合成为图像（c）。此渲染函数是可微分的，因此我们可以通过最小化合成图像与真实观测图像之间的残差来优化场景表示（d）。

方向作为三维笛卡尔单位向量 $\mathbf{d}$。我们使用 MLP 网络 F_Θ 来近似这个连续的五维场景表示：$(\mathbf{x},\mathbf{d}) \rightarrow (\mathbf{c}\ \sigma)$，并优化其权重 Θ，以将每个输入的五维坐标映射到其对应的体积密度和方向发射颜色。

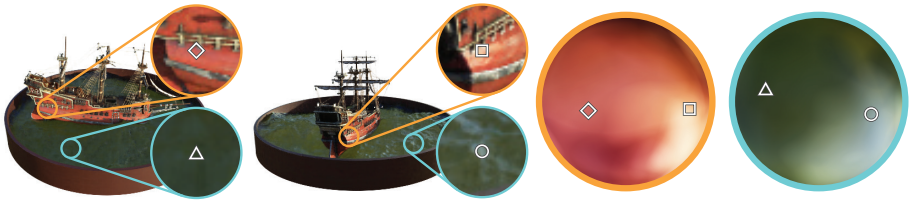
我们通过将网络限制为仅将体积密度 σ 预测为位置 $\mathbf{x}$ 的函数，同时允许将 RGB 颜色 $\mathbf{c}$ 预测为位置和观察方向的函数，来鼓励表示的多视图一致性。为此，多层感知机 F_Θ 首先使用 ReLU 激活和每层 256 个通道的 8 个全连接层处理输入三维坐标 $\mathbf{x}$，然后输出 σ 和一个 256 维的特征向量。此特征向量然后与相机光线的观察方向连接，并传递到一个额外的全连接层（使用 ReLU 激活和 128 个通道），该层输出与视图相关的 RGB 颜色。

参见图3，了解我们的方法如何使用输入观察方向来表示非朗伯效应。如图4所示，一个未经视图依赖训练的模型（仅将<样式 id='1'>x</样式>作为输入）难以表示高光。

4 基于辐射场的体渲染

我们的5D神经辐射场将场景表示为空间中任意点的体积密度和方向发射辐射。我们使用经典体积渲染原理 [16]渲染穿过场景的任何射线的颜色。体积密度 $\sigma(\mathbf{x})$可以解释为射线在位置$\mathbf{x}$处的无穷小粒子终止的微分概率。相机射线$\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ 的预期颜色$C(\mathbf{r})$（t）$= \mathbf{o} + t\mathbf{d}$ 具有近端和远端界限 t_n 和 t_f，为：

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(\mathbf{r}(t))\mathbf{c}(\mathbf{r}(t),\mathbf{d})dt\,,\ \text{where}\ T(t) = \exp\left(-\int_{t_n}^{t}\sigma(\mathbf{r}(s))ds\right). \quad (1)$$



(a) 视图1 (b) 视图2 (c) 辐射分布

图3：视点相关发射辐射的可视化。我们的神经辐射场表示将RGB颜色作为空间位置$\mathbf{x}$ 和观察方向 $\mathbf{d}$的5D函数输出。在这里，我们可视化了神经表示中两个空间位置的两个示例方向颜色分布，该神经表示对应于船场景。在(a)和(b)中，我们展示了从两个不同相机位置看到的两个固定3D点的外观：一个在船的侧面（橙色插入）和一个在水面上（蓝色插入）。我们的方法预测了这两个3D点的变化镜面外观，并在(c)中展示了这种行为如何在整个观察方向半球上连续扩展。

函数 $T(t)$表示从t_n 到$i_。$ $e_。$的射线上的累积透射率，即射线在未击中任何其他粒子的情况下从 t_n 到 t 旅行的概率。从我们的连续神经辐射场渲染视图需要估计通过所需虚拟相机的每个像素的相机射线所经过的积分 C（$\mathbf{r}$）。

我们使用数值积分来估计这个连续积分。确定性积分通常用于渲染离散体素网格，会有效地限制我们表示的分辨率，因为多层感知机仅在固定的离散位置进行查询。相反，我们使用分层采样方法，其中我们将 $[t_n, t_f]$ 分为 N 个均匀间隔的桶，然后从每个桶内均匀随机抽取一个样本：

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N}(t_f - t_n),\ t_n + \frac{i}{N}(t_f - t_n)\right]. \tag{2}$$

尽管我们使用离散样本来估计积分，分层采样使我们能够表示连续的场景，因为它导致多层感知机在优化过程中在连续位置上进行评估。我们使用这些样本根据体积渲染综述中Max [26]讨论的求积规则来估计 $C(\mathbf{r})$：

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^{N} T_i(1 - \exp(-\sigma_i\delta_i))\mathbf{c}_i\,,\ \text{where } T_i = \exp\left(-\sum_{j=1}^{i-1}\sigma_j\delta_j\right), \tag{3}$$

$\delta_i = t_{i+1} - t_i$ 表示相邻样本之间的距离。这个用于从($_i\mathbf{c}\,\sigma_i$)值集合中计算 $C(\mathbf{r})$的函数ˆ是显然可微分的，并简化为传统的alpha混合，其中alpha值为 $\alpha_i = 1 - \exp(-\sigma_i\delta_i)$。

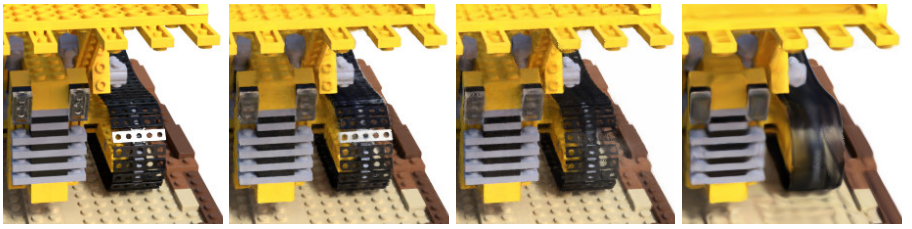


图4：这里我们展示了我们的完整模型如何从表示视图相关的发射辐射以及将输入坐标通过高频位置编码中受益。移除视图依赖会阻止模型重现推土机履带上的镜面反射。移除位置编码会大幅降低模型表示高频几何形状和纹理的能力，导致外观过度平滑。

5 优化神经辐射场

在上一节中，我们描述了将场景建模为神经辐射场并从该表示中渲染新视图所必需的核心组件。然而，我们观察到这些组件不足以实现最先进的质量，如第6.4节所示。我们引入两项改进以支持表示高分辨率复杂场景。第一个是输入坐标的位置编码，它协助多层感知机表示高频函数；第二个是分层采样程序，它允许我们高效地对这个高频表示进行采样。

5.1 位置编码

尽管神经网络是通用函数逼近器 [14]，我们发现让网络 F_Θ 直接对 $xyz\theta\phi$ 输入坐标进行操作会导致渲染效果在表示颜色和几何形状的高频变化时表现不佳。这与 Rahaman等 [35], 的近期工作一致，他们表明深度网络倾向于学习低频函数。他们还表明，在将输入传递给网络之前，使用高频函数将输入映射到更高维的空间，能够更好地拟合包含高频变化的数据。

我们利用这些发现于神经场景表示的背景下，并表明将 F_Θ 重新表述为两个函数 $F_\Theta = F'_\Theta \circ \gamma$ 的组合，一个被学习，一个没有被学习，显著提高了性能（参见图 4 和表 2）。这里 γ 是一个从 $\mathbb{R}$ 映射到更高维空间 $\mathbb{R}^{2L}$ 的映射，而 F'_Θ 仍然只是一个常规的多层感知机。形式上，我们使用的编码函数是：

$$\gamma(p) = \left(\sin\left(2^0\pi p\right), \cos\left(2^0\pi p\right), \cdots, \sin\left(2^{L-1}\pi p\right), \cos\left(2^{L-1}\pi p\right)\right). \quad (4)$$

该函数 $\gamma(\cdot)$ 会分别应用于 $\mathbf{x}$ （其值被归一化到 $[-1,1]$ 范围内）中的每个坐标值以及向量的三个分量

笛卡尔观察方向单位向量 $\mathbf{d}$（其构造上位于 $[-1,1]$ 范围内）。在我们的实验中，我们为 $\gamma(\mathbf{x})$ 设置 $L=10$，为 $\gamma(\mathbf{d})$ 设置 $L=4$。

在流行的 Transformer 架构中 [47]，也使用了类似的映射，那里将其称为位置编码。然而，Transformer 使用它的目的是为了将序列中标记的离散位置作为输入提供给不包含任何顺序概念的架构。相比之下，我们使用这些函数将连续的输入坐标映射到更高维的空间，以使我们的多层感知机能够更容易地近似更高频率的函数。一项关于建模 3D 蛋白质结构（从投影中）的相关工作 [51] 也利用了类似的输入坐标映射。

5.2 分层体积采样

我们的渲染策略在沿着每个相机射线的查询点密集评估神经辐射场网络效率低下：自由空间和遮挡区域（这些区域不会对渲染图像做出贡献）仍然被重复采样。我们从早期的体积渲染工作 [20] 中汲取灵感，并提出了一种分层表示方法，通过按样本对最终渲染的预期效果进行比例分配来提高渲染效率。

与其仅使用单个网络来表示场景，我们同时优化两个网络：一个“粗略”的和一个“精细”的。我们首先使用分层采样来采样一组 N_c 位置，并在这些位置上评估“粗略”网络，如公式 2 和 3 所述。基于此“粗略”网络的输出，我们沿每条射线生成更明智的点采样，其中采样倾向于体积的相关部分。为此，$\hat{}$ 我们首先将公式 3 中的粗略网络 $C_c(\mathbf{r})$ 的 alpha 混合颜色重写为沿射线所有采样颜色 c_i 的加权求和：

$$\hat{C}_c(\mathbf{r})=\sum_{i=1}^{N_c} w_i c_i\,, \qquad w_i = T_i(1-\exp(-\sigma_i\delta_i))\,. \tag{5}$$

将这些权重标准化为 $\hat{}w_i = {}^{w_i}/_{\sum_{j=1}^{N_c} w_j}$ 会在沿射线上产生一个分段常数的 PDF。我们从该分布中采样第二组 N_f 位置，在第一组和第二组样本的并集中评估我们的“精细”网络，并使用公式 3 但使用所有 N_c+N_f 采样来计算射线 $\hat{}C_f(\mathbf{r})$ 的最终渲染颜色。此过程将更多采样分配给我们预期包含可见内容的区域。这解决了与重要性采样类似的目标，但我们使用采样值作为整个积分域的非均匀离散化，而不是将每个样本视为对整个积分的独立概率估计。

5.3 实现细节

我们为每个场景优化一个独立的神经连续体积表示网络。这只需要场景捕获的 RGB图像数据集。

我们为每个场景优化一个独立的神经连续体积表示网络。这只需要场景捕获的RGB图像数据集、相应的相机姿态和内参，以及场景边界（对于合成数据，我们使用真实的相机姿态、内参和边界，而对于真实数据，我们使用COLMAP结构从运动包 [39]来估计这些参数）。在每次优化迭代中，我们从数据集中所有像素的集合中随机采样一批相机射线，然后按照第5.2节中描述的分层采样方法，从粗网络查询 N_c 个样本，从细网络查询 $N_c + N_f$ 个样本。然后，我们使用第4节中描述的体积渲染过程，从这两个样本集渲染每条射线的颜色。我们的损失仅仅是粗渲染和细渲染中渲染颜色与真实像素颜色之间的总平方误差：

$$\mathcal{L} = \sum_{\mathbf{r}\in\mathcal{R}} \left[\left\| \hat{C}_c(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 + \left\| \hat{C}_f(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 \right] \tag{6}$$

其中 $\mathcal{R}$ 是每个批次中的射线集合，而 $C(\mathbf{r})$、$\hat{C}_c(\mathbf{r})$ 和 $\hat{C}_f(\mathbf{r})$ 分别是射线 $\mathbf{r}$ 的真实值、粗体积预测和细体积预测的RGB颜色。请注意，尽管最终渲染来自 $\hat{\hat{C}}_f(\mathbf{r})$，但我们仍然最小化 $C_c(\mathbf{r})$ 的损失，以便粗网络中的权重分布可用于在细网络中分配样本。

在我们的实验中，我们使用4096条射线的批次大小，每个射线在粗体积中采样于 $N_c = 64$ 个坐标，并在细体积中采样于 $N_f = 128$ 个附加坐标。我们使用 Adam 优化器 [18]，其学习率从 5×10^{-4} 开始，并在优化过程中呈指数衰减至 5×10^{-5}（其他 Adam 超参数保持为 $\beta_1 = 0.9$、$\beta_2 = 0.999$ 和 $\epsilon = 10^{-7}$ 的默认值）。在单个 NVIDIA V100 GPU 上，单个场景的优化通常需要约 100–300k 次迭代才能收敛（大约需要 1–2 天）。

6 结果

我们定量（表1）和定性（图8和图6）地展示了我们的方法优于先前工作，并提供了广泛的消融研究来验证我们的设计选择（表2）。我们敦促读者观看我们的补充视频，以更好地欣赏我们的方法在渲染新视图的平滑路径时相对于基线方法的显著改进。

6.1 数据集

物体的合成渲染我们首先展示在两个物体合成渲染数据集（表1，“Diffuse Synthetic 360°”和“Realistic Synthetic 360°”）上的实验结果。DeepVoxels [41] 数据集包含四个具有简单几何形状的朗伯物体。每个物体从上半球（输入为479个视点，测试为1000个视点）上采样的视点渲染，分辨率为 512×512 像素。我们额外生成了自己的数据集，包含八个具有复杂几何形状和真实非朗伯材料特性的路径追踪图像。其中六个从上半球采样的视点渲染，两个从完整球面采样的视点渲染。我们对每个场景渲染100个输入视图和200个测试视图，所有视图均分辨率为 800×800 像素。

方法	漫射合成 360° [41]			逼真合成 360°			真实正向 [28]		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
SRN [42]	33.20	0.963	0.073	22.26	0.846	0.170	22.84	0.668	0.378
NV [24]	29.62	0.929	0.099	26.05	0.893	0.160	-	-	-
LLFF [28]	34.38	0.985	0.048	24.88	0.911	0.114	24.13	0.798	**0.212**
Ours	**40.15**	**0.991**	**0.023**	**31.01**	**0.947**	**0.081**	**26.50**	**0.811**	0.250

表1：我们的方法在合成和真实图像数据集上定量优于现有工作。我们报告PSNR/SSIM（越高越好）和LPIPS [50]（越低越好）。DeepVoxels [41] 数据集包含4个具有简单几何形状的漫反射物体。我们的真实合成数据集包含8个具有复杂几何形状和复杂非朗伯材料的路径追踪渲染物体。真实数据集包含8个真实世界场景的前向手持捕捉（NV无法评估此数据，因为它仅重建有界体积内的物体）。尽管LLFF在LPIPS上略好，但我们建议读者查看我们的补充视频，其中我们的方法实现了更好的多视图一致性，并比所有基线产生更少的伪影。

复杂场景的真实图像我们在复杂真实世界场景上展示了结果（表1，“真实正向”）。该数据集包含8个场景，使用手持手机拍摄（其中5个来自LLFF论文，3个是我们拍摄的），拍摄了20到62张图像，并保留其中的 $1/8$ 用于测试集。所有图像都是 1008×756 像素。

6.2 对比

为了评估我们的模型，我们将其与当前用于视图合成的顶尖技术进行比较，具体如下。所有方法都使用相同的一组输入视图来为每个场景训练一个单独的网络，局部光场融合 [28],除外，它在一个大型数据集上训练单个3D卷积网络，然后在测试时使用相同的训练网络来处理新场景的输入图像。

神经体积***(NV)*** *[24]* 合成位于特定前景区域内（该前景区域必须单独捕获，且不包含目标物体）的物体的新视角。它优化了一个深度3D卷积网络，以预测一个离散化的RGBα 体素网格以及一个具有 128^3 样本的3D变换网格。该算法通过沿相机光线穿过变换后的体素网格来渲染新视角。

场景表示网络***(SRN)*** *[42]* 将连续场景表示为不透明表面，由一个MLP隐式定义，该MLP将每个(x, y, z)坐标映射到特征向量。它们训练一个循环神经网络，沿着穿过场景表示的射线行进，使用任何3D坐标处的特征向量来预测沿射线的前一步大小。从最后一步得到的特征向量被解码为该表面上该点的单一颜色。请注意，SRN是同一作者基于DeepVoxels [41] 的更好性能的后续作品，这就是我们不包括与DeepVoxels比较的原因。



图5：在物理渲染器生成的我们新合成数据集的场景测试集视图上的比较。我们的方法能够恢复几何形状和外观的细节，例如 船的系泊装置、乐高的齿轮和履带、麦克风的光滑支架和网格格栅，以及 材质的非朗伯反射。LLFF在 麦克风支架和 材质的物体边缘出现 banding伪影，并在 船的桅杆和 乐高物体内部出现重影伪影。SRN在所有情况下都产生模糊和失真的渲染效果。神经体积无法捕捉 麦克风格栅或 乐高齿轮的细节，并且完全无法恢复 船的系泊装置的几何形状。



图6：在真实世界场景的测试集视图上的比较。LLFF是专门为此用例设计的（真实场景的前向捕捉）。我们的方法能够在渲染视图之间更一致地表示精细几何形状，如图<样式 id='1'>蕨类植物</样式>的叶子以及<样式 id='3'>三角龙</样式>的骨架肋骨和栏杆所示。我们的方法还能正确重建LLFF难以清晰渲染的部分遮挡区域，例如底部<样式 id='5'>蕨类植物</样式>作物中叶子后面的黄色架子，以及底部<样式 id='7'>兰花</样式>作物背景中的绿色叶子。多次渲染之间的混合也可能导致LLFF出现重复边缘，如顶部<样式 id='9'>兰花</样式>作物所示。SRN捕获每个场景中的低频几何形状和颜色变化，但无法再现任何精细细节。

局部光场融合***(LLFF)*** *[28]* LLFF旨在为充分采样的正向场景生成逼真的新视角。它使用一个训练好的3D卷积网络，直接预测每个输入视图的离散化截锥采样RGBα网格（多平面图像或MPI [52]），然后通过alpha混合和将附近的MPIs混合到新视点中渲染新视角。

6.3 讨论

我们在所有场景中都彻底超越了同时为每个场景优化单独网络（NV和SRN）的基线。此外，在仅使用它们的输入图像作为我们整个训练集的情况下，我们在所有指标（除一个外）上产生了定性和定量上更优越的渲染效果，而与LLFF相比。

SRN方法产生高度平滑的几何形状和纹理，并且其视图合成的表示能力受限于每个相机射线仅选择一个深度和颜色。NV基线能够捕获相当详细的体素几何形状和外观，但其使用底层显式 128^3 体素网格阻止它扩展到在高分辨率下表示精细细节。LLFF特别提供了一个“采样指南”，以不超过输入视图之间64像素的视差，因此它经常无法在包含视图之间高达400-500像素视差的合成数据集中正确估计几何形状。此外，LLFF在渲染不同视图时混合不同的场景表示，导致感知上分散的不一致性，正如我们在补充视频中明显看到的那样。

这些方法之间最大的实际权衡是时间与空间。所有比较的单场景方法每个场景至少需要12小时来训练。相比之下，LLFF可以在不到10分钟内处理一个小型输入数据集。然而，LLFF为每个输入图像生成一个大的3D体素网格，导致巨大的存储需求（一个“Realistic Synthetic”场景超过15GB）。我们的方法只需要5 MB的网络权重（相对于LLFF的3000× 倍压缩），这甚至比我们数据集中任何单个场景的输入图像本身 还要少内存。

6.4 消融研究

我们在表2中通过广泛的消融研究验证了我们算法的设计选择和参数。我们在“逼真的合成 360°”场景上展示了结果。第9行展示了我们的完整模型作为参考。第1行展示了不包含位置编码（PE）、视点依赖（VD）或分层采样（H）的我们模型的极简版本。在第2-4行中，我们从完整模型中逐一移除这三个组件，观察到位置编码（第2行）和视点依赖（第3行）提供了最大的定量收益，其次是分层采样（第4行）。第5-6行展示了随着输入图像数量减少，我们的性能如何下降。请注意，当其他方法使用100张图像时，我们的方法仅使用25张图像的性能仍然在所有指标上超过NV、SRN和LLFF（参见补充材料）。在第7-8行中，我们验证了我们选择的位置编码中使用的最大频率

	输入Im。	L	(N_c, N_f)	PSNR↑	SSIM↑	LPIPS↓
1) 无PE、VD、H	xyz	100	- (256, -)	26.67	0.906	0.136
2) 无位置编码	$xyz\theta\phi$	100	- (64, 128)	28.77	0.924	0.108
3) 无视图依赖	xyz	100	10 (64, 128)	27.66	0.925	0.117
4) 无分层	$xyz\theta\phi$	100	10 (256, -)	30.06	0.938	0.109
5) 远更少的图像	$xyz\theta\phi$	25	10 (64, 128)	27.78	0.925	0.107
6) 更少的图像	$xyz\theta\phi$	50	10 (64, 128)	29.79	0.940	0.096
7) 更少频率	$xyz\theta\phi$	100	5 (64, 128)	30.59	0.944	0.088
8) 更多频率	$xyz\theta\phi$	100	15 (64, 128)	30.81	0.946	0.096
9) 完整模型	$xyz\theta\phi$	100	10 (64, 128)	**31.01**	**0.947**	**0.081**

表2：我们模型的消融研究。指标在8个真实合成数据集场景上取平均值。详见第6.4节。

L （用于$\mathbf{x}$ 的位置编码，用于$\mathbf{d}$ 的最大频率按比例缩放）。仅使用5个频率会降低性能，但将频率数量从10增加到15并不会提升性能。我们认为，一旦 2^L 超过采样输入图像中存在的最大频率（在我们的数据中约为1024），增加 L 的好处就有限了。

7 结论

我们的工作直接解决了先前使用多层感知机（MLP）将对象和场景表示为连续函数时存在的不足。我们证明，将场景表示为5D神经辐射场（一种MLP，其输出体素密度和视点相关发射辐射作为3D位置和2D观察方向的函数）产生的渲染效果优于先前主导的深度卷积网络输出离散体素表示的方法。

尽管我们提出了分层采样策略以使渲染更样本高效（用于训练和测试），但在研究有效优化和渲染神经辐射场的技术方面仍有大量进展空间。未来工作的另一个方向是可解释性：体素网格和网格等采样表示允许推理渲染视图的预期质量和失败模式，但在我们将场景编码到深度神经网络的权重中时，如何分析这些问题尚不清楚。我们相信这项工作朝着基于真实世界图像的图形流水线迈进了一步，其中复杂场景可以由从实际对象和场景图像中优化的神经辐射场组成。

致谢 我们感谢 Kevin Cao、Guowei Frank Yang 和 Nithin Raghavan 的评论和讨论。RR 感谢美国海军研究办公室（ONR）的资助（合同号 N000141712687 和 N000142012529）以及 Ronald L. Graham 讲座的支持。BM 由赫茨基金会奖学金资助，MT 由美国国家科学基金会研究生奖学金资助。谷歌通过 BAIR 公共程序提供了慷慨的云计算资源捐赠。我们感谢以下

Blend Swap 用户，他们为我们的逼真合成数据集提供了模型：gregzaal（船）、1DInc（椅子）、bryanajones（鼓）、Herberhold（Ficus）、erickfree（热狗）、Heinzelnisse（乐高）、elbrujodelatribu（材料）和 up3d.de（麦克风）。

参考文献

1. Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G.S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Man´e, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Vi´egas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., Zheng, X.: TensorFlow: 大规模机器学习在异构系统上（2015） 2. Buehler, C., Bosse, M., McMillan, L., Gortler, S., Cohen, M.: 非结构化光照图渲染。在SIGGRAPH（2001） 3. Chang, A.X., Funkhouser, T., Guibas, L., Hanrahan, P., Huang, Q., Li, Z., Savarese, S., Savva, M., Song, S., Su, H., 等：Shapenet: 一个信息丰富的3D模型库。arXiv:1512.03012（2015） 4. Chen, W., Gao, J., Ling, H., Smith, E.J., Lehtinen, J., Jacobson, A., Fidler, S.: 基于插值的可微分渲染器学习预测3D物体。在NeurIPS（2019） 5. Cohen, M., Gortler, S.J., Szeliski, R., Grzeszczuk, R., Szeliski, R.: 光照图。在SIGGRAPH（1996） 6. Curless, B., Levoy, M.: 一种基于体积的方法从深度图像构建复杂模型。在SIGGRAPH（1996） 7. Davis, A., Levoy, M., Durand, F.: 非结构化光场。在Eurographics（2012） 8. Debevec, P., Taylor, C.J., Malik, J.: 从照片建模和渲染建筑：一种混合几何和基于图像的方法。在SIGGRAPH（1996） 9. Flynn, J., Broxton, M., Debevec, P., DuVall, M., Fyffe, G., Overbeck, R., Snavely, N., Tucker, R.: DeepView: 基于学习的梯度下降视图合成。在CVPR（2019） 10. Genova, K., Cole, F., Maschinot, A., Sarna, A., Vlasic, D., , Freeman, W.T.: 3D可变形模型回归的无监督训练。在CVPR（2018） 11. Genova, K., Cole, F., Sud, A., Sarna, A., Funkhouser, T.: 局部深度隐式函数用于3D形状。在CVPR（2020） 12. Henzler, P., Mitra, N.J., Ritschel, T.: 从2D示例学习神经3D纹理空间。在CVPR（2020） 13. Henzler, P., Rasche, V., Ropinski, T., Ritschel, T.: 单图像断层扫描：从2D颅骨X射线获取3D体积。在Eurographics（2018） 14. Hornik, K., Stinchcombe, M., White, H.: 多层前馈网络是通用逼近器。Neural Networks（1989） 15. Jiang, C., Sud, A., Makadia, A., Huang, J., Nießner, M., Funkhouser, T.: 局部隐式网格表示用于3D场景。在CVPR（2020） 16. Kajiya, J.T., Herzen, B.P.V.: 射线追踪体积密度。Computer Graphics（SIGGRAPH）（1984） 17. Kar, A., H¨ane, C., Malik, J.: 学习多视图立体机器。在NeurIPS（2017） 18. Kingma, D.P., Ba, J.: Adam: 一种随机优化的方法。在ICLR（2015）

19. Kutulakos, K.N., Seitz, S.M.: 空间雕刻的形状理论。International Journal of Computer Vision（2000） 20. Levoy, M.: 体积数据的有效射线追踪。ACM Transactions on Graphics（1990） 21. Levoy, M., Hanrahan, P.: 光场渲染。在SIGGRAPH（1996） 22. Li, T.M., Aittala, M., Durand, F., Lehtinen, J.: 通过边缘采样进行可微蒙特卡洛射线追踪。ACM Transactions on Graphics（SIGGRAPH Asia）（2018） 23. Liu, S., Li, T., Chen, W., Li, H.: 软光栅化器：基于图像的3D推理的可微分渲染器。在ICCV（2019） 24. Lombardi, S., Simon, T., Saragih, J., Schwartz, G., Lehrmann, A., Sheikh, Y.: 神经体积：从图像学习动态可渲染体积。ACM Transactions on Graphics（SIGGRAPH）（2019） 25. Loper, M.M., Black, M.J.: OpenDR: 一种近似可微渲染器。在ECCV（2014） 26. Max, N.: 直接体积渲染的光学模型。IEEE Transactions on Visualization and Computer Graphics（1995） 27. Mescheder, L., Oechsle, M., Niemeyer, M., Nowozin, S., Geiger, A.: 占用网络：在函数空间中学习3D重建。在CVPR（2019） 28. Mildenhall, B., Srinivasan, P.P., Ortiz-Cayon, R., Kalantari, N.K., Ramamoorthi, R., Ng, R., Kar, A.: 局部光场融合：具有规定采样指南的实用视图合成。ACM Transactions on Graphics（SIGGRAPH）（2019） 29. Niemeyer, M., Mescheder, L., Oechsle, M., Geiger, A.: 可微体积渲染：在没有3D监督的情况下学习隐式3D表示。在CVPR（2019） 30. Nimier-David, M., Vicini, D., Zeltner, T., Jakob, W.: Mitsuba 2: 一个可重定向的前向和反向渲染器。ACM Transactions on Graphics（SIGGRAPH Asia）（2019） 31. Oechsle, M., Mescheder, L., Niemeyer, M., Strauss, T., Geiger, A.: 纹理场：在函数空间中学习纹理表示。在ICCV（2019） 32. Park, J.J., Florence, P., Straub, J., Newcombe, R., Lovegrove, S.: DeepSDF: 学习用于形状表示的连续符号距离函数。在CVPR（2019） 33. Penner, E., Zhang, L.: 用于视图合成的软3D重建。ACM Transactions on Graphics（SIGGRAPH Asia）（2017） 34. Porter, T., Duff, T.: 数字图像合成。Computer Graphics（SIGGRAPH）（1984） 35. Rahaman, N., Baratin, A., Arpit, D., Dr¨axler, F., Lin, M., Hamprecht, F.A., Bengio, Y., Courville, A.C.: 关于神经网络的谱偏差。在ICML（2018） 36. Rainer, G., Ghosh, A., Jakob, W., Weyrich, T.: BTF的统一神经编码。Computer Graphics Forum（Eurographics）（2020） 37. Rainer, G., Jakob, W., Ghosh, A., Weyrich, T.: 神经BTF压缩和插值。Computer Graphics Forum（Eurographics）（2019） 38. Ren, P., Wang, J., Gong, M., Lin, S., Tong, X., Guo, B.: 基于辐射回归函数的全局照明。ACM Transactions on Graphics（2013） 39. Sch¨onberger, J.L., Frahm, J.M.: 运动结构重估。在CVPR（2016） 40. Seitz, S.M., Dyer, C.R.: 基于体素着色的照片级真实感场景重建。International Journal of Computer Vision（1999） 41. Sitzmann, V., Thies, J., Heide, F., Nießner, M., Wetzstein, G., Zollh¨ofer, M.: Deep-voxels：学习持久的3D特征嵌入。在CVPR（2019） 42. Sitzmann, V., Zollhoefer, M., Wetzstein, G.: 场景表示网络：连续3D结构感知的神经场景表示。在NeurIPS（2019）

43. Srinivasan, P.P., Tucker, R., Barron, J.T., Ramamoorthi, R., Ng, R., Snavely, N.: 使用多平面图像推动视图外推的边界。在：CVPR (2019) 44. Stanley, K.O.: 组合模式产生网络：开发的一种新颖抽象。遗传编程和可进化机器 (2007) 45. Szeliski, R., Golland, P.: 具有透明度和抠图的立体匹配。在：ICCV (1998) 46. Tulsiani, S., Zhou, T., Efros, A.A., Malik, J.: 通过可微射线一致性实现单视图重建的多视图监督。在：CVPR (2017) 47. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser Ł., Polosukhin, I.: 注意力机制就够了。在：NeurIPS (2017) 48. Waechter, M., Moehrle, N., Goesele, M.: 让它有颜色！对 3D 重建进行大规模纹理化。在：ECCV (2014) 49. Wood, D.N., Azuma, D.I., Aldinger, K., Curless, B., Duchamp, T., Salesin, D.H., Stuetzle, W.: 用于 3D 照相的表面光场。在：SIGGRAPH (2000) 50. Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: 深度特征作为感知度量的不合理有效性。在：CVPR (2018) 51. Zhong, E.D., Bepler, T., Davis, J.H., Berger, B.: 从冷冻电镜图像重建连续的 3D 蛋白质结构分布。在：ICLR (2020) 52. Zhou, T., Tucker, R., Flynn, J., Fyffe, G., Snavely, N.: 立体放大：使用多平面图像学习视图合成。ACM Transactions on Graphics (SIGGRAPH) (2018)

附加实现细节

网络 架构 图7详细介绍了我们简单的全连接架构 .

体积边界 我们的方法通过在相机光线上的连续五维坐标处查询神经辐射场表示来渲染视图。对于合成图像的实验，我们将场景缩放到以原点为中心、边长为2的立方体内，并且只查询此边界体积内的表示。我们的真实图像数据集包含可以在最近点和无穷远处存在的任何内容，因此我们使用归一化设备坐标将这些点的深度范围映射到 $[-1, 1]$。这将所有射线原点移动到场景的近平面，将相机的透视射线映射到变换体积中的平行射线，并使用视差（倒数深度）而不是度量深度，因此所有坐标现在都有界。

训练细节 对于真实场景数据，我们通过在优化过程中向输出 σ 值（在通过ReLU之前）添加具有零均值和单位方差的随机高斯噪声来正则化网络，发现这略微提高了渲染新视图的视觉性能。我们使用Tensorflow [1]实现模型。

渲染细节 为了在测试时渲染新视图，我们通过粗网络对每条射线采样64个点，通过精细网络采样 $64 + 128 = 192$ 个点，总共每条射线有256个网络查询。我们的逼真合成

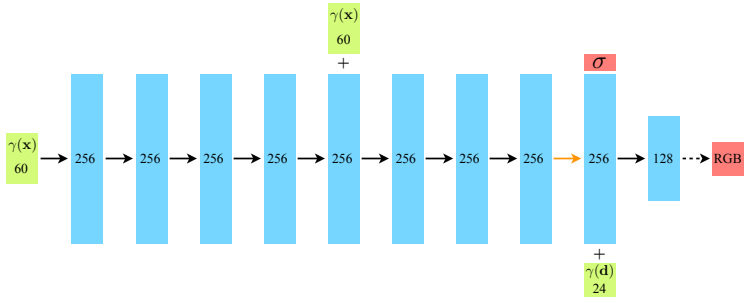


图7：我们全连接网络架构的可视化。输入向量以绿色显示，中间隐藏层以蓝色显示，输出向量以红色显示，每个块内的数字表示向量的维度。所有层都是标准全连接层，黑色箭头表示具有ReLU激活的层，橙色箭头表示无激活的层，虚线黑色箭头表示具有sigmoid激活的层，“+”表示向量拼接。输入位置($\gamma(\mathbf{x})$)的位置编码通过8个具有256个通道的全连接ReLU层传递。我们遵循DeepSDF [32] 架构，并包含一个跳跃连接，该连接将此输入与第五层的激活连接起来。额外的层输出体积密度 σ （使用ReLU整流以确保输出体积密度非负）和256维特征向量。此特征向量与输入观察方向($\gamma(\mathbf{d})$)的位置编码连接，并由一个具有128个通道的额外全连接ReLU层处理。最后一层（具有sigmoid激活）输出在位置$\mathbf{x}$处、由方向$\mathbf{d}$的射线观察到的发射RGB辐射。

该数据集每张图像需要 640k 射线，而我们真实场景每张图像需要 762k 射线，导致每张渲染图像的网络查询量在 1.5 亿到 2 亿之间。在 NVIDIA V100 上，这大约需要每帧 30 秒的时间。

B. 额外基线方法细节

神经体积***(NV)*** *[24]* 我们使用了作者在 https://github.com/facebookresearch/neuralvolumes 开源代码的 NV 代码，并遵循他们在单场景上训练且无时间依赖的流程。

场景表示网络***(SRN)*** *[42]* 我们使用了作者在 https://github.com/vsitzmann/scene-representation-ne 开源代码的 SRN 代码，并遵循他们在单个场景上训练的步骤。

局部光场融合***(LLFF)*** *[28]* 我们使用了作者开源于 https://github.com/Fyusion/LLFF 的预训练LLFF模型。

定量比较 作者发布的SRN实现需要大量GPU显存，即使在4块NVIDIA V100 GPU上并行计算，也仅限于 512×512 像素的分辨率。我们针对合成数据集计算了 512×512 像素的SRN定量指标，针对真实数据集计算了 504×376 像素的指标，而其他方法在更高分辨率下运行时，其指标分别为800×800 和 1008×752 。

C NDC射线空间推导

我们在归一化设备坐标（NDC）空间中重建真实场景，该空间通常作为三角形光栅化管线的一部分使用。“正向”捕获在该空间中。这个空间很方便，因为它在将 z 轴（相机轴）转换为视差线性时保留了平行线。

在这里，我们推导出应用于射线的变换，将它们从相机空间映射到NDC空间。齐次坐标的标准3D透视投影矩阵是：

$$M = \begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \tag{7}$$

其中 n、 f 是近裁剪平面和远裁剪平面， r 和 t 是近裁剪平面处的场景右边界和上边界。（注意：这是相机朝向 $-z$ 方向的约定。）要投影齐次点$(x$、 y、 z, $1)^\top$，我们左乘以 M，然后除以第四坐标：

$$\begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{n}{r}x \\ \frac{n}{t}y \\ \frac{-(f+n)}{f-n}z - \frac{-2fn}{f-n} \\ -z \end{pmatrix} \tag{8}$$

$$\text{project} \rightarrow \begin{pmatrix} \frac{n}{r}\frac{x}{-z} \\ \frac{n}{t}\frac{y}{-z} \\ \frac{(f+n)}{f-n} - \frac{2fn}{f-n}\frac{1}{-z} \end{pmatrix} \tag{9}$$

投影点现在位于归一化设备坐标（NDC）空间中，原始视锥体已被映射到立方体 $[-1, 1]^3$。

我们的目标是将一个射线 $\mathbf{o} + t\mathbf{d}$ 转换为 NDC 空间中的射线原点 $\mathbf{o}'$和方向 $\mathbf{d}'$，使得对于每一个 t，都存在一个新的 t'，满足 $\pi(\mathbf{o} + t\mathbf{d}) = \mathbf{o}' + t'\mathbf{d}'$（其中 π 是使用上述矩阵进行的投影）。换句话说，原始射线的投影和 NDC 空间中的射线追踪出相同的点（但速度可能不同）。

让我们将方程式 9 中的投影点重写为 $(a_x x/z, a_y y/z, a_z + b_z/z)^\top$。新的原点 $\mathbf{o}'$ 和方向 $\mathbf{d}'$ 的分量必须满足：

$$\begin{pmatrix} a_x \frac{o_x+td_x}{o_z+td_z} \\ a_y \frac{o_y+td_y}{o_z+td_z} \\ a_z + \frac{b_z}{o_z+td_z} \end{pmatrix} = \begin{pmatrix} o'_x + t'd'_x \\ o'_y + t'd'_y \\ o'_z + t'd'_z \end{pmatrix}. \tag{10}$$

为了消除一个自由度，我们决定 $t' = 0$ 和 $t = 0$ 应该映射到同一个点。直接代入 $t = 0$ 和 $t' = 0$ 到公式 10 中，就得到了我们的 NDC 空间原点 $\mathbf{o}'$：

$$\mathbf{o}' = \begin{pmatrix} o'_x \\ o'_y \\ o'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x}{o_z} \\ a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z} \end{pmatrix} = \pi(\mathbf{o}). \tag{11}$$

这正是原始射线原点的投影 $\pi(\mathbf{o})$。通过将这个结果代入公式 10 中的任意 t，我们可以确定 t' 和 $\mathbf{d}'$ 的值：

$$\begin{pmatrix} t'd'_x \\ t'd'_y \\ t'd'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x+td_x}{o_z+td_z} - a_x \frac{o_x}{o_z} \\ a_y \frac{o_y+td_y}{o_z+td_z} - a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z+td_z} - a_z - \frac{b_z}{o_z} \end{pmatrix} \tag{12}$$

$$= \begin{pmatrix} a_x \frac{o_z(o_x+td_x) - o_x(o_z+td_z)}{(o_z+td_z)o_z} \\ a_y \frac{o_z(o_y+td_y) - o_y(o_z+td_z)}{(o_z+td_z)o_z} \\ b_z \frac{o_z - (o_z+td_z)}{(o_z+td_z)o_z} \end{pmatrix} \tag{13}$$

$$= \begin{pmatrix} a_x \frac{td_z}{o_z+td_z} \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \frac{td_z}{o_z+td_z} \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{td_z}{o_z+td_z} \frac{1}{o_z} \end{pmatrix} \tag{14}$$

提取出仅依赖于 t 的公共表达式，我们得到：

$$t' = \frac{td_z}{o_z + td_z} = 1 - \frac{o_z}{o_z + td_z} \tag{15}$$

$$\mathbf{d}' = \begin{pmatrix} a_x \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{1}{o_z} \end{pmatrix}. \tag{16}$$

请注意，正如所期望的，当 $t' = 0$ 时 $t = 0$。此外，我们看到 $t' \to 1$ 作为 $t \to \infty$。回到原始投影矩阵，我们的常数为：

$$a_x = -\frac{n}{r} \tag{17}$$

$$a_y = -\frac{n}{t} \tag{18}$$

$$a_z = \frac{f+n}{f-n} \tag{19}$$

$$b_z = \frac{2fn}{f-n} \tag{20}$$

使用标准的针孔相机模型，我们可以重新参数化为：

$$a_x = -\frac{f_{cam}}{W/2} \tag{21}$$

$$a_y = -\frac{f_{cam}}{H/2} \tag{22}$$

其中 W 和 H 是图像的宽度和高度（以像素为单位），f_{cam} 是相机的焦距。

在我们的真实正向捕捉中，我们假设远场景边界是无穷大（这损失很小，因为 NDC 使用 z 维度来表示倒数深度，即视差）。在这种情况下，z 常数简化为：

$$a_z = 1 \tag{23}$$

$$b_z = 2n\,. \tag{24}$$

将所有内容结合起来：

$$\mathbf{o}' = \begin{pmatrix} -\frac{f_{cam}}{W/2}\frac{o_x}{o_z} \\ -\frac{f_{cam}}{H/2}\frac{o_y}{o_z} \\ 1 + \frac{2n}{o_z} \end{pmatrix} \tag{25}$$

$$\mathbf{d}' = \begin{pmatrix} -\frac{f_{cam}}{W/2}\left(\frac{d_x}{d_z} - \frac{o_x}{o_z}\right) \\ -\frac{f_{cam}}{H/2}\left(\frac{d_y}{d_z} - \frac{o_y}{o_z}\right) \\ -2n\frac{1}{o_z} \end{pmatrix}. \tag{26}$$

我们实现中的一个最后细节：我们将 $\mathbf{o}$ 通过取 $\mathbf{o}_n = \mathbf{o} + t_n\mathbf{d}$for $t_n = -(n+o_z)/d_z$，将其平移到射线与近平面的交点处（在进行NDC转换之前）。一旦我们转换到NDC射线，这使我们能够简单地从0到1线性采样 t'，从而在原始空间中获得从n 到 ∞ 的线性视差采样。

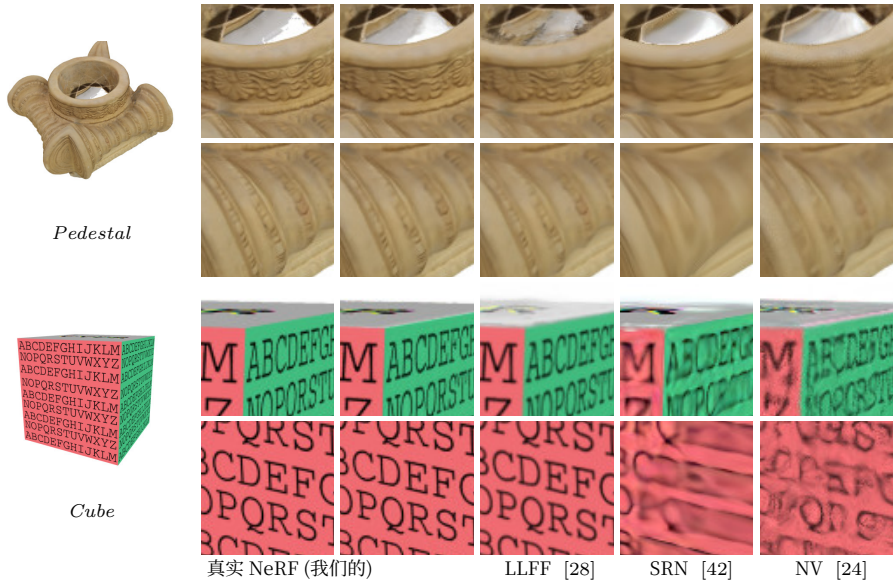


图8：在 DeepVoxels [41] 合成数据集的场景测试集视图上的比较。该数据集中的物体具有简单的几何形状和完美的漫反射。由于输入图像数量众多（479个视图）以及渲染物体的简单性，我们的方法和 LLFF [28]在这份数据上表现近乎完美。LLFF 在插值其 3D 体积时仍偶尔出现伪影，如每个物体顶部插图所示。SRN [42]和 NV [24] 没有足够的表示能力来渲染精细细节。

D 额外结果

场景级分解 表3、4、5和6将主论文中呈现的定量结果分解为场景级指标。场景级分解与论文中呈现的汇总定量指标一致，其中我们的方法在定量上优于所有基线方法。尽管LLFF在LPIPS指标上略好，但我们建议读者观看我们的补充视频，其中我们的方法实现了更好的多视图一致性，并且产生的伪影少于所有基线方法。

	PSNR↑				SSIM↑				LPIPS↓			
	椅子	基座立方体		Vase	椅子	基座立方体		Vase	椅子	基座立方体		Vase
DeepVoxels [41]	33.45	32.35	28.42	27.99	0.99	0.97	0.97	0.96	–	–	–	–
SRN [42]	36.67	35.91	28.74	31.46	0.982	0.957	0.944	0.969	0.093	0.081	0.074	0.044
NV [24]	35.15	36.47	26.48	20.39	0.980	0.963	0.916	0.857	0.096	0.069	0.113	0.117
LLFF [28]	36.11	35.87	32.58	32.97	**0.992**	0.983	0.983	0.983	0.051	0.039	0.064	0.039
Ours	**42.65**	**41.44**	**39.19**	**37.32**	0.991	**0.986**	**0.996**	**0.992**	**0.047**	**0.024**	**0.006**	**0.017**

表3：来自DeepVoxels [41] 数据集的每场景定量结果。该数据集中的“场景”都是具有简单几何形状的漫反射物体，由3D扫描仪捕获的纹理映射网格渲染而成。DeepVoxels方法的指标直接来自其论文，该论文未报告LPIPS，且仅报告了SSIM的两位有效数字。

PSNR↑

	椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
SRN [42]	26.96	17.18	20.73	26.81	20.85	18.09	26.85	20.60
NV [24]	28.33	22.58	24.79	30.71	26.08	24.22	27.78	23.93
LLFF [28]	28.72	21.13	21.79	31.41	24.54	20.72	27.48	23.22
Ours	**33.00**	**25.01**	**30.13**	**36.18**	**32.54**	**29.62**	**32.91**	**28.65**

SSIM↑

	椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
SRN [42]	0.910	0.766	0.849	0.923	0.809	0.808	0.947	0.757
NV [24]	0.916	0.873	0.910	0.944	0.880	0.888	0.946	0.784
LLFF [28]	0.948	0.890	0.896	0.965	0.911	0.890	0.964	0.823
Ours	**0.967**	**0.925**	**0.964**	**0.974**	**0.961**	**0.949**	**0.980**	**0.856**

LPIPS↓

	椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
SRN [42]	0.106	0.267	0.149	0.100	0.200	0.174	0.063	0.299
NV [24]	0.109	0.214	0.162	0.109	0.175	0.130	0.107	0.276
LLFF [28]	0.064	0.126	0.130	**0.061**	0.110	0.117	0.084	0.218
Ours	**0.046**	**0.091**	**0.044**	0.121	**0.050**	**0.063**	**0.028**	**0.206**

表4：从我们的真实合成数据集中获得的每场景定量结果。该数据集中的“场景”都是具有更复杂几何形状和非朗伯材料（Lambertian）的物体，使用Blender的Cycles路径追踪器渲染而成。

	PSNR↑							
	Room	Fern	Leaves	Fortress	兰花花三角龙			角
SRN [42]	27.29	21.37	18.24	26.63	17.37	24.63	22.87	24.33
LLFF [28]	28.42	22.85	19.52	29.40	18.52	25.46	24.15	24.70
Ours	**32.70**	**25.17**	**20.92**	**31.16**	**20.36**	**27.40**	**26.80**	**27.45**

	SSIM↑							
	Room	Fern	Leaves	Fortress	兰花花花三角龙			角
SRN [42]	0.883	0.611	0.520	0.641	0.449	0.738	0.761	0.742
LLFF [28]	0.932	0.753	**0.697**	0.872	0.588	**0.844**	0.857	**0.840**
Ours	**0.948**	**0.792**	0.690	**0.881**	**0.641**	0.827	**0.880**	0.828

	LPIPS↓							
	Room	Fern	叶堡垒		兰花花三角龙			角
SRN [42]	0.240	0.459	0.440	0.453	0.467	0.288	0.298	0.376
LLFF [28]	**0.155**	**0.247**	**0.216**	0.173	**0.313**	**0.174**	**0.222**	**0.193**
Ours	0.178	0.280	0.316	**0.171**	0.321	0.219	0.249	0.268

表5：从我们的真实图像数据集获得的每场景定量结果。该数据集中的场景全部由前置手持手机拍摄。

		PSNR↑							
		椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
1)	无位置编码、无视图依赖、无分层	28.44	23.11	25.17	32.24	26.38	24.69	28.16	25.12
2)	无位置编码	30.33	24.54	29.32	33.16	27.75	27.79	30.76	26.55
3)	无视图依赖	30.06	23.41	25.91	32.65	29.93	24.96	28.62	25.72
4)	无分层	31.32	24.55	29.25	35.24	31.42	29.22	31.74	27.73
5)	远更少的图像	30.92	22.62	24.39	32.77	27.97	26.55	30.47	26.57
6)	更少的图像	32.19	23.70	27.45	34.91	31.53	28.54	32.33	27.67
7)	更少频率	32.19	**25.29**	**30.73**	36.06	30.77	**29.77**	31.66	28.26
8)	更多频率	32.87	24.65	29.92	35.78	32.50	29.54	32.86	28.34
9)	完整模型	**33.00**	25.01	30.13	**36.18**	**32.54**	29.62	**32.91**	**28.65**

		SSIM↑							
		椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
1)	无位置编码，无视图依赖，无分层	0.919	0.896	0.926	0.955	0.882	0.905	0.955	0.810
2)	无位置编码	0.938	0.918	0.953	0.956	0.903	0.933	0.968	0.824
3)	无视图依赖	0.948	0.906	0.938	0.961	0.947	0.912	0.962	0.828
4)	无分层	0.951	0.914	0.956	0.969	0.951	0.944	0.973	0.844
5)	远更少的图像	0.956	0.895	0.922	0.966	0.930	0.925	0.972	0.832
6)	更少的图像	0.963	0.911	0.948	0.971	0.957	0.941	0.979	0.847
7)	更少频率	0.959	**0.928**	**0.965**	0.972	0.947	**0.952**	0.973	0.853
8)	更多频率	0.967	0.921	0.962	0.973	0.961	0.948	**0.980**	0.853
9)	完整模型	**0.967**	0.925	0.964	**0.974**	**0.961**	0.949	0.980	**0.856**

		LPIPS↓							
		椅子	鼓	Ficus	热狗	Lego	材料	Mic	Ship
1)	无位置编码、无视图依赖、无H	0.095	0.168	0.084	0.104	0.178	0.111	0.084	0.261
2)	无位置编码	0.076	0.104	0.050	0.124	0.128	0.079	0.041	0.261
3)	无视图依赖	0.075	0.148	0.113	0.112	0.088	0.102	0.073	0.220
4)	无分层	0.065	0.177	0.056	0.130	0.072	0.080	0.039	0.249
5)	远更少的图像	0.058	0.173	0.082	0.123	0.081	0.079	0.035	0.229
6)	更少的图像	0.051	0.166	0.057	0.121	0.055	0.068	0.029	0.223
7)	更少频率	0.055	0.143	**0.038**	**0.087**	0.071	**0.060**	0.029	0.219
8)	更多频率	0.047	0.158	0.045	0.116	0.050	0.064	**0.027**	0.261
9)	完整模型	**0.046**	**0.091**	0.044	0.121	**0.050**	0.063	0.028	**0.206**

表6：我们消融研究中的每场景定量结果。这里使用的场景与表4中的相同。