This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

本文档由 funstory.ai 的开源 PDF 翻译库 BabelDOC v0.6.2 (https://github.com/funstory-ai/BabelDOC) 翻译，本仓库正在积极的建设当中，欢迎 star 和关注。

占用网络：在函数空间中学习3D重建

拉尔斯·梅斯切德[1] 迈克尔·奥克斯勒[1,2] 迈克尔·尼迈耶尔[1] 塞巴斯蒂安·诺沃齐恩[3†] 安德烈亚斯·盖格[1]1自主视觉小组、智能系统研究所和蒂宾根大学·2ETAS股份公司、斯图加特3谷歌AI柏林

{firstname.lastname}@tue.mpg.de nowozin@gmail.com

摘要

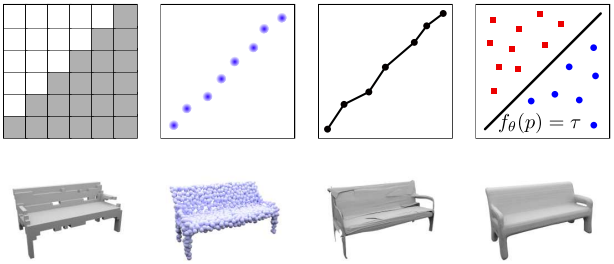
随着深度神经网络的出现，基于学习的3D重建方法越来越受欢迎。然而，与图像不同，在3D中不存在一种计算高效且内存占用小，同时又能表示任意拓扑结构的高分辨率几何的规范表示。因此，许多最先进的学习型3D重建方法只能表示非常粗糙的3D几何，或者仅限于受限域。在本文中，我们提出了占用网络，这是一种用于基于学习的3D重建方法的新表示。占用网络隐式地表示3D表面为深度神经网络分类器的连续决策边界。与现有方法不同，我们的表示在无限分辨率下编码3D输出的描述，而不会带来过大的内存占用。我们验证了我们的表示可以有效地编码3D结构，并且可以从各种类型的输入中推断出来。我们的实验在单张图像、噪声点云和粗糙离散体素网格等具有挑战性的3D重建任务上，无论定性地还是定量地，都取得了具有竞争力的结果。我们相信，占用网络将成为各种基于学习的3D任务中一个有用的工具。

1. 简介

近年来，基于学习的三维重建方法越来越受欢迎[4,9,23,58,75,77]。与传统多视图立体算法不同，学习模型能够编码关于三维形状空间丰富的先验信息，这有助于解决输入中的歧义。

虽然生成模型最近在生成逼真的高分辨率图像方面取得了显著的成就[36, 47, 72],，但这种成功尚未在3D领域得到复制。与2D领域不同，3D领域的

†部分工作是在 MSR Cambridge 完成的。



(a) 体素 (b) 点 (c) 网格 (d) 我们的

图1：概述：现有的3D表示以不同的方式离散化输出空间：(a) 在体素表示中空间地，(b) 在预测点方面，以及(c) 在网格表示的顶点方面。相比之下，(d) 我们提出将分类器的连续决策边界 f_θ (例如，深度神经网络)视为一个3D表面，该表面允许在任何分辨率下提取3D网格。

社區尚未就一種既內存高效又能高效從數據中推理的3D輸出表示達成共識。現有的表示方法可以廣泛分為三種類別：基於體素表示[4,19,43,58,64,69,75]，基於點表示 [1,17]和網格表示 [34,57,70]，見圖1。

体素表示是像素在三维情况下的直接泛化。然而，不幸的是，体素表示的内存占用随分辨率呈立方级增长，因此限制了原始实现只能处理有限的体素。虽然可以通过使用数据自适应表示（如八叉树）来减少内存占用，但这种方法会导致复杂的实现，而现有的数据自适应算法仍然仅限于相对较小的体素网格。点云和网格已被引入作为深度学习的替代表示，使用适当的损失函数。然而，点云缺乏底层网格的连通性结构，因此需要额外的后处理步骤从模型中提取三维几何。¨原始32^3或 64^3体素。虽然可以通过使用数据自适应表示（如八叉树）来减少内存占用，但这种方法会导致复杂的实现，而现有的数据自适应算法仍然仅限于相对较小的 [61,67], 体素网格。点云 [1,17] 和网格 [34,57,70]已被引入作为深度学习的替代表示，使用适当的损失函数。然而，点云缺乏底层网格的连通性结构，因此需要额外的后处理步骤从模型中提取三维几何。

现有的网格表示通常基于变形模板网格，因此不允许任意拓扑结构。此外，这两种方法在标准前馈网络可靠预测的点/顶点数量上都有限制。

在本文中[1]，我们提出了一种基于直接学习连续三维占用函数（图1d）的三维重建新方法。我们不是在固定分辨率下预测体素化表示，而是用神经网络预测完整的占用函数，该神经网络可以在 f_θ任意分辨率下进行评估。这大大减少了训练期间的内存占用。在推理时，我们使用简单的多分辨率等值面提取算法从学习到的模型中提取网格，该算法可以 trivially 在三维位置上并行化。

总之，我们的贡献如下：

- 我们基于学习连续三维映射，引入了一种新的三维几何表示方法。
- 我们展示了这种表示如何用于从各种输入类型重建三维几何。
- 我们通过实验验证了我们的方法能够生成高质量的网格，并证明了它与最先进的方法相比具有优势。

2. 相关工作

基于学习的3D重建现有工作可以大致根据其输出表示分为体素表示、点表示或网格表示。

体素表示：由于简单性，体素是最常用的判别性[45,55,63]和生成性 [9,23,58,64,75,77] 3D任务的表示。

早期工作考虑了使用在体素网格[9, 68, 77]上运行的3D卷积神经网络从单张图像重建3D几何的问题。然而，由于内存需求，这些方法仅限于相对较小的 32^3 体素网格。虽然近期工作 [74, 76, 79] 已将3D卷积神经网络应用于高达 128^3, 的分辨率，但这仅通过浅层架构和小批量大小才可能实现，导致训练速度缓慢。

从多个输入视点重建3D几何的问题已在[31, 35, 52]中得到考虑。Ji等人 [31] 和Kar等人 [35] 在3D体素表示中编码相机参数以及输入图像，并应用3D卷积从多个视点重建3D场景。Paschalidou等人 [52] 引入了一种架构，该架构从多张图像预测体素占用情况，利用多视图几何约束 [69]。

其他研究应用体素表示来学习三维形状的生成模型。这些方法中的大多数都是基于变分自编码器 [39, 59] 或生成对抗网络 [25]。这两种方法分别由 [4, 58] 和 [75], 研究。

由于体素表示需要高内存，最近的研究工作提出了以多分辨率方式重建3D物体 [28, 67]。然而，这些方法通常实现起来很复杂，需要多次处理输入才能生成最终的3D模型。此外，它们仍然受限于相对较小的 256^3 体素网格。为了实现亚体素精度，一些工作[12,42,60]提出了预测截断符号距离场（TSDF） [11] ，其中3D网格中的每个点存储到最近3D表面点的截断符号距离。然而，与占用表示相比，这种表示通常更难学习，因为网络必须在3D空间中推理距离函数，而不仅仅是将体素分类为占用或未占用。此外，这种表示仍然受限于底层3D网格的分辨率。

点表示：一种有趣的3D几何表示方法是3D点云，它在机器人技术和计算机图形学领域都得到了广泛应用。Qi等人[54, 56] 率先将点云作为判别深度学习任务的表示方法。他们通过独立地对每个点应用全连接神经网络，然后进行全局池化操作，实现了置换不变性。Fan等人[17] 将点云作为3D重建的输出表示方法。然而，与其他表示方法不同，这种方法需要额外的非平凡后处理步骤[3, 6, 37, 38] 来生成最终的3D网格。

网格表示：网格最初是通过在由网格的顶点和边张成的图上应用卷积，被考虑用于判别3D分类或分割任务[5, 27, 71]。

最近，网格也被考虑作为3D重建的输出表示方法[26,33,41,70]。不幸的是，这些方法大多容易生成自相交网格。此外，它们只能生成具有简单拓扑结构的网格[70], 需要从同一对象类获取参考模板 [33, 41, 57]或无法保证封闭表面 [26]。Liao等人 [43]提出了一种端到端可学习的马氏立方体算法[44]版本。然而，他们的方法仍然受限于底层3D网格的内存需求，因此也仅限于 32^3 体素分辨率。

与上述方法不同，我们的方法能够生成高分辨率无自交的封闭表面，并且不需要来自同一物体类别的模板网格作为输入。这个想法与用于多视图三维重建的经典水平集[10, 14, 50] 方法[18,24,32,40,53,78]相关。然而，我们的方法不是求解微分方程，而是使用深度学习来获得更具有表达能力（表达能力）的表示，这种表示可以自然地集成到端到端（端到端）学习流程中。

[1]也请参见[8,48,51]，该研究提出了类似的想法。

我们的方法使用深度学习来获得更具有表达能力（表达能力）的表示，这种表示可以自然地集成到端到端（端到端）学习流程中。

3. 方法

在本节中，我们首先将占用网络（Occupancy Networks）介绍为三维几何（3D geometry）的一种表示形式。然后，我们描述了如何从点云、单张图像和低分辨率体素表示（low-resolution voxel representations）等多种形式的输入中学习一个能够推断这种表示的模型。最后，我们描述了一种在测试时从我们的模型中提取高质量三维网格（3D meshes）的技术。

3.1. 占用网络

理想情况下，我们希望不仅能在固定的离散三维位置（如在体素表示中那样）推理占用情况，而且能在每一个可能的三维点 $p \in \mathbb{R}^3$ 上推理。我们将这个函数称为

$$o : \mathbb{R}^3 \rightarrow \{0, 1\} \tag{1}$$

该三维对象的占用函数。我们的关键洞察在于，我们可以用一个神经网络来近似这个三维函数，该网络为每一个位置 $p \in \mathbb{R}^3$ 分配一个介于0和1之间的占用概率。请注意，这个网络与一个二元分类神经网络等效，除了我们感兴趣的是决策边界，该边界隐式地表示了对象的表面（Surface）。

当使用此类网络基于对物体的观测（例如图像、点云等）进行3D重建时，我们必须基于输入对其进行条件化。幸运的是，我们可以利用以下简单的函数等价性：一个以观测 $x \in \mathcal{X}$为输入，以从 $p \in \mathbb{R}^3$ 到 $\mathbb{R}$ 的函数为输出的函数，可以等价地描述为一个以对(p, x) $\in \mathbb{R}^3 \times \mathcal{X}$ 为输入并输出一个实数的函数。后者表示可以使用一个以对(p, x)为输入并输出一个实数的神经网络 f_θ 来简单地参数化，该实数表示占据概率：

$$f_\theta : \mathbb{R}^3 \times \mathcal{X} \rightarrow [0, 1] \tag{2}$$

我们将此网络称为占据网络。

3.2. 训练

为了学习神经网络的参数 θ，我们需要在考虑对象的 3D 边界体积中随机采样点：对于训练批次中的第 i 个样本，我们采样 K 个点 $p_{ij} \in \mathbb{R}^3, j = 1, \ldots, K$。然后我们在这些位置评估小批量损失 $\mathcal{L}_\mathcal{B}$：

$$\mathcal{L}_\mathcal{B}(\theta) = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{K} \mathcal{L}(f_\theta(p_{ij}, x_i), o_{ij}) \tag{3}$$

在这里， x_i 是批次 $\mathcal{B}$ 的第 i 个观测值， $o_{ij} \equiv o(p_{ij})$ 表示在点 p_{ij} 处的真实占用情况，而 $\mathcal{L}(\cdot, \cdot)$ 是交叉熵分类损失。

我们的方法性能取决于我们用于绘制用于训练的位置的采样方案。在4.6节中，我们进行了一项详细的消融研究，比较了不同的采样方案。在实践中，我们发现以物体边界框内均匀采样并附加一个小填充可以获得最佳结果。

我们的三维表示也可以用于学习概率潜变量模型。为此目标，我们引入了一个编码器网络 $g_\psi(\cdot)$ 该网络以位置 p_{ij} 和占用 o_{ij} 作为输入，并预测高斯分布 $q_\psi(z|(p_{ij}, o_{ij})^{j=1:K})$ 在潜空间 $z \in \mathbb{R}^L$上的均值 μ_ψ 和标准差 σ_ψ 作为输出。我们优化了生成模型负对数似然的下界 [21, 39, 59]$((o_{ij})_{j=1:K}|(p_{ij})^{j=1:K})$：

$$\mathcal{L}_\mathcal{B}^{\text{gen}}(\theta, \psi) = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \Big[\sum_{j=1}^{K} \mathcal{L}(f_\theta(p_{ij}, z_i), o_{ij}) + \text{KL}\left(q_\psi(z|(p_{ij}, o_{ij})_{j=1:K}) \,\|\, p_0(z)\right) \Big] \tag{4}$$

其中KL表示KL散度， $p_0(z)$是潜在变量 z_i （通常为高斯分布）上的先验分布，而z_i 根据 $q_\psi(z_i|(p_{ij}, o_{ij})^{j=1:K})$进行采样。

3.3. 推理

对于从训练好的占用网络中提取对应于新观测的等值面，我们引入多分辨率等值面提取 (MISE)，一种分层等值面提取算法 (图 2)。通过逐步构建八叉树 [30, 46, 66, 73], MISE 能够让我们从占用网络中提取高分辨率的网格，而无需密集评估高维占用网格的所有点。

我们首先在初始分辨率下对体素空间进行离散化，并评估占用网络 $f_\theta(p, x)$ 以该网格中的所有 p。我们将所有占用网格点 p 标记为占用，其中$f_\theta(p, x)$ 大于或等于某个阈值[2] τ。接下来，我们将所有至少有两个相邻网格点具有不同占用预测的体素标记为活动。这些体素如果在当前分辨率下应用马氏立方体算法，将与网格相交。我们将所有活动体素细分为8个子体素，并评估通过这种细分引入占用网格的所有新网格点。我们重复这些步骤，直到达到所需的最终分辨率。在此最终分辨率下

[2]阈值 τ是我们占用网络的唯一超参数。它决定了提取的3D表面的“厚度”。在我们的实验中，我们在验证集上交叉验证这个阈值。

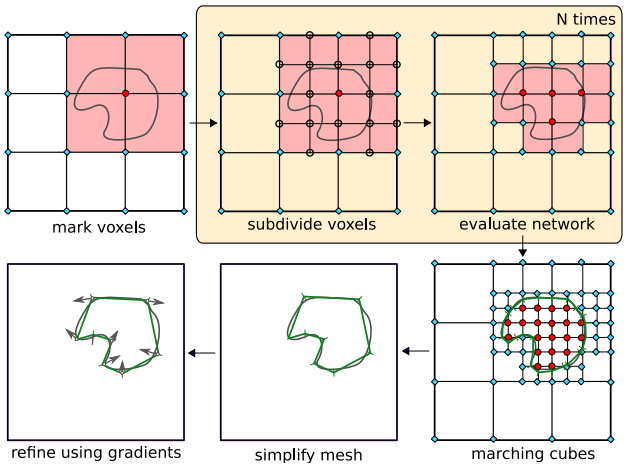


图2：多分辨率等值面提取：我们首先标记给定分辨率下所有已评估的点，这些点要么被标记为占用（红色圆圈），要么被标记为未占用（青色菱形）。然后，我们确定所有具有占用和未占用角点的体素，并将它们标记为活动（浅红色）并将它们细分为每个8个子体素。接下来，我们评估由细分引入的所有新网格点（空圆圈）。前两个步骤重复进行，直到达到所需的输出分辨率。最后，我们使用马氏立方体算法提取网格[44], 使用一阶和二阶梯度信息简化并细化输出网格。

我们应用马氏立方体算法 [44] 来提取近似等值面

$$\{p \in \mathbb{R}^3 \mid f_\theta(p, x) = \tau\}. \tag{5}$$

我们的算法如果初始分辨率下的占用网格包含来自网格内部和外部所有连通分量的点，就会收敛到正确的网格。因此，选择一个足够高的初始分辨率以满足此条件非常重要。在实践中，我们发现 32^3 在几乎所有情况下都足够。

Marching Cubes 算法提取的初始网格可以进一步细化。第一步，我们使用 Fast-Quadric-Mesh-Simplification 算法[3] [20]简化网格。最后，我们使用一阶和二阶（即梯度）信息细化输出网格。为此，我们从输出网格的每个面上采样随机点 p_k 并最小化损失

$$\sum_{k=1}^{K} (f_\theta(p_k, x) - \tau)^2 + \lambda \left\| \frac{\nabla_p f_\theta(p_k, x)}{\|\nabla_p f_\theta(p_k, x)\|} - n(p_k) \right\|^2 \tag{6}$$

$n(p_k)$表示网格在 p_k处的法向量。在实践中，我们设置 $\lambda = 0.01$。最小化第二项

[3]https://github.com/sp4cerat/Fast-Quadric-Mesh-Simplification

在（6）使用二阶梯度信息，并且可以使用 Double-Backpropagation高效实现 [15]。

注意，最后这一步会消除 Marching Cubes 近似中的离散化伪影，如果我们直接预测体素化表示则无法实现。此外，我们的方法还可以通过简单地反向传播通过占用网络来高效提取输出网格所有顶点的法线。总共，我们的推理算法每个网格需要 3 秒。

3.4. 实现细节

我们使用一个包含 5 个 ResNet 模块的完全连接神经网络实现我们的占用网络 [29]，并使用条件批归一化 [13, 16] 对其进行条件化。根据输入类型，我们采用不同的编码器架构。对于单视图 3D 重建，我们使用 ResNet18 架构 [29]。对于点云，我们使用 PointNet 编码器 [54]。对于体素化输入，我们使用 3D 卷积神经网络 [45]。对于无条件网格生成，我们使用 PointNet [54] 作为编码器网络 g_ψ。更多细节请参见补充材料。

4. 实验

我们进行了三种类型的实验来验证所提出的占用网络。首先，我们通过分析网络从学习到的潜在嵌入中重建复杂三维形状的能力，来评估占用网络的表示能力。这为我们根据额外的输入条件我们的表示所能达到的结果提供了一个上限。其次，我们将占用网络应用于图像、噪声点云和低分辨率体素表示，并将我们方法的性能与几种最先进的基线方法进行比较。最后，我们通过向我们的模型添加一个编码器，并从该模型生成无条件的样本，来检验占用网络的生成能力。[4]

基线：对于单图像3D重建任务，我们将其方法与几种最先进的基线进行了比较，这些基线利用了各种3D表示：我们将其与3D-R2N2 [9] 作为体素方法，点集生成网络 (PSGN) [17]作为点技术以及Pixel2Mesh [70] 以及 AtlasNet [26] 作为基于网格的方法。对于点云输入，我们通过更改编码器对3D-R2N2和PSGN进行了适配。作为基于网格的基线，我们使用深度Marching Cubes (DMC) [43]该模型最近在这个任务上报告了最先进的结果。对于体素超分辨率任务，我们评估了相对于输入的改进。

[4]可复现我们实验的代码可在 https://github.com/LMescheder/Occupancy-Networks。

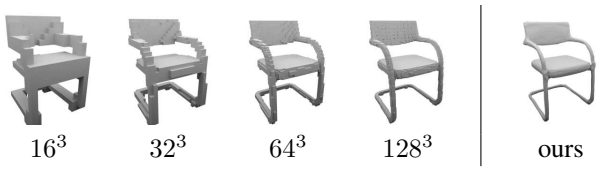


图3：离散与连续。我们连续表示（右）与不同分辨率体素化的定性比较（左）。注意我们的表示如何编码体素表示中丢失的细节。

数据集： 在我们的所有实验中，我们使用Choy等人提出的ShapeNet[7]子集 [9]。我们还使用与Choy等人相同的体素化、图像渲染和训练/测试分割。此外，我们将训练集细分为训练集和验证集，以跟踪我们方法和基线的损失，以确定何时停止训练。

为了生成无孔洞网格并确定点是否位于网格内部（例如，用于测量交并比IoU），我们使用Stutz等人提供的代码 [64]。为了公平比较，我们使用无孔洞网格表面而不是原始模型作为PSGN [17], Pixel2Mesh [70] 和 DMC [43]的ground truth点。所有评估都是针对这些无孔洞网格进行的。

指标：评估时我们使用体素交并比、Chamfer-L_1 距离和法线一致性分数。

体素交并比定义为两个网格并集体积与交集体积的商。我们通过从边界体积中随机采样100k个点并确定这些点是否位于ground truth / 预测网格内部或外部，从而获得交集和并集的 unbiased 估计。

Chamfer-L_1 距离定义为准确性和完整性指标的均值。准确率指标定义为输出网格上的点到真实值网格上最近邻点的平均距离。完整性指标定义方式类似，但方向相反。我们通过从两个网格中随机采样100k个点，并使用KD树来估计相应的距离，从而高效地估计这两种距离。与Fan等人[17] 一样，我们使用当前对象边界框最大边长的 1/10 倍作为单位1。

最后，为了衡量方法捕获高阶信息的能力，我们将法线一致性分数定义为两个网格中法线的平均绝对点积，以及另一个网格中对应最近邻点的法线。

4.1. 表示能力

在我们的第一个实验中，我们研究了占用网络如何独立于输入编码的不准确性来表示三维几何。在这个实验中，我们试图回答的问题是：我们的网络是否能够学习三维形状的内存高效表示，同时尽可能保留尽可能多的细节。这为我们提供了模型表示能力的估计，以及在我们基于额外输入对模型进行条件化时可能达到的性能上限。类似于 [67], ，我们将每个训练样本嵌入到一个512维的潜在空间中，并训练我们的神经网络从这个嵌入中重建三维形状。

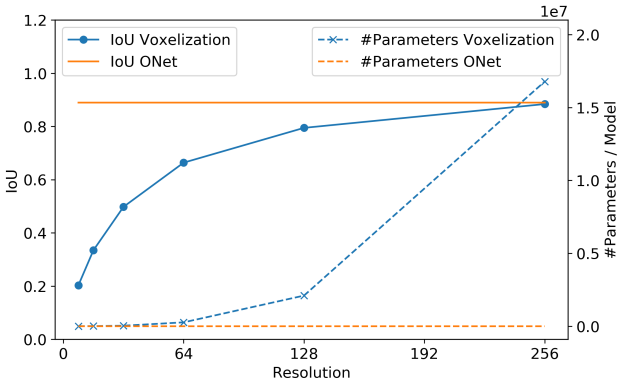


图4：交并比与分辨率。该图显示了体素化与真实值网格的交并比（实蓝线）与我们的连续表示（实橙线）的对比，以及两种表示每个模型所需的参数数量（虚线）。请注意，与低分辨率体素表示相比，我们的表示在交并比方面优于真实值网格。同时，体素表示的参数数量随分辨率呈立方级增长，而占用网络的参数数量与分辨率无关。

我们将方法应用于ShapeNet数据集中“椅子”类别的训练集。这个子集难以表示，因为它高度多样化，且许多模型包含高频细节。由于我们只对重建训练数据感兴趣，因此在这个实验中不使用单独的验证集和测试集。

为评估效果，我们测量了体素IoU与真实值网格的匹配度。定量结果及在不同分辨率下与体素表示的对比显示在图4中。我们发现，占用网络（ONet）能够以0.89的高平均IoU忠实地表示整个数据集，而低分辨率的体素表示无法准确表示网格。同时，占用网络仅需6M参数即可编码所有4746个训练样本，且与分辨率无关。相比之下，体素表示的内存需求随分辨率呈立方级增长。定性结果显示在图3中。我们观察到，占用网络使我们能够表示三维几何的细节，而这些细节在低分辨率体素化中会丢失。

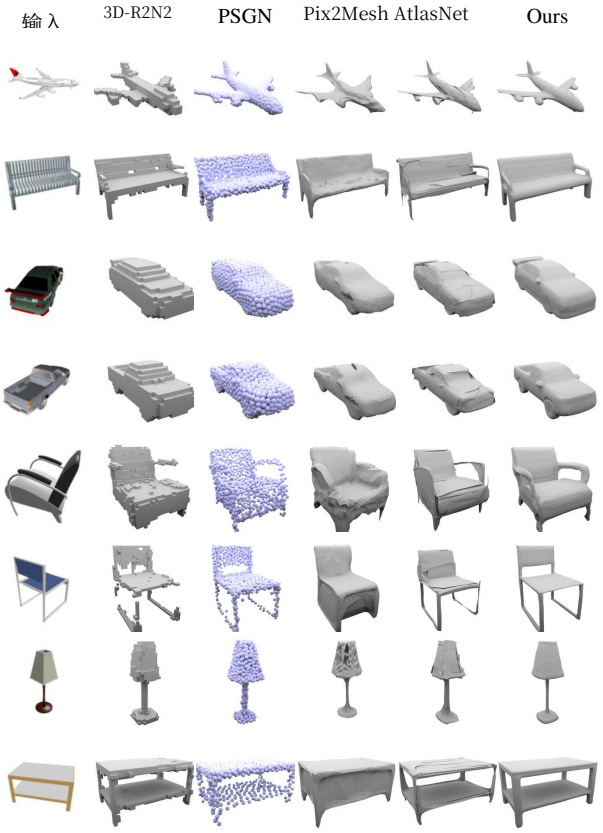


图5：单图像3D重建。输入图像显示在第一列，其他列展示了我们的方法与各种基线方法的对比结果。

4.2. 单图像3D重建

在我们的第二个实验中，我们基于从随机相机位置拍摄的物体额外视角来条件化占用网络。该实验旨在评估占用函数从复杂输入中推断的效果。虽然我们在ShapeNet数据集上训练和测试我们的方法，但也为KITTI [22] 和在线产品数据集 [49]呈现了定性结果。

ShapeNet: 在本实验中，我们使用在ImageNet数据集上预训练的ResNet-18图像编码器。为了公平比较，我们为3D-R2N2和PSGN使用相同的图像编码器[5]。对于PSGN，我们使用一个具有4层和每层512个隐藏单元的全连接解码器。最后一层将隐藏表示投影为一个3072维的向量，然后将其重塑为1024个3D点。由于我们只使用单个输入视图，我们在3D-R2N2中移除了循环网络。我们使用PyTorch重新实现了该方法，紧密遵循作者提供的Tensorflow实现。对于 [70] 的方法，我们使用作者提供的代码和预训练模型 [26],。[6]。

[5]请参考补充材料以比较与原始架构。 [6] https://github.com/ThibaultGROUEIX/AtlasNet

对于所有方法，我们在验证集上跟踪损失和其他指标，并在目标指标达到最优时立即停止训练。对于3D-R2N2和我们的方法，我们使用与真实值网格的IoU作为目标指标，对于PSGN和Pixel2Mesh，我们使用与真实值网格的马氏距离作为目标指标。为了提取最终网格，我们使用0。4 作为3D-R2N2的阈值，如原始出版物中建议的 [9]。为了选择我们方法的阈值参数 τ，我们在验证集上执行网格搜索（见补充材料），发现 $\tau = 0.2$在准确性和完整性之间取得了良好的平衡。

我们的模型和基线的定性结果如图5所示。我们观察到所有方法都能够捕捉输入图像的三维几何。然而，3D-R2N2生成的表示非常粗糙，因此缺乏细节。相比之下，PSGN生成了高保真输出，但缺乏连通性。因此，PSGN需要额外的有损后处理步骤来生成最终网格[7]。Pixel2Mesh能够创建引人注目的网格，但在拓扑结构更复杂的情况下经常遗漏孔洞。这种拓扑结构很常见，例如在ShapeNet数据集的“椅子“类别中。类似地，AtlasNet能够很好地捕捉几何，但会产生自相交和重叠块形式的伪影。

相比之下，我们的方法能够捕捉复杂的拓扑结构，生成封闭的网格并保留大部分细节。请参阅补充材料以获取额外的全分辨率结果和失败案例。

定量结果如表1所示。我们观察到我们的方法实现了最高的交并比，并且与真实值网格具有正常的连贯性。令人惊讶的是，虽然我们的方法没有像PSGN、Pixel2Mesh或AtlasNet那样针对马氏距离进行训练，但它在这个指标上也取得了良好的结果。请注意，由于PSGN或AtlasNet不会生成水密网格，因此无法评估它们的交并比。

真实数据：为了测试我们的模型在真实数据上的泛化能力，我们将网络应用于 KITTI [22] 和在线产品数据集 [49]。为了捕捉 KITTI 和在线产品中视角的多样性，我们使用随机相机位置重新渲染了所有 ShapeNet 对象，并重新训练了网络以完成这项任务。

对于 KITTI 数据集，我们额外使用提供的实例掩码来遮罩和裁剪汽车区域。然后，我们将这些图像输入到我们的神经网络中以预测占用函数。图 6a中展示了部分选定的定性结果。尽管只在合成数据上训练，我们观察到我们的方法在这个具有挑战性的设置中也能够生成逼真的重建。

对于在线产品数据集，我们使用相同的预训练模型。图6b展示了若干定性结果。再次，我们观察到我们的方法在真实图像上泛化得相当好——尽管它仅使用合成数据进行训练。6b。

[7]请参阅补充材料以获取网格化结果。

类别	IoU					Chamfer-L_1					法线一致性				
	3D-R2N2	PSGN	Pix2Mesh	AtlasNet	ONet	3D-R2N2	PSGN	Pix2Mesh	AtlasNet	ONet	3D-R2N2	PSGN	Pix2Mesh	AtlasNet	ONet
飞机	0.426	-	0.420	-	**0.571**	0.227	0.137	0.187	**0.104**	0.147	0.629	-	0.759	0.836	**0.840**
<code>bench</code>	0.373	-	0.323	-	**0.485**	0.194	0.181	0.201	**0.138**	0.155	0.678	-	0.732	0.779	**0.813**
内阁	0.667	-	0.664	-	**0.733**	0.217	0.215	0.196	0.175	**0.167**	0.782	-	0.834	0.850	**0.879**
car	0.661	-	0.552	-	**0.737**	0.213	0.169	0.180	**0.141**	0.159	0.714	-	0.756	0.836	**0.852**
椅子	0.439	-	0.396	-	**0.501**	0.270	0.247	0.265	**0.209**	0.228	0.663	-	0.746	0.791	**0.823**
显示	0.440	-	**0.490**	-	0.471	0.314	0.284	0.239	**0.198**	0.278	0.720	-	0.830	**0.858**	0.854
lamp	0.281	-	0.323	-	**0.371**	0.778	0.314	0.308	**0.305**	0.479	0.560	-	0.666	0.694	**0.731**
扬声器	0.611	-	0.599	-	**0.647**	0.318	0.316	0.285	**0.245**	0.300	0.711	-	0.782	0.825	**0.832**
步枪	0.375	-	0.402	-	**0.474**	0.183	0.134	0.164	**0.115**	0.141	0.670	-	0.718	0.725	**0.766**
sofa	0.626	-	0.613	-	**0.680**	0.229	0.224	0.212	**0.177**	0.194	0.731	-	0.820	0.840	**0.863**
桌子	0.420	-	0.395	-	**0.506**	0.239	0.222	0.218	0.190	**0.189**	0.732	-	0.784	0.832	**0.858**
电话	0.611	-	0.661	-	**0.720**	0.195	0.161	0.149	**0.128**	0.140	0.817	-	0.907	0.923	**0.935**
vessel	0.482	-	0.397	-	**0.530**	0.238	0.188	0.212	**0.151**	0.218	0.629	-	0.699	0.756	**0.794**
mean	0.493	-	0.480	-	**0.571**	0.278	0.215	0.216	**0.175**	0.215	0.695	-	0.772	0.811	**0.834**

表1：单图像3D重建。此表展示了我们的方法与基线在ShapeNet数据集上单图像3D重建的数值比较。我们测量了各种方法的交并比、Chamfer-L_1 距离和法线一致性，相对于真实值网格。请注意，与先前工作不同，我们计算交并比相对于高分辨率网格，而不是粗糙的体素表示。除了AtlasNet [26] 之外的所有方法都是由Choy等人评估在测试集上的。[9]。由于AtlasNet使用预训练模型，我们在 [9]和 [26]的测试集交集上评估它。



(a) KITTI　　(b) 在线产品

图6：真实数据的定性结果。我们将训练好的模型应用于KITTI和在线产品数据集。尽管仅在合成数据上训练，但我们的模型对真实数据的泛化表现相当好。

在Pix3D数据集上的额外定量评估 [65] 可在补充材料中找到。

4.3. 点云补全

作为第二个条件任务，我们将我们的方法应用于从噪声点云重建网格的问题。为此目标，我们从每个（水密）ShapeNet模型的表面抽取300个点，并使用均值为零、标准差为0.05的高斯分布对点云添加噪声。

再次，我们测量了交并比和Chamfer-L_1 距离相对于真实值网格。结果如表2所示。我们观察到我们的方法在交并比、法线一致性和Chamfer-距离方面均取得了最佳结果。

	IoU	Chamfer-L_1	法线一致性
3D-R2N2	0.565	0.169	0.719
PSGN	-	0.202	-
DMC	0.674	0.117	0.848
ONet	**0.778**	**0.079**	**0.895**

表2：点云的3D重建。该表展示了我们在ShapeNet数据集上对点云3D重建的基线方法的数值比较。我们测量了与真实值网格的交并比、Chamfer-L_1 距离和法线一致性。

交并比和法线一致性也最好，而Chamfer-L_1 距离最低。请注意，所有数值都比单图像3D重建任务有显著提升。这可以解释为，对于识别模型来说，这项任务要容易得多，因为存在较少歧义，模型只需填补空白即可。

4.4. 体积超分辨率

作为最后一个条件任务，我们将占用网络应用于3D超分辨率 [62]。在这里，任务是从小体积化的高分辨率网格重建一个粗略 32^3 的网格。

结果如表3所示。我们观察到，与粗略输入网格相比，我们的模型显着提高了交并比、Chamfer-距离和法线一致性。请参阅补充材料以了解定性结果。

4.5. 无条件网格生成

最后，我们将我们的占用网络应用于无条件网格生成，以无监督的方式分别对ShapeNet数据集的四个类别进行训练。我们的目标是探索我们的模型能够多好地表示

	IoU	Chamfer-L_1	法线一致性
输入	0.631	0.136	0.810
ONet	**0.703**	**0.109**	**0.879**

表3：体素超分辨率。该表展示了我们的方法在ShapeNet数据集上与输入的输出进行的数值比较。

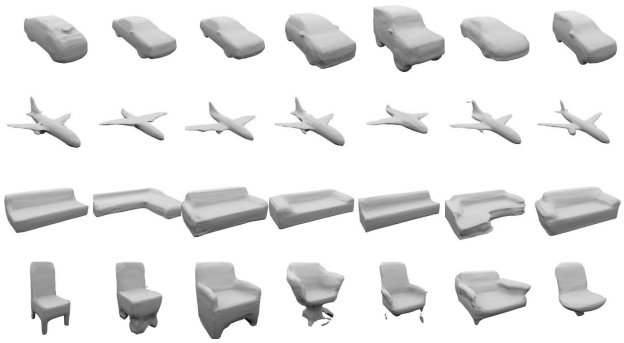


图7：无条件3D样本。我们在ShapeNet数据集的“汽车”、“飞机”、“沙发”和“椅子”类别上训练的无监督模型的随机样本。我们看到我们的模型能够捕捉3D物体的分布，并生成引人入胜的新样本。

3D模型的潜在空间。一些样本显示在图7中。确实，我们发现我们的模型可以生成引人入胜的新模型。在补充材料中，我们展示了我们模型的潜在空间插值。

4.6. 消融研究

在本节中，我们测试我们模型的各个组件如何影响其在单图像3D重建任务上的性能。

采样策略的影响 首先，我们考察采样策略如何影响我们最终模型的性能。我们尝试了三种不同的采样策略：(i) 在真实值网格的边界体积中均匀采样2048个点（均匀采样），(ii) 在网格内部采样1024个点，在网格外部采样1024个点（相等采样），以及(iii) 在网格表面均匀采样1024个点，并加上标准差为0.1的高斯噪声（表面采样）。我们还考察了采样点数量的影响，将这个数量从2048减少到64。

结果如表4a所示。令我们惊讶的是，我们发现最简单的均匀采样策略效果最佳。我们通过以下事实解释这一现象：其他采样策略会对模型引入偏差；例如，当在网格内外采样相同数量的点时，我们隐式地告诉模型每个对象的体积为0。5。实际上，当使用这种采样策略时，我们观察到

	IoU	Chamfer-L_1	法线一致性
均匀	**0.571**	**0.215**	0.834
均匀（64）	0.554	0.256	0.829
相等	0.475	0.291	**0.835**
表面	0.536	0.254	0.822

(a) 采样策略的影响

	IoU	Chamfer-L_1	法线一致性
完整模型	**0.571**	**0.215**	**0.834**
无ResNet	0.559	0.243	0.831
无CBN	0.522	0.301	0.806

(b) 占用网络架构的影响

表4：消融研究。当改变采样策略时，我们发现边界体积内的均匀采样效果最佳。同样，当改变架构时，我们发现带有条件批归一化的ResNet架构效果最佳。

在模型的输出中产生厚化伪影。此外，我们发现将采样点数量从2048减少到64仍然能获得良好性能，尽管模型的表现不如使用2048个采样点训练的模型好。

架构的影响 为了测试我们架构中各个组件的效果，我们测试了两种变体：(i) 我们移除条件批归一化，并在网络的起始处用线性层替换，将输入的编码投影到所需的隐藏维度，以及(ii) 我们移除解码器中的所有ResNet块，并用线性块替换。结果展示在表 4b。我们发现这两个组件都有助于获得良好性能。

5. 结论

在本文中，我们介绍了占用网络，这是一种用于三维几何的新型表示方法。与现有的表示方法不同，占用网络不受三维空间离散化的限制，因此可以用来表示逼真的高分辨率网格。

我们的实验表明，占用网络具有很高的表达能力，并且可以有效地用于监督学习和无监督学习。因此，我们相信占用网络是一种有用的工具，可以应用于各种三维任务。

致谢

这项工作得到了英特尔智能系统网络和微软研究院通过其博士奖学金计划的资助。

参考文献

[1] P. Achlioptas, O. Diamanti, I. Mitliagkas, 和 L. J. Guibas. 学习 3D 点云的表示和生成模型。在 2018 年国际机器学习会议 (ICML) 会议录。1[2] H. A. Alhaija, S. K. Mustikovela, L. Mescheder, A. Geiger, 和 C. Rother. 增强现实与深度学习在城市场景中的汽车实例分割。在 2017 年英国机器视觉会议 (BMVC) 会议录。6[3] F. Bernardini, J. Mittleman, H. Rushmeier, C. Silva, 和 G. Taubin. 球旋转算法用于表面重建。IEEE 图形与计算可视化汇刊 (VCG), 5(4):349–359, 1999。2[4] A. Brock, T. Lim, J. M. Ritchie, 和 N. Weston. 基于卷积神经网络的生成和判别体素建模。arXiv.org, 1608.04236, 2016。1, 2[5] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam, 和 P. Vanderghemst. 几何深度学习：超越欧几里得数据。信号处理杂志, 34 42, 2017 4 18 2 ( ): – 。[6] F. Calakli 和 G. Taubin. SSD: 平滑符号距离表面重建。计算机图形论坛, 30(7):1993–2002, 2011。2[7] A. X. Chang, T. A. Funkhouser, L. J. Guibas, P. Hanrahan, Q. Huang, Z. Li, S. Savarese, M. Savva, S. Song, H. Su, J. Xiao, L. Yi, 和 F. Yu. ShapeNet: 一个信息丰富的 3D 模型库。arXiv.org, 1512.03012, 2015。5[8] Z. Chen 和 H. Zhang. 学习隐式场用于生成式形状建模。IEEE 计算机视觉与模式识别会议 (CVPR) 会议录, 2019。2[9] C. B. Choy, D. Xu, J. Gwak, K. Chen, 和 S. Savarese. 3D- R2N2: 一种用于单视图和多视图 3D 对象重建的统一方法。在 2016 年欧洲计算机视觉会议 (ECCV) 会议录。1, 2, 4, 5, 6, 7[10] D. Cremers, M. Rousson, 和 R. Deriche. 统计方法用于水平集分割的综述：整合颜色、纹理、运动和形状。国际计算机视觉杂志, 72(2):195–215, 2007。2[11] B. Curless 和 M. Levoy. 一种从范围图像构建复杂模型的方法。在 ACM 图形传输 (SIGGRAPH) 会议录, 1996。2[12] A. Dai, C. R. Qi, 和 M. Nießner. 使用 3D- 编码器 - 预测器 CNN 和形状合成进行形状补全。在 IEEE 计算机视觉与模式识别会议 (CVPR) 会议录, 2017。2[13] H. de Vries, F. Strub, J. Mary, H. Larochelle, O. Pietquin, 和 A. C. Courville. 通过语言调节早期视觉处理。在神经信息处理系统进展 (NIPS) 会议录, 2017。4[14] A. Dervieux 和 F. Thomasset. 一种用于模拟瑞利-泰勒不稳定的有限元方法。在纳维-斯托克斯问题的近似方法, 页面 145–158。Springer, 1980。2[15] H. Drucker 和 Y. Le Cun. 使用双重反向传播提高泛化性能。IEEE 神经网络汇刊, 3(6):991–997, 1992。4

[16] V. Dumoulin、I. Belghazi、B. Poole、O. Mastropietro、A. Lamb、M. Arjovsky 和 A. Courville。对抗学习推理。在2017年国际学习表示会议（ICLR）论文集中。4[17] H. Fan、H. Su 和 L. J. Guibas。用于从单张图像进行3D物体重建的点集生成网络。在2017年IEEE计算机视觉与模式识别会议（CVPR）论文集中。1, 2, 4, 5[18] O. Faugeras 和 R. Keriven。水平集方法与立体问题。在1997年国际尺度空间计算机视觉理论会议论文集中。2[19] M. Gadelha、S. Maji 和 R. Wang。从多个物体的二维视图进行3D形状归纳。在2017年国际3D视觉会议（3DV）论文集中。1[20] M. Garland 和 P. S. Heckbert。使用二次误差度量简化具有颜色和纹理的表面。在Visualization’

98 263 269 1998 4 。会议论

[21] 文集，第–页。IEEE，。M. Garnelo、J. Schwarz、D. Rosenbaum、F. Viola、D. J. Rezende、S. M. A. Eslami 和 Y. W. Teh。神经过程。arXiv.org，1807.01622，2018。3

[22] A. Geiger、P. Lenz、C. Stiller 和 R. Urtasun。视觉与机器人学：KITTI数据集。国际机器人研究杂志（IJRR），

32 11 1231 1237, 2013 6 ( ): – 。

[23] R. Girdhar、D. F. Fouhey、M. Rodriguez 和 A. Gupta。学习可预测和生成的物体向量表示。在2016年欧洲计算机视觉会议（ECCV）论文集中。1, 2[24] B. Goldluecke 和 M. Magnor。时空等值面演化用于时间一致的3D重建。在2014年IEEE计算机视觉与模式识别会议（CVPR）论文集中。2[25] I. J. Goodfellow、J. Pouget-Abadie、M. Mirza、B. Xu、D. Warde-Farley、S. Ozair、A. C. Courville 和 Y. Bengio。生成对抗网络。在2014年神经信息处理系统大会（NIPS）论文集中。2[26] T. Groueix、M. Fisher、V. G. Kim、B. Russell 和 M. Aubry。AtlasNet：一种纸浆模型方法来学习 3D 表面生成。在2018年IEEE计算机视觉与模式识别会议（CVPR）论文集中。2, 4, 6, 7´K. Guo、D. Zou 和 X. Chen。通过深度卷积神经网络进行3D网格标注。在ACM图形学汇刊（SIGGRAPH）中，2015。2[27] C. H[28] ane、S. Tulsiani 和 J. Malik。用于3D物体重建的分层表面预测。在国际

3 *3* 2017 2 D视觉（DV）会议

[29] 论文集中。K. He、X. Zhang、S. Ren 和 J. Sun。深度残差学习用于图像识别。在2016年IEEE计算机视觉与模式识别会议（CVPR）论文集中。4[30] C. L. Jackins 和 S. L. Tanimoto。八叉树及其在表示三维物体中的应用。计算机图形学与图像处理, 14(3):249–270，1980。3[31] M. Ji、J. Gall、H. Zheng、Y. Liu 和 L. Fang。SurfaceNet：一个用于多视图立体视觉的端到端3D神经网络。在2017年IEEE国际计算机视觉会议（ICCV）论文集中。2[32] H. Jin、D. Cremers、A. J. Yezzi 和 S. Soatto。立体分割的启示。在2014年IEEE计算机视觉与模式识别会议（CVPR）论文集中。2

[33] A. Kanazawa、M. J. Black、D. W. Jacobs 和 J. Malik。端到端恢复人体形状和姿态。在2018年IEEE计算机视觉与模式识别会议（CVPR）论文集中。2[34] A. Kanazawa、S. Tulsiani、A. A. Efros 和 J. Malik。从图像集合学习特定类别的网格重建。在2018年欧洲计算机视觉会议（ECCV）论文集中。1[35] A. Kar、C. H¨ane 和 J. Malik。学习多视图立体机器。在2017年神经信息处理系统大会（NIPS）论文集中。2[36] T. Karras、T. Aila、S. Laine 和 J. Lehtinen。GANs的渐进式增长以改进质量、稳定性和多样性。在2018年国际学习表示会议（ICLR）论文集中。1[37] M. M. Kazhdan、M. Bolitho 和 H. Hoppe。泊松表面重建。在2006年几何处理研讨会（SGP）论文集中。2[38] M. M. Kazhdan 和 H. Hoppe。筛选泊松表面重建。ACM图形学汇刊（SIGGRAPH），32(3):29，2013。2[39] D. P. Kingma 和 M. Welling。自编码变分贝叶斯。在2014年国际学习表示会议（ICLR）论文集中。2, 3[40] K. Kolev、T. Brox 和 D. Cremers。从多视图鲁棒变分分割3D物体。在2006年联合模式识别研讨会中。2[41] C. Kong、C.-H. Lin 和 S. Lucey。使用局部对应的CAD模型从单张图像进行密集3D重建。在2017年IEEE计算机视觉与模式识别会议（CVPR）论文集中。2[42] L. Ladicky、O. Saurer、S. Jeong、F. Maninchedda 和 M. Pollefeys。使用回归从点云到网格。在2017年IEEE国际计算机视觉会议（ICCV）论文集中。2[43] Y. Liao、S. Donne 和 A. Geiger。深度Marching Cubes：学习显式表面表示。在2018年IEEE计算机视觉与模式识别会议（CVPR）论文集中。1, 2, 4, 5[44] W. E. Lorensen 和 H. E. Cline。Marching Cubes：一种高分辨率3D表面构造算法。在ACM图形学汇刊（SIGGRAPH）中，1987。2, 4[45] D. Maturana 和 S. Scherer。Voxnet：一个用于实时物体识别的3D卷积神经网络。在2015年IEEE国际智能机器人与系统会议（IROS）论文集中。2, 4[46] D. Meagher。使用八叉树编码的几何建模。计算机图形学与图像处理，19 147，1982 2 129 3 ( ): – 。[47] L. Mescheder、A. Geiger 和 S. Nowozin。哪些GANs的训练方法实际上收敛？在2018年国际机器学习会议（ICML）论文集中。1[48] M. Michalkiewicz、J. K. Pontes、D. Jack、M. Baktashmot-lagh 和 A. Eriksson。深度水平集：用于3D形状推断的隐式表面表示。arXiv.org，2019。2[49] H. Oh Song、Y. Xiang、S. Jegelka 和 S. Savarese。通过提升结构特征嵌入进行深度度量学习。在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2016. 6[50]S. Osher 和 J. A. Sethian. 具有曲率相关速度的传播前沿：基于哈密顿-雅可比公式的算法. 计算机物理杂志，79(1):12–49，1988. 2[51] J. J. Park, P. Florence, J. Straub, R. Newcombe, 和 S. Lovegrove. DeepSDF: 学习用于形状表示的连续符号距离函数. arXiv.org，2019. 2[52] D. Paschalidou, A. O. Ulusoy, C. Schmitt, L. van Gool, 和 A. Geiger. Raynet: 使用射线势学习体素化 3D 重建. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2018. 2[53] J.-P. Pons, R. Keriven, 和 O. Faugeras. 通过注册多视图图像序列对动态场景建模. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2005. 2[54] C. R. Qi, H. Su, K. Mo, 和 L. J. Guibas. PointNet: 用于 3D 分类和分割的点集深度学习. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2017. 2, 4[55] C. R. Qi, H. Su, M. Nießner, A. Dai, M. Yan, 和 L. Guibas. 体素化和多视图 CNN 用于 3D 数据的对象分类. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2016. 2[56] C. R. Qi, L. Yi, H. Su, 和 L. J. Guibas. PointNet++: 在度量空间中点集的深度分层特征学习. 在神经信息处理系统进展 (NIPS)，2017. 2[57] A. Ranjan, T. Bolkart, S. Sanyal, 和 M. J. Black. 使用卷积网格自动编码器生成 3D 人脸. 在欧洲计算机视觉会议 (ECCV) 论文集，2018. 1, 2[58] D. J. Rezende, S. M. A. Eslami, S. Mohamed, P. Battaglia, M. Jaderberg, 和 N. Heess. 从图像中无监督学习 3D 结构. 在神经信息处理系统进展 (NIPS)，2016. 1, 2[59] D. J. Rezende, S. Mohamed, 和 D. Wierstra. 深度生成模型的随机反向传播和近似推理. 在国际机器学习会议 (ICML) 论文集，2014. 2, 3[60] G. Riegler, A. O. Ulusoy, H. Bischof, 和 A. Geiger. Oct-NetFusion: 从数据中学习深度融合. 在 3D 视觉国际会议 (3DV) 论文集，2017. 2[61] G. Riegler, A. O. Ulusoy, 和 A. Geiger. OctNet: 在高分辨率下学习深度 3 D 表示. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2017. 1[62] E. Smith, S. Fujimoto, 和 D. Meger. 多视图轮廓和深度分解用于高分辨率 3D 对象表示. 在神经信息处理系统进展 (NIPS). 2018. 7[63] S. Song 和 J. Xiao. 深度滑动形状用于 RGB-D 图像中无模态 3D 对象检测. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR)，2016 年 6 月 . 2[64] D. Stutz 和 A. Geiger. 使用弱监督从激光扫描数据中学习 3D 形状补全. 在 IEEE 计算机视觉与模式识别会议论文集

on 计算机视觉与模式识别会议论文集 (CVPR), 2018. 1, 2, 5[65] X. Sun, J. Wu, X. Zhang, Z. Zhang, C. Zhang, T. Xue, J. B. Tenenbaum, 和 W. T. Freeman. Pix3d: 单图像 3D 形状建模的数据集和方法. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR), 2018. 7[66] R. Szeliski. 从图像序列快速构建八叉树. CVGIP: 图像理解, 58(1):23–32, 1993. 3[67] M. Tatarchenko, A. Dosovitskiy, 和 T. Brox. 八叉树生成网络：用于高分辨率 3D 输出的高效卷积架构. 在 IEEE 国际计算机视觉会议 (ICCV) 论文集, 2017. 1, 2, 5[68] S. Tulsiani, T. Zhou, A. A. Efros, 和 J. Malik. 通过可微射线路径一致性进行单视图重建的多视图监督. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR), 2017. 2[69] A. O. Ulusoy, A. Geiger, 和 M. J. Black. 使用射线势进行概率体素化重建. 在 3D 视觉国际会议 (3DV) 论文集, 2015. 1, 2[70] N. Wang, Y. Zhang, Z. Li, Y. Fu, W. Liu, 和 Y.-G. Jiang. Pixel2Mesh: 从单 RGB 图像生成 3D 网格模型. 在欧洲计算机视觉会议 (ECCV) 论文集, 2018. 1, 2, 4, 5, 6[71] P. Wang, Y. Gan, Y. Zhang, 和 P. Shui. 通过形状全卷积网络进行 3D 形状分割. 计算机图形学, 1702.08675, 2017. 2[72] T.-C. Wang, M.-Y. Liu, J.-Y. Zhu, A. Tao, J. Kautz, 和 B. Catanzaro. 使用条件 GAN 进行高分辨率图像合成和语义操作. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR), 2018. 1[73] K.-Y. Wong 和 R. Cipolla. 轮廓的结构和运动. 在国际机器视觉会议 (ICCV) 论文集, 2001. 3[74] J. Wu, Y. Wang, T. Xue, X. Sun, B. Freeman, 和 J. Tenenbaum. MarrNet: 通过 2.5D 提示进行 3D 形状重建. 在神经信息处理系统进展 (NIPS), 2017. 2[75] J. Wu, C. Zhang, T. Xue, B. Freeman, 和 J. Tenenbaum. 通过 3D 生成对抗建模学习对象形状的概率潜在空间. 在神经信息处理系统进展 (NIPS), 2016 1, 2. J.[76] Wu, C. Zhang, X. Zhang, Z. Zhang, W. T. Freeman, 和 J. B. Tenenbaum. 学习单视图 3D 完成和重建的形状先验. 在欧洲计算机视觉会议 (ECCV) 论文集, 2018. 2[77] Z. Wu, S. Song, A. Khosla, F. Yu, L. Zhang, X. Tang, 和 J. Xiao. 3D ShapeNets: 体素形状的深度表示. 在 IEEE 计算机视觉与模式识别会议论文集 (CVPR), 2015 1, 2. A. Yezzi 和 S. Soatto.[78] 立体分割. 国际计算机视觉杂志, 53(1):31–43, 2003. 2[79] X. Zhang, Z. Zhang, C. Zhang, J. B. Tenenbaum, W. T. Freeman, 和 J. Wu. 学习从未见过的类别中重建形状. 在神经信息处理系统进展 (NIPS), 2018. 2