本文档由 funstory.ai 的开源 PDF 翻译库 BabelDOC v0.6.4 (https://github.com/funstory-ai/BabelDOC) 翻译，本仓库正在积极的建设当中，欢迎 star 和关注。

本文已被接受发表在<样式 id='1'>机器人技术汇刊</样式>上。

<样式 id='1'>DOI: </样式><样式 id='3'>10.1109/TRO.2015.2463671</样式><样式 id='5'>IEEE Xplore: </样式><样式 id='7'>http://ieeexplore.ieee.org/xpl/articleDetails.jsp?arnumber</样式>=7219438

c◯2015 IEEE。个人使用本材料是被允许的。对于所有其他用途，在任何当前或未来的媒体中，包括为广告或促销目的重新印刷/再出版本材料，创建新的集体作品，为转售或重新分配到服务器或列表，或在其他作品中重用本作品中任何受版权保护的部分，必须获得IEEE的许可。

arXiv:1502.00956v2 [cs.RO] 18 Sep 2015

ORB-SLAM：一种通用且精确的单目SLAM系统

Ra´ul Mur-Artal*，J. M. M. Montiel，*IEEE*会员，和Juan D. Tard´os，*IEEE*会员 ，

摘要—本文介绍了ORB-SLAM，一种基于特征的实时单目SLAM系统，可在小型、大型、室内和室外环境中运行。该系统对严重的运动杂波具有鲁棒性，支持宽基线回环检测和重定位，并包含全自动初始化。基于近年来优秀的算法，我们从零开始设计了一个新型系统，该系统对所有SLAM任务（跟踪、建图、重定位和回环检测）都使用相同的特征。通过“适者生存”策略选择重建中的点和关键帧，可带来优异的鲁棒性，并生成一个紧凑且可跟踪的地图，该地图仅在场景内容变化时才会增长，从而实现终身运行。我们在来自最受欢迎数据集的27个序列中进行了详尽的评估。ORB-SLAM相对于其他最先进的单目SLAM方法实现了前所未有的性能。为了社区的利益，我们公开了源代码。

索引词—**终身地图构建、定位、单目视觉、识别、SLAM**

I. 引言

BUNDLE调整（BA）已知可提供相机定位的精确估计，以及稀疏几何重建 [1], [2],前提是提供强大的匹配网络和良好的初始猜测。长期以来，这种方法被认为对实时应用（如视觉同步定位与地图构建，Visual SLAM）来说过于昂贵。Visual SLAM的目标是在重建环境的同时估计相机轨迹。如今我们知道，要在可接受的计算成本下获得精确结果，实时SLAM算法必须为BA提供：

- 所选帧（关键帧）子集中场景特征（地图点）的对应观测。
- 随着关键帧数量的增加，其选择应避免不必要的冗余。
- 关键帧和点之间具有强大网络配置，以产生精确结果，即，一个分布良好的关键帧集合，观察具有显著视差的点，并具有大量回环匹配。
- 对非线性优化所需的关键帧位姿和点位置进行初始估计。
- 在探索过程中构建局部地图，以实现优化并提高可扩展性。
- 能够进行快速全局优化（例如位姿图）以实时闭合回环的能力。

本研究由西班牙通用研究局（Direcci´on General de Investigaci´on）通过项目DPI2012-32168资助，由西班牙教育部奖学金FPU13/04175和阿拉贡政府（Gobierno de Arag´on）奖学金B121/13支持。作者隶属于阿拉贡工程研究所（Instituto de Investigaci´on en Ingenier´ıa de Arag´on (I3A)），萨拉戈萨大学，西班牙萨拉戈萨马里亚·卢纳1号，50018（邮箱：raulmur@unizar.es; josemari@unizar.es；tardos@unizar.es）。*通讯作者。

BA的第一个实时应用是Mouragon等人的视觉里程计工作， [3], 随后是Klein和Murray的开创性SLAM工作，即并行跟踪与地图构建（PTAM）。该算法虽然仅限于小规模操作，但提供了简单而有效的关键帧选择、特征匹配、点三角化、每帧相机定位以及跟踪失败后的重定位方法。不幸的是，几个因素严重限制了其应用：缺乏回环闭合和遮挡处理的不足、重定位对视角的低不变性以及地图初始化需要人工干预。

本研究基于PTAM的主要思想、加尔韦斯-洛佩兹（G´alvez-L´opez）和塔多斯（Tard´os）的位置识别工作、斯特拉达特等人（Strasdat et. al）的尺度感知回环检测以及为大规模操作使用共视性信息来设计从零开始的ORB-SLAM系统，这是一个新颖的单目SLAM系统，其主要贡献包括：

- 使用相同的特征进行所有任务：跟踪、建图、重定位和回环检测。这使得我们的系统更高效、简单和可靠。我们使用ORB特征[9] ，它们允许在没有GPU的情况下实现实时性能，并提供良好的视角和光照变化不变性。
- 在大型环境中进行实时操作。得益于使用可观测性图，跟踪和建图集中在局部可观测区域内，与全局地图大小无关。
- 基于我们称为<样式 id='2'>基本图</样式>的位姿图优化的实时回环检测。它由系统维护的生成树、回环链接和可观测性图中的强边构建而成。
- 具有显著视角和光照不变性的实时相机重定位。这允许从跟踪失败中恢复，并增强了地图重用。
- 一种基于模型选择的新自动且鲁棒的初始化程序，允许创建平面和非平面场景的初始地图。
- 一种<样式 id='2'>适者生存</样式>的地图点和关键帧选择方法，在生成时慷慨但在剔除时非常严格。这种策略提高了跟踪鲁棒性，并增强了终身运行能力，因为冗余的关键帧被丢弃。

我们在室内和室外环境的流行公开数据集上进行了广泛的评估，包括手持设备、汽车和机器人序列。值得注意的是，我们在直接方法 [10], 上实现了比现有技术更好的相机定位精度，这些方法直接优化像素强度而不是特征重投影误差。我们还包含了一个讨论

在第九节B关于可能导致基于特征的方法比直接方法更准确的可能原因

这里提出的回环关闭和重定位方法基于我们之前的工作 [11]。该系统的初步版本已在 [12]。在当前论文中，我们增加了初始化方法、基本图，并完善了所有涉及的方法。我们还详细描述了所有构建模块，并进行了详尽的实验验证。

据我们所知，这是最完整、最可靠的单目SLAM解决方案，为了社区的利益，我们公开了源代码。演示视频和代码可以在我们的项目网页上找到[1]。

II. 相关工作

A. 场所识别

威廉姆斯等人进行的调查 [13] 比较了几种场所识别方法，并得出结论：基于外观的技术，即图像到图像匹配，比地图到地图或图像到地图方法在大环境中表现更好。在基于外观的方法中，诸如概率方法FAB-MAP[15], 等词袋技术因其高效率而备受关注。DBoW2[5] 首次使用了从BRIEF描述符获得的二进制词袋 [16] 以及非常高效的FAST特征检测器 [17]。与之前词袋方法中使用的SURF [18] 和SIFT [19]特征相比，这将特征提取所需的时间减少了超过一个数量级。尽管系统被证明非常高效和鲁棒，但BRIEF的使用（既对旋转也不对尺度具有不变性）将系统限制在平面轨迹和从相似视点检测回环。在我们之前的工作 [11], 中，我们提出了一个基于DBoW2和ORB [9]的词袋场所识别器。ORB是旋转和尺度（在一定范围内）不变的二进制特征，从而产生一个非常快的识别器，并且对视点具有良好的不变性。我们在四个不同的数据集上证明了识别器的高召回率和鲁棒性，从10K图像数据库中检索回环候选所需时间不到39ms（包括特征提取）。在这项工作中，我们使用了一个改进版本的该场所识别器，使用共视信息，并在查询数据库时返回多个假设而不是仅最佳匹配。

B. 地图初始化

单目SLAM需要一个创建初始地图的流程，因为深度无法从单张图像中恢复。解决此问题的一种方法是在初始阶段跟踪一个已知的结构 [20]。在滤波方法框架下，点可以使用逆深度参数化 [21]，以高不确定性初始化深度，希望它们最终能收敛到真实位置。Engel等人最近的半稠密工作 [10], 遵循类似的方法，将像素的深度初始化为具有高方差的随机值。

来自twoviews的初始化方法要么假设局部场景平面性 [4], [22] 并恢复相对相机位姿

[1]http://webdiis.unizar.es/~raulmur/orbslam

使用Faugeras等人提出的方法从单应性 [23],或计算一个基础矩阵 [24], [25] 该矩阵可以模拟平面和一般场景，使用Nister的五点算法[26],这需要处理多个解。这两种重建方法在视差较低的情况下约束性不佳，如果非平面场景的所有点都更靠近其中一个相机中心，就会产生两倍的歧义解[27]。另一方面，如果非平面场景具有视差，则可以使用八点算法 [2]唯一地计算基础矩阵，并且可以无歧义地恢复相对相机位姿

我们在第 IV 节提出了一种基于模型选择的新自动方法，用于在平面场景的单应性和非平面场景的基础矩阵之间进行选择。Torr等人提出了一个统计模型选择方法。[28]。在类似的推理下，我们开发了一种启发式初始化算法，该算法考虑了在接近退化情况下（即平面、近乎平面和低视差）选择基础矩阵的风险，优先选择单应性。在平面情况下，为了安全操作，如果解存在双重歧义，我们避免初始化，因为可能会选择到损坏的解。我们延迟初始化，直到该方法产生具有显著视差的唯一解。

C. 单目*SLAM*

单目SLAM最初通过滤波 [20],[21], [29], [30]得到解决。在该方法中，每个帧都由滤波器处理，以联合估计地图特征位置和相机姿态。它存在处理连续帧时浪费计算量且信息更新较少的缺点，以及线性化误差的累积。另一方面，基于关键帧的方法 [3], [4]仅使用选定的帧（关键帧）来估计地图，允许执行更昂贵但更精确的束调整优化，因为地图构建与帧率无关。Strasdat等人 [31] 证明了对于相同的计算成本，基于关键帧的技术比滤波更准确。

最具代表性的基于关键帧的SLAM系统可能是Klein和Murray [4]开发的PTAM。它是第一个引入并行线程分割相机跟踪和地图构建想法的工作，并证明了在小环境中对实时增强现实应用的成功。原始版本后来通过边缘特征、跟踪过程中的旋转估计步骤以及更好的重定位方法 [32]进行了改进。PTAM的地图点对应于通过块相关匹配的FAST角点。这使得这些点仅适用于跟踪，而不适用于位置识别。事实上，PTAM不会检测大型回环，其重定位基于关键帧低分辨率缩略图的关联，导致对视角变化具有较低的鲁棒性。

Strasdat 等人 [6] 提出了一种大规模单目 SLAM 系统，其前端基于光流并在 GPU 上实现，随后进行 FAST 特征匹配和 仅运动 *BA*，后端基于滑动窗口 BA。回环闭合通过使用具有相似性约束（7DoF）的位姿图优化来解决，该优化能够校正尺度

单目SLAM中出现的漂移。从这项工作中我们获得了基于7DoF位姿图优化的回环检测的想法，并将其应用于基本图定义在第三节D中 III-D

Strasdat 等人 [7] 使用了PTAM的前端，但仅在从可观测性图中检索到的局部地图中进行跟踪。他们提出了一种双窗口优化后端，在内窗口中持续执行BA，在外窗口中执行位姿图。然而，如果外窗口的大小足够大以包含整个回环，则回环闭合才有效。在我们的系统中，我们利用了基于可观测性使用局部地图和从可观测性图构建位姿图的优秀思想，但将它们应用于完全重新设计的 frontend 和 backend。另一个区别是，我们没有使用特定的特征（SURF）进行回环检测，而是在相同的跟踪和映射特征上执行位置识别，从而获得鲁棒的帧率重定位和回环检测。

Pirker 等人 [33] 提出了CD-SLAM，这是一个非常完整的系统，包括回环闭合、重定位、大规模操作以及针对动态环境的努力。然而，地图初始化并未提及。由于缺乏公开实现，我们无法比较其精度、鲁棒性或大规模能力。

Song等人 [34] 的视觉里程计使用ORB特征进行跟踪，并采用时间滑动窗口BA后端。相比之下，我们的系统更通用，因为它们没有全局重定位、回环检测并且不重用地图。它们还使用从相机到地面的已知距离来限制单目尺度漂移。

Lim 等人 [25]，在我们提交这项工作的初步版本之后发表的工作 [12]，也使用相同的特征进行跟踪、建图和回环检测。但是 BRIEF 的选择将系统限制在平面轨迹内。他们的系统仅跟踪最后的关键帧中的点，因此如果重新访问地图就不会被重用（类似于视觉里程计），并且存在无界增长的问题。我们在第 VIII-E.

Engel 等人最近的成果 [10]，被称为 LSD-SLAM，能够构建大规模半稠密地图，使用直接方法（即直接在图像像素强度上进行优化）而不是在特征上进行束调整。他们的结果非常令人印象深刻，因为该系统能够实时运行，无需 GPU 加速，构建半稠密地图，其潜在应用比基于特征的 SLAM 生成的稀疏输出对机器人更有价值。尽管如此，他们仍然需要特征进行回环检测，并且他们的相机定位精度明显低于我们的系统和 PTAM，正如我们在第VIII-B节中实验所展示的那样。这一令人惊讶的结果将在第IX-B节中讨论。

在直接法和基于特征的方法之间，Forster等人提出的半直接视觉里程计SVO处于一个中间位置。 [22]。他们无需在每一帧中提取特征，就能以高帧率运行，在四旋翼飞行器上取得令人印象深刻的结果。然而，没有执行回环检测，当前实现主要针对向下看摄像头。

最后我们想要讨论关键帧选择。所有文献中的视觉SLAM工作都同意运行BA

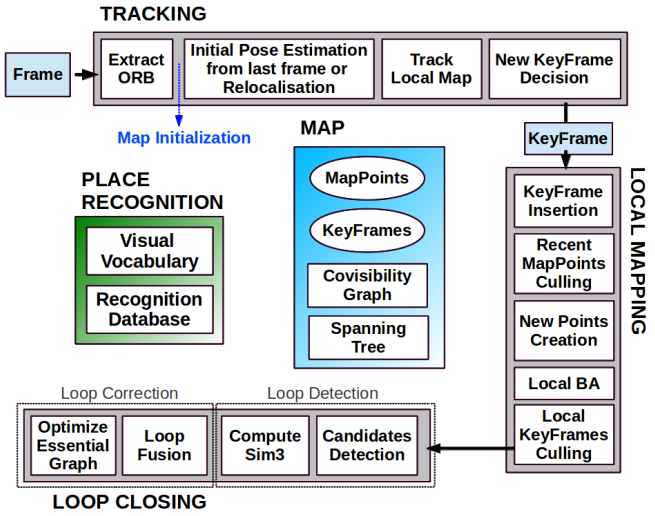


图1. ORB-SLAM系统概述，展示了跟踪、局部建图和回环闭合线程执行的所有步骤。还显示了位置识别模块和地图的主要组件。

最后我们想讨论关键帧选择。所有文献中的视觉SLAM工作都认为，使用所有点和所有帧运行BA是不可行的。Strasdat等人 [31]的工作表明，最具成本效益的方法是尽可能保留更多点，同时仅保留非冗余关键帧。PTAM方法非常谨慎地插入关键帧，以避免计算复杂度的过度增长。这种限制性关键帧插入策略导致在困难探索条件下跟踪失败。我们的适者生存 策略通过尽可能快地插入关键帧，并在后期移除冗余帧，以避免额外成本，在困难场景中实现了前所未有的鲁棒性。

III. 系统概述

A. 特征选择

我们系统中的一个主要设计思想是，用于映射和跟踪的特征也用于位置识别，以执行帧率重定位和回环检测。这使得我们的系统高效，并避免了像先前工作那样需要从近SLAM特征中插值识别特征的深度。我们要求每张图像的特征提取时间少于33毫秒，这排除了流行的SIFT（～ 300毫秒） [19],SURF（～ 300毫秒） [18] 或最近的A-KAZE（～ 100毫秒） [35]。为了获得通用位置识别能力，我们需要旋转不变性，这排除了BRIEF [16] 和LDB [36]。

我们选择了ORB [9]，它们是具有256位描述符的定向多尺度FAST角点。它们计算和匹配速度极快，同时具有良好的视角不变性。这使得可以从大基线距离匹配它们，从而提高BA的精度。我们已经在 [11]中展示了ORB在位置识别方面的良好性能。虽然我们当前的实现使用了ORB，但所提出的技术并不局限于这些特征。

B. 三线程：跟踪、局部地图构建和回环检测

我们的系统，请参见图1，包含三个并行运行的线程：跟踪、局部建图和回环

闭合。跟踪负责用每一帧定位相机，并决定何时插入新关键帧。我们首先使用前一帧进行初始特征匹配，然后使用仅运动*BA*优化位姿。如果跟踪丢失（例如由于遮挡或突然运动），则使用位置识别模块执行全局重定位。一旦获得初始相机位姿和特征匹配，系统维护的关键帧可观测性图将检索局部可见地图，请参见图2(a) 和图2(b)。然后通过重投影搜索与局部地图点的匹配，并使用所有匹配再次优化相机位姿。最后，跟踪线程决定是否插入新关键帧。所有跟踪步骤在第五节V中有详细说明。创建初始地图的新方法在第四节IV中介绍。

局部地图处理新的关键帧并执行局部*BA* 以在相机位姿周围实现最优重建。在新关键帧中搜索未匹配的ORB对应关系，在可观测性图中连接的关键帧中三角化新点。创建一段时间后，根据跟踪期间收集的信息，应用紧急点剔除策略，仅保留高质量点。局部地图还负责剔除冗余关键帧。我们在第VI节详细解释所有局部地图步骤。

回环搜索在每次新关键帧时搜索回环。如果检测到回环，我们计算相似性变换，该变换告知回环中累积的漂移。然后对回环的两边进行对齐和重复点的融合。最后在相似性约束下执行位姿图优化 [6] 以实现全局一致性。主要创新在于我们在基本图上执行优化，基本图是可观测性图的一个稀疏子图，在第III-D节中解释。回环检测和校正步骤在第VII节详细解释。

我们使用 g2o 中实现的 Levenberg-Marquardt 算法 [37] 来执行所有优化。在附录中我们描述了每个优化中涉及的误差项、代价函数和变量。

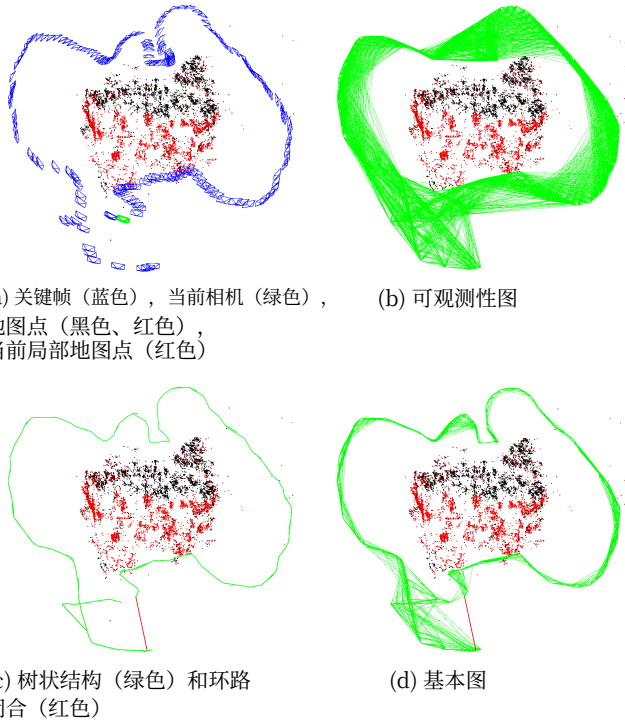
C. 地图点、关键帧及其选择

每个地图点 p_i 存储着：

- 它的 3D 位置$\mathbf{X}_{w,i}$ 在世界坐标系中。
- 观察方向 $\mathbf{n}_i$，这是其所有观察方向的平均单位向量（即连接该点与观察它的关键帧的光学中心的射线）。
- 一个代表性的 ORB 描述符 $\mathbf{D}_i$，这是与该点在观察它的关键帧中关联的所有描述符中汉明距离最小的 ORB 描述符。
- 该点可观测的最大 $d_{\max}$ 和最小 $d_{\min}$ 距离，根据ORB特征的尺度不变性限制。

每个关键帧 K_i 存储以下内容：

- 相机位姿 $\mathbf{T}_{iw}$，它是一个刚体变换，将点从世界坐标系变换到相机坐标系。



(a) 关键帧（蓝色），当前相机（绿色），地图点（黑色、红色），当前局部地图点（红色）

(b) 可观测性图

(c) 树状结构（绿色）和环路闭合（红色）

(d) 基本图

图2. TUM RGB-D基准中序列<样式id='1'>fr3 长办公室 家庭 </样式> [38]的重建和图

- 相机内参，包括焦距和主点。
- 所有在帧中提取的ORB特征，无论是否关联到地图点，如果提供了畸变模型，其坐标将被校正。

<样式id='1'>地图点和关键帧通过宽松的策略创建，而后期非常严格的剔除机制负责检测冗余关键帧和错误的匹配或不可追踪的地图点。这允许在探索过程中灵活地扩展地图，从而增强在困难条件（例如旋转、快速运动）下的跟踪鲁棒性，同时其大小在持续访问相同环境时受限制，即终身运行。此外，与PTAM相比，我们的地图包含非常少的异常值，代价是包含较少的点。地图点和关键帧的剔除过程分别在 </样式><样式id='3'>VI-B </样式><样式id='5'>和 </样式><样式id='7'>VI-E </样式><样式id='9'>中分别解释。</样式>

D. 可观测性图和基本图

关键帧之间的可观测性信息在我们的系统多个任务中非常有用，表示为一个无向加权图，如 [7]。每个节点是一个关键帧，如果两个关键帧共享对相同地图点的观测（至少15个），则它们之间存在一条边，边的权重 θ 为公共地图点的数量。

为了修正回环，我们执行一个姿态图优化 [6]，将回环闭合误差沿图分布。为了避免包含可观测性图提供的所有边（这可能非常密集），我们提议构建一个 *EssentialGraph* ，它保留所有节点（关键帧），但边更少，同时仍然保留一个能产生强网络的图。

精确的结果。系统从初始关键帧开始逐步构建一棵生成树，该树提供了一个具有最少边数的可观测性图的可连接子图。当插入一个新的关键帧时，它被包含在与其共享最多点观测的关键帧链接的树中，当关键帧被剔除策略删除时，系统会更新受该关键帧影响的所有链接。The 基本图 包含生成树、可观测性图的高可观测性（$\theta_{\min} = 100$）边子集以及回环闭合边，从而形成一个强化的相机网络。图. 2 展示了可观测性图、生成树和相关的基本图的一个示例。如第 VIII-E节中的实验所示，在执行位姿图优化时，解非常精确，额外的全束调整优化几乎无法改进解。基本图和 $\theta_{\min}$ 的影响在 VIII-E 节的末尾展示。

E. 袋子词位置识别

该系统集成了基于DBoW的袋子词位置识别模块，用于执行回环检测和重定位。视觉词只是描述空间的离散化，称为视觉词汇。该词汇通过离线方式使用从大量图像中提取的ORB描述符创建。如果图像足够通用，相同的词汇可用于不同环境并取得良好性能，正如我们之前的工作所示 2[2] [5], 。系统逐步构建一个包含倒排索引的数据库，该索引存储词汇表中的每个视觉词在哪些关键帧中出现过，以便高效地查询数据库。当关键帧被剔除程序删除时，数据库也会更新。

由于关键帧之间存在视觉重叠，在查询数据库时不会存在一个具有高分的唯一关键帧。原始DBoW2考虑了这种重叠，将时间上接近的图像的分数相加。这限制了它不包括在同一位置但插入时间不同的关键帧。相反，我们将可观测性图中连接的关键帧进行分组。此外，我们的数据库会返回所有分数高于最佳分数75%的关键帧匹配。

单词袋表示在特征匹配方面的另一个好处在 [5]中报告。当我们想要计算两组ORB特征之间的对应关系时，我们可以将暴力匹配约束到词汇树中同一节点属于同一级别的那些特征（我们选择六个中的第二个），从而加快搜索速度。我们在搜索用于三角化新点、回环检测和重定位的匹配时使用这个技巧。我们还使用方向一致性测试来细化对应关系，参见 [11] 的详细内容，该测试会丢弃异常值，确保所有对应关系具有一致的旋转。

[2]https://github.com/dorian3d/DBoW2

IV. 自动地图初始化

地图初始化的目标是计算两个帧之间的相对位姿，以三角化一组初始地图点。该方法应与场景（平面或一般）无关，并且不应需要人工干预来选择一个好的双视图配置，即具有显著视差的配置。我们提出并行计算两种几何模型：一个假设场景为平面的单应性，和一个假设场景为非平面的基础矩阵。然后我们使用启发式算法选择一个模型，并尝试使用针对所选模型的特定方法恢复相对位姿。我们的方法仅在确定双视图配置安全时才进行初始化，检测低视差情况以及众所周知的平面二重歧义 [27], 避免初始化损坏的地图。我们的算法步骤如下：

1) 寻找初始对应关系：在当前帧中提取ORB特征（仅在最高尺度），并在参考帧中搜索匹配的 $\mathbf{x}_c \leftrightarrow \mathbf{x}_r$ 。如果找到的匹配数量不足，则重置参考帧。

2) 两个模型的并行计算：
并行线程计算单应性 $\mathbf{H}_{cr}$ 和基础矩阵 $\mathbf{F}_{cr}$:

$$\mathbf{x}_c = \mathbf{H}_{cr}\,\mathbf{x}_r \qquad \mathbf{x}_c^T\,\mathbf{F}_{cr}\,\mathbf{x}_r = 0 \tag{1}$$

使用归一化DLT和8点算法（如前所述）分别在RANSAC方案内进行计算。为了使两个模型的步骤保持一致，迭代次数被预设且相同，同时指定每次迭代使用的点数——8个用于基础矩阵，4个用于单应性。在每次迭代中，我们为每个模型 M （H 用于单应性， F 用于基础矩阵）计算一个分数 S_M ：

$$S_M = \sum_i \left(\rho_M\left(d^2_{cr}(\mathbf{x}^i_c, \mathbf{x}^i_r, M)\right) + \rho_M(d^2_{rc}(\mathbf{x}^i_c, \mathbf{x}^i_r, M))\right)$$
$$\rho_M(d^2) = \begin{cases} \Gamma - d^2 & \text{if} \quad d^2 < T_M \\ 0 & \text{if} \quad d^2 \geq T_M \end{cases} \tag{2}$$

d^2_{cr} 和 d^2_{rc} 是两个帧之间的对称传输误差 [2]。 T_M 是基于 χ^2 测试的异常值剔除阈值，在95%置信度下（$T_H = 5.99, T_F = 3.84$，假设测量误差的标准差为1像素）。 Γ 被定义为等于 T_H，以便两个模型在它们的内点区域内对相同的 d 得分相同，再次使过程保持一致性。
我们保留得分最高的单应性和基础矩阵。如果没有模型可以被找到（内点不足），我们将重新从步骤1开始这个过程。

3) 模型选择：
如果场景是平面的、近似平面的或存在低视差，这可以用单应性来解释。然而也可以找到一个基础矩阵，但问题是约束性不好 [2] ，并且任何从基础矩阵中恢复运动的做法都会

我们选择单应性作为重建方法，因为重建方法会从平面正确初始化，或者它会检测到低视差情况并拒绝初始化。另一方面，具有足够视差的非平面场景只能用基础矩阵来解释，但如果匹配点位于平面上或视差较低（它们距离较远），也可以找到单应性来解释其中一部分匹配。在这种情况下，我们应该选择基础矩阵。我们发现有鲁棒的启发式算法是计算：

$$R_H = \frac{S_H}{S_H + S_F} \tag{3}$$

并选择单应性如果 $R_H > 0.45$，它可以充分捕捉平面和低视差的情况。否则，我们选择基础矩阵。

4) 运动结构恢复：
一旦选择了一个模型，我们检索与之关联的运动假设。在单应性的情况下，我们使用Faugeras等人提出的方法检索8个运动假设 [23]。该方法提出使用对偶性测试来选择有效解。然而，如果存在低视差，这些测试会失败，因为点会轻易地出现在相机的前方或后方，这可能导致选择错误解。我们建议直接三角化这八个解，并检查是否存在一个解，其视差点同时出现在两个相机前方且具有低重投影误差。如果没有明显的获胜解，我们不初始化并继续步骤1。这种消除歧义解的技术使我们的初始化在低视差和双重歧义配置下保持鲁棒性，并可以被认为是我们方法鲁棒性的关键。

对于基础矩阵，我们使用校准矩阵$\mathbf{K}$将其转换为本质矩阵：

$$\mathbf{E}_{rc} = \mathbf{K}^T \mathbf{F}_{rc} \mathbf{K} \tag{4}$$

然后使用 [2]中解释的奇异值分解方法检索4个运动假设。我们对这四个解进行三角测量，并选择重建结果，就像对单应性所做的那样。

5) 束调整：
最后我们执行完整*BA*，见附录以获取详细信息，以细化初始重建。

户外纽卡斯尔学院机器人序列中一个具有挑战性的初始化示例 [39]如图3所示。可以看出PTAM和LSD-SLAM如何初始化平面上的所有点，而我们的方法则等待视差足够时，从基础矩阵正确初始化。

V. TRACKING

在本节中，我们描述了跟踪线程执行的步骤，这些步骤使用来自相机的每一帧完成。在多个步骤中提到的相机位姿优化，包括仅运动*BA*，在附录中描述。

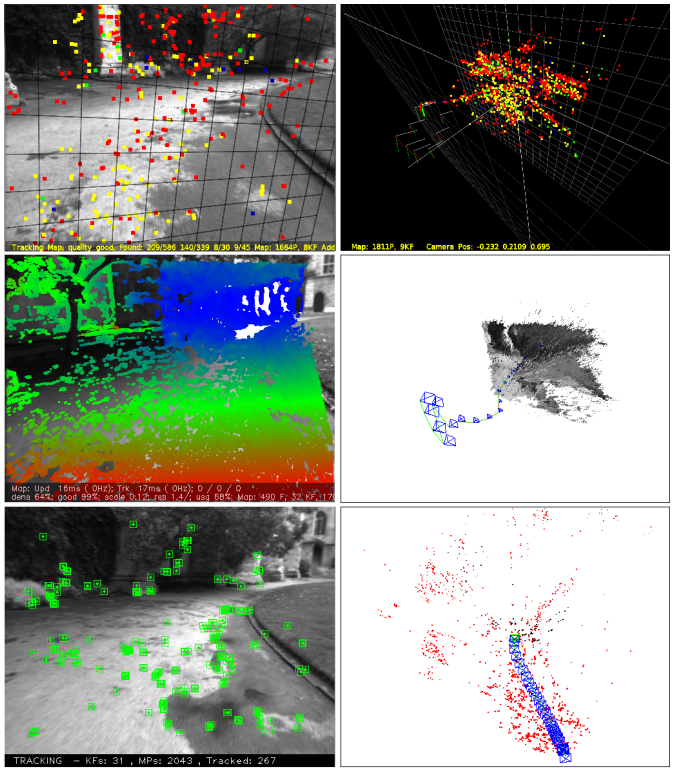


图3。顶部：PTAM，中部：LSD-SLAM，底部：ORB-SLAM，在纽卡斯尔学院序列初始化一段时间后 [39]。PTAM和LSD-SLAM初始化了一个损坏的平面解，而我们的方法在检测到足够的视差时已自动从基础矩阵初始化。根据手动选择的关键帧，PTAM也能够很好地初始化。

A. *ORB*提取

我们在8个尺度级别上提取FAST角点，尺度因子为1.2。对于从 512×384 到 752×480像素的图像分辨率，我们发现提取1000个角点合适，对于更高分辨率，如KITTI数据集中的 1241×376 ，我们提取2000个角点。为了确保均匀分布，我们将每个尺度级别划分为网格，尝试每个单元格至少提取5个角点。然后我们在每个单元格中检测角点，如果找到的角点不足，则调整检测器阈值。如果某些单元格不包含角点（无纹理或对比度低），则还会调整每个单元格保留的角点数量。然后在保留的FAST角点上计算方向和ORB描述符。ORB描述符用于所有特征匹配，这与PTAM中的基于区域相关性的搜索不同。

B. 从前一帧进行初始位姿估计

如果上一帧的跟踪成功，我们使用匀速运动模型来预测相机位姿，并对上一帧中观察到的地图点进行引导搜索。如果找到的匹配不足（即运动模型明显被违反），我们使用更广泛的搜索来寻找位于上一帧中其位置周围的地图点。然后使用找到的对应关系来优化位姿。

C. 通过全局重定位进行初始位姿估计

如果跟踪丢失，我们将帧转换为词袋，并查询识别数据库以获取用于全局重定位的关键帧候选。我们使用与每个关键帧中的地图点关联的ORB计算对应关系，如第III-E节所述。然后，我们交替对每个关键帧进行RANSAC迭代，并尝试使用PnP算法找到相机位姿 [41]。如果我们找到一个具有足够内点的相机位姿，我们将优化该位姿，并对候选关键帧的地图点进行引导搜索以找到更多匹配。最后，再次优化相机位姿，如果得到足够内点的支持，跟踪程序将继续。

D. 跟踪局部地图

一旦我们获得了相机位姿的估计以及一组初始特征匹配，就可以将地图投影到当前帧中，并搜索更多的地图点对应关系。为了限制在大地图中的复杂度，我们只投影局部地图。这个局部地图包含与当前帧共享地图点的关键帧集 $\mathcal{K}_1$，以及与可观测性图中关键帧 $\mathcal{K}_1$ 的邻居组成 $\mathcal{K}_2$ 的集合。局部地图还有一个与当前帧共享最多地图点的参考关键帧 $K_{\text{ref}} \in \mathcal{K}_1$。现在，$\mathcal{K}_1$ 和 $\mathcal{K}_2$ 中看到的每个地图点都按照以下方式在当前帧中进行搜索：

1) 计算地图点在当前帧中的投影 $\mathbf{x}$。如果它位于图像边界之外，则丢弃。2) 计算当前视线路 $\mathbf{v}$ 与地图点平均视向 $\mathbf{n}$ 之间的角度。如果 $\mathbf{v} \cdot \mathbf{n} < \cos(60°)$，则丢弃。3) 计算地图点到相机中心的距离 d。如果它超出了地图点 $d \notin [d_{\min}, d_{\max}]$ 的尺度不变性区域，则丢弃。4) 通过比例 $d/d_{\min}$ 计算帧中的尺度。5) 将地图点的代表性描述符 $\mathbf{D}$ 与当前帧中仍未匹配的 ORB 特征，在预测的尺度下，并在 $\mathbf{x}$ 附近进行比较，并将地图点与最佳匹配关联起来。

相机位姿最终通过优化，利用了帧中所有找到的地图点。

E. 新关键帧决策

最后一步是判断当前帧是否生成为新关键帧。由于局部映射中有剔除冗余关键帧的机制，我们会尽可能快速地插入关键帧，因为这样可以使跟踪对具有挑战性的相机运动（通常为旋转）更加鲁棒。要插入新关键帧，必须满足以下所有条件：

1) 从上次全局重定位以来，必须有超过20帧过去。2) 局部映射处于空闲状态，或者从上次关键帧插入以来已经过去超过20帧。3) 当前帧至少跟踪50个点。4) 当前帧跟踪的点数少于 K_{ref}的90%。

代替像 PTAM 那样使用与关键帧的距离标准，我们施加一个最小的视觉变化（条件4). 条件1确保良好的重定位，条件3确保良好的跟踪。如果在局部地图繁忙时插入关键帧（条件2的第二部分），则会发送信号停止local bundleadjustment，以便它能够尽快处理新的关键帧。

VI. 局部映射

在本节中，我们描述了局部映射在每次新关键帧 K_i时执行的操作步骤。

A. 关键帧插入

首先我们更新可观测性图，为 K_i 添加一个新节点，并更新与其他关键帧通过共享地图点产生的边。然后我们更新连接 K_i 与具有最多共同点的关键帧的生成树。接着我们计算关键帧的词袋表示，这将有助于新点的三角化数据关联。

B. 近期地图点剔除

地图点若要保留在地图中，在创建后的前三个关键帧期间必须通过一项严格的测试，以确保它们是可追踪的且没有被错误三角化，即由于虚假数据关联导致。一个点必须满足这两个条件：

1) 追踪必须在它被预测可见的25%以上的帧中找到该点。2) 如果从地图点创建后已经过了多个关键帧，它必须至少被三个关键帧观测到。

一旦地图点通过这项测试，它只能在与少于三个关键帧的观测中移除。这会在关键帧被剔除以及局部束调整丢弃异常观测时发生。这项策略使我们的地图包含极少数异常点。

C. 新地图点创建

新地图点是通过从连通的关键帧中三角化ORB创建的 $\mathcal{K}_c$ 在可观测性图中。对于每个未匹配的ORB K_i 我们搜索与其他关键帧中未匹配点之间的匹配。此匹配操作如III-E节所述进行，并丢弃不满足极线约束的匹配项。ORB对被三角化，为接受新点，会检查双目相机中的正深度、视差、重投影误差和尺度一致性。初始时地图点由两个关键帧观测，但它可能在其他关键帧中匹配，因此会在其余连通关键帧中投影，对应关系搜索如V-D节详细所述。

D. 局部束调整

The 局部*BA*优化当前处理的关$\{K_i\}$，可观测性图$\{\mathcal{K}_c\}$中与之相连的所有关键帧，以及这些关键帧所观测到的所有地{{map points}}。其他观测到这些点但与当前处理的关键帧不相连的关键帧也会被包含在优化过程中，但会保持固定。标记为异常值的数据在优化的中间和结束时被丢弃。有关此优化的更多详细信息，请参阅附录。

当前处理的关键帧之外，观测到这些点但未与之相连的关键帧会被包含在优化中，但会保持固定。标记为异常值的数据在优化的中间和结束时被丢弃。有关此优化的更多详细信息，请参阅附录。

E. 本地关键帧筛选

为了保持紧凑的重建，局部映射尝试检测冗余关键帧并删除它们。这有益处，因为束调整的复杂度会随着关键帧数量的增加而增长，同时因为它能够实现同一环境中的终身运行，因为关键帧数量不会无限制增长，除非场景中的视觉内容发生变化。我们丢弃所有在 $\mathcal{K}_c$ 90%的地图点至少在相同或更精细尺度中的其他三个关键帧中已被看到的关键帧。尺度条件确保地图点保持从它们被测量时精度最高的关键帧。这种策略受Tan等人工作中提出的策略启发 [24], , 在该工作中，关键帧在变化检测过程后会被丢弃。

VII. 回环检测

回环检测线程获取 K_i，即局部映射处理的最后一个关键帧，并尝试检测和闭合回环。步骤如下所述。

A. 循环候选检测

首先，我们计算 K_i 的词袋向量与可观测性图 ($\theta_{min} = 30$) 中所有其邻居之间的相似度，并保留最低分 $s_{\min}$。然后我们查询识别数据库并丢弃所有得分低于 $s_{\min}$ 的关键帧。这与 DBoW2 中的归一化得分操作类似，该得分基于前一张图像计算，但这里我们使用可观测性信息。此外，所有直接连接到 K_i 的关键帧都会被从结果中丢弃。要接受一个循环候选，我们必须检测连续的三个一致的循环候选（在可观测性图中连接的关键帧）。如果有多个外观相似于 K_i 的位置，可能会有多个循环候选。

B. 计算相似度变换

在单目 SLAM 中，地图有七个自由度会发生漂移，包括三个平移、三个旋转和一个缩放因子 [6]。因此，为了闭合循环，我们需要计算当前关键帧 K_i 到循环关键帧 K_l 的相似度变换，该变换会告诉我们循环中累积的错误。这个相似度的计算也将作为循环的几何验证。

我们首先计算当前关键帧中与地图点关联的ORB之间与回环候选关键帧之间的对应关系，按照第三节中解释的步骤 III-E。此时，每个回环候选都拥有3D到3D的对应关系。我们依次对每个候选执行RANSAC迭代，尝试使用Horn的方法找到相似变换 [42]。如果我们找到一个具有足够内点的相似$\mathbf{S}_{il}$，我们会对其进行优化（见附录），然后执行引导式搜索以获取更多对应关系。我们再次对其进行优化，如果$\mathbf{S}_{il}$ 得到足够内点的支持，则接受包含 K_l 的回环。

C. 回环融合

回环校正的第一步是融合重复的地图点，并在可观测性图中插入新的边来连接回环闭合。最初，当前关键帧位姿 $\mathbf{T}_{iw}$ 通过相似变换 $\mathbf{S}_{il}$进行校正，并将此校正传播到所有邻居 K_i，通过连接变换，使回环的两边对齐。所有被回环关键帧及其邻居看到的地图点都被投影到 K_i 及其邻居中，并在投影周围狭窄区域内搜索匹配，如第 V-D节所述。所有匹配的地图点以及那些在 $\mathbf{S}_{il}$ 计算中是内点的地图点都会被融合。所有参与融合的关键帧将在可观测性图中更新它们的边，从而有效地创建连接回环闭合的边。

D. 基本图优化

为了有效闭合回环，我们在第 基本图中执行位姿图优化，该图在 III-D节中描述，将回环闭合误差沿图分布。优化是在相似变换上执行的，以校正 [6]的尺度漂移 。误差项和成本函数在附录中详细说明。优化后，每个地图点会根据观察它的一个关键帧的校正进行变换。

第八章 实验验证

我们在纽卡斯尔 [39], 的机器人大型序列中对该系统进行了广泛的实验验证，评估了系统的整体性能；在图宾根RGB-D基准的16个手持室内序列中 [38], 评估了定位精度、重定位和终身能力；以及在KITTI数据集的10个汽车室外序列中 [40], 评估了实时大规模操作、定位精度和位姿图优化的效率。

我们的系统可实时运行，并精确地在图像采集的帧率下进行处理。所有实验均使用Intel Core i7-4700MQ（4核@2.40GHz）和8Gb RAM进行。ORB-SLAM有三个主要线程，与其他ROS和操作系统的任务并行运行，这给结果带来了一些随机性。因此，在某些实验中，我们报告了多次运行的中位数。

A. 纽卡斯尔数据集的系统性能

纽卡斯尔学院数据集 [39] 包含一个 2.2 公里的序列，由一个在校园及相邻公园中行走的机器人记录。该序列由立体相机以 20 fps 的帧率和分辨率 512×382 记录。它包含多个环路和快速旋转，这使得该序列对单目视觉来说相当具有挑战性。据我们所知，文献中没有其他单目系统能够处理这个整个序列。例如 Strasdat 等人 [7]，尽管能够闭合环路并在大尺度环境中工作，但仅对该序列的一小部分显示了单目结果。

表 II 纽卡斯尔学院中的回环闭合时间

			回环检测 (ms)		回环校正 (s)		
Loop	关键帧	基本图 边	候选人 检测	相似性 变换	融合	基本图 优化	总计 (s)
1	287	1347	4.71	20.77	0.20	0.26	0.51
2	1082	5950	4.14	17.98	0.39	1.06	1.52
3	1279	7128	9.82	31.29	0.95	1.26	2.27
4	2648	12547	12.37	30.36	0.97	2.30	3.33
5	3150	16033	14.71	41.28	1.73	2.80	4.60
6	4496	21797	13.52	48.68	0.97	3.62	4.69

表 I 纽卡斯尔学院中的跟踪和建图时间

线程	操作	中位数 (ms)	Mean (ms)	Std (ms)
跟踪	ORB 提取	11.10	11.42	1.61
	初始位姿估计	3.38	3.45	0.99
	跟踪局部地图	14.84	16.01	9.98
	总计	30.57	31.60	10.39
本地 映射	关键帧插入	10.29	11.88	5.03
	地图点剔除	0.10	3.18	6.70
	地图点创建	66.79	72.96	31.48
	局部BA	296.08	360.41	171.11
	关键帧筛选	8.07	15.79	18.98
	总计	383.59	464.27	217.89

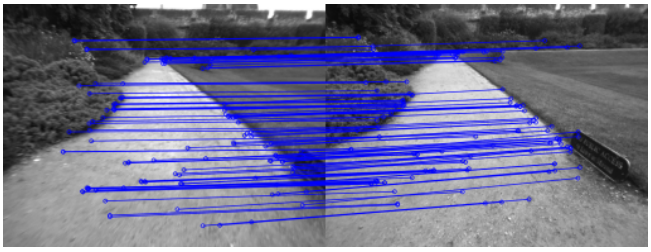


图4. 纽卡斯尔序列中检测到的回环示例。我们绘制了支持相似变换找到的内点对应关系。

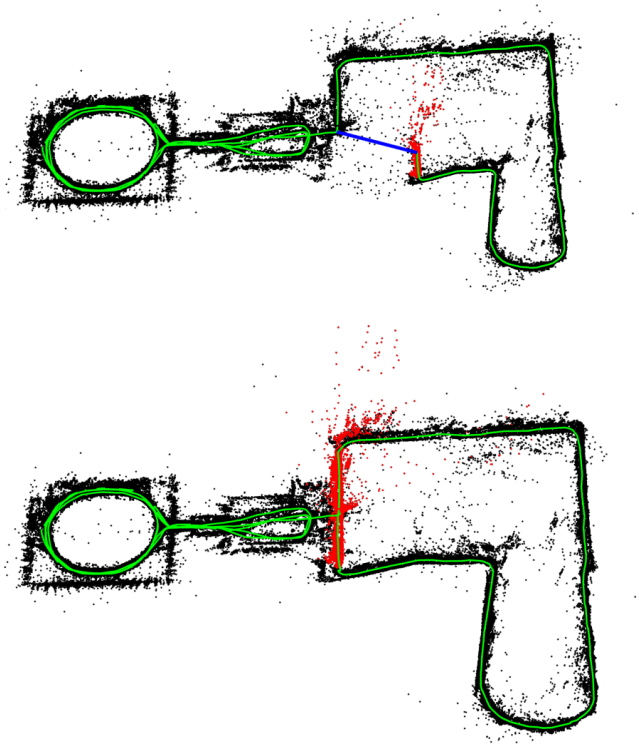


图5. 纽卡斯尔序列中回环闭合前后的地图。回环匹配用蓝色绘制，轨迹用绿色，当前跟踪的局部地图用红色。闭合后，局部地图沿回环两侧扩展。

环路并在大尺度环境中工作，但仅对该序列的一小部分显示了单目结果。

作为我们回环闭合过程的示例，我们在图4 中展示了检测到的回环及其支持相似变换的内点。图5 显示了回环闭合前后的重建结果。红色部分显示了局部地图，闭合后沿回环两侧扩展。处理完整序列后的完整地图显示在图6 中。右侧的大回环未能完美对齐，因为它被相反方向穿越，且位置识别器未能找到回环闭合。

我们已提取了本次实验中每个线程所花费的时间统计。表 I 展示了跟踪和局部建图的结果。跟踪的帧率在25-30Hz左右，是跟踪局部地图时最耗时的任务。如果需要，可以减少这段时间，方法是限制局部地图中包含的关键帧数量。在局部建图线程中，最耗时的任务是局部束调整。局部束调整的时间会因机器人在探索或已知地图区域而变化，因为在探索过程中，如果跟踪插入新关键帧，束调整会被中断，如第 局部*BA* 节所述。如果不需要新关键帧，局部束调整会执行大量预定的迭代次数。

表 二 展示了针对每个6个回环闭合找到的结果。可以看出，回环检测随着关键帧数量的增加呈次线性增长。这是由于

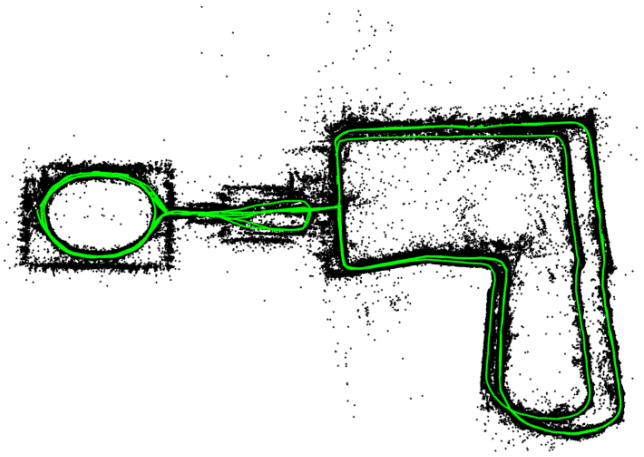


图6. 纽卡斯尔学院全序列的ORB-SLAM重建。右侧较大的回环沿相反方向遍历，且未发现视觉回环闭合，因此它们不能完全对齐。

数据库的高效查询，它仅比较具有共同词语的图像子集，这展示了词袋模型在位置识别中的潜力。我们的基本图包含的关键帧周围边数约为关键帧数量的5倍，这是一个相当稀疏的图。

B. 图宾根*RGB-D*基准中的定位精度

图宾根RGB-D基准 [38] 是一个优秀的数据库，用于评估相机定位的精度，因为它提供了多个具有外部运动捕捉系统获得的精确真值的序列。我们已经丢弃了所有我们认为不适合纯单目SLAM系统的序列，因为它们包含强烈的旋转、无纹理或无运动。

为了比较，我们还执行了新型、直接、半稠密的LSD-SLAM [10] 和PTAM [4] 在基准中。我们还与基准网站为部分序列提供的RGBD-SLAM [43] 生成的轨迹进行比较。为了将ORB-SLAM、LSD-SLAM和PTAM与真值进行比较，我们使用相似性变换对关键帧轨迹进行对齐，因为尺度未知，并测量绝对轨迹误差（ATE） [38]。对于RGBD-SLAM，我们使用刚体变换对齐轨迹，但也进行相似性检查，以确认尺度是否正确恢复。LSD-SLAM从随机深度值初始化并需要时间收敛，因此在与真值比较时，我们丢弃了前10个关键帧。对于PTAM，我们手动选择了两个帧以获得良好的初始化。表III显示了在每个16个选定的序列中5次执行的中值结果。

可以看出ORB-SLAM能够处理所有序列，除了*fr3*无结构纹理远(fr3 nstr tex far)。这是一个平面场景，由于相机轨迹相对于平面的原因，存在两种可能的解释，即 [27]中描述的双重歧义。我们的初始化方法检测到歧义，出于安全考虑拒绝初始化。PTAM有时会选择正确的解，而其他情况下则选择错误的解，此时误差是不可接受的。我们没有注意到LSD-SLAM产生两种不同的重建结果，但该序列中的误差非常高。在其他序列中，PTAM和LSD-SLAM的鲁棒性不如我们的方法，分别在八次和三次序列中丢失目标。

在精度方面，ORB-SLAM和PTAM在开放轨迹中表现相似，而ORB-SLAM在检测大型回环时（如在序列中）能达到更高的精度*fr3*无结构纹理近(fr3 nstr tex near)。最令人惊讶的结果是，PTAM和ORB-SLAM的精度明显优于LSD-SLAM和RGBD-SLAM。可能的原因之一是它们将地图优化简化为位姿图优化，而忽略了传感器测量，而我们则执行束调整，并在传感器测量上联合优化相机和地图，这是解决运动结构恢复问题的黄金标准算法 [2]。我们将在第IX-B节进一步讨论这一结果。另一个有趣的结果是，LSD-SLAM似乎比我们的系统对动态物体更不鲁棒，如在*fr2*带人物的桌子和*fr3*行走*xyz*中所示。

我们注意到RGBD-SLAM在*fr2* 序列中存在尺度偏差，将轨迹对齐到7自由度能显著减少误差。最后应该指出的是，Engel等人 [10] 报告称PTAM在*fr2 xyz* 中的均方根误差为24.28厘米。然而，该论文并未提供足够细节说明这些结果是如何得出的，我们未能复现它们。

C. 在图宾根*RGB-D*基准中的重定位

我们在图宾根RGB-D基准中进行了两次重定位实验。在第一次实验中，我们使用序列的前30秒构建地图*fr2 xyz*，并对每个后续帧进行全局重定位，评估恢复位姿的精度。我们使用PTAM进行相同实验以供比较。图7显示了用于创建初始地图的关键帧、重定位帧的位姿以及这些帧的真值。可以看出，由于其重定位方法缺乏不变性，PTAM只能重定位靠近关键帧的帧。表IV 显示了召回率和相对于真值的误差。ORB-SLAM准确重定位的帧数是PTAM的两倍多。在第二次实验中，我们使用序列*fr3*坐着*xyz* 创建初始地图，并尝试重定位来自*fr3*行走*xyz*的所有帧。这是一个具有挑战性的实验，因为场景中有人移动导致存在大的遮挡。在这里，PTAM没有找到重定位，而我们的系统重定位了78%的帧，如表IV所示。图8 显示了我们系统在这些实验中执行的一些具有挑战性的重定位示例。

D. *L*在*TUM RGB-D*测试平台上的*ifelong*实验 *mark*

之前的重定位实验表明，我们的系统能够从非常不同的视角定位在地图中，并且在中等动态变化下保持稳健。这一特性连同我们的关键帧筛选流程

表III 图宾根RGB-D基准中关键帧定位误差比较 [38]

	绝对关键帧轨迹RMSE (厘米)			
	ORB-SLAM	PTAM	LSD-SLAM	RGBD-SLAM
fr1_xyz	**0.90**	1.15	9.00	1.34 (1.34)
fr2_xyz	0.30	**0.20**	2.15	2.61 (1.42)
fr1_地板	**2.99**	X	38.07	3.51 (3.51)
fr1_桌子	**1.69**	X	10.65	2.58 (2.52)
fr2_360_绑架	3.81	**2.63**	X	393.3 (100.5)
fr2_桌子	**0.88**	X	4.57	9.50 (3.94)
fr3_长_办公室	**3.45**	X	38.53	-
fr3_nstr_tex_far	歧义检测	4.92 / 34.74	18.31	-
fr3_nstr_tex_near	**1.39**	2.74	7.54	-
fr3_str_tex_far	**0.77**	0.93	7.95	-
fr3_str_tex_near	1.58	**1.04**	X	-
fr2_桌子_人	**0.63**	X	31.73	6.97 (2.00)
fr3_坐_xyz	**0.79**	0.83	7.73	-
fr3_坐_半球	**1.34**	X	5.87	-
fr3_行走_xyz	**1.24**	X	12.44	-
fr3_行走_半球	**1.74**	X	X	-

ORB-SLAM、PTAM 和 LSD-SLAM 的结果在每个序列中都是 5 次执行的中位数。轨迹已与 7DoF 真值对齐。RGBD-SLAM 的轨迹来自基准网站，仅适用于 fr1 和 fr2 序列，已与 6DoF 和 7DoF 对齐（括号中的结果）。X 表示跟踪在某些点丢失，系统未处理序列的显著部分。

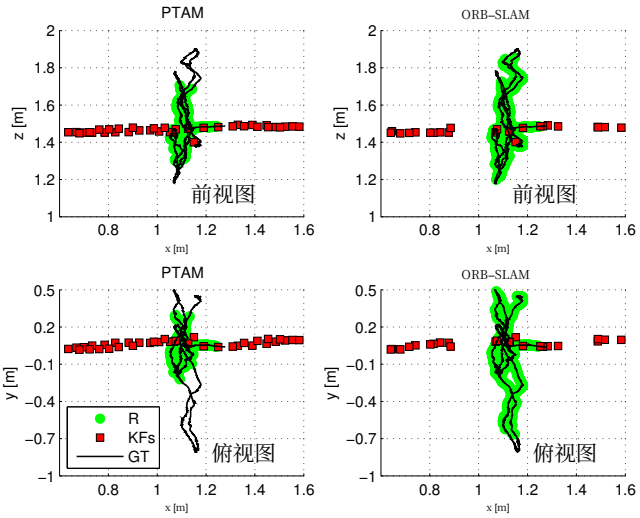


图 7. 在*fr2 xyz*中的重定位实验。地图最初是在序列的前 30 秒内创建的（关键点）。目标是重定位后续帧。我们系统和 PTAM 成功的重定位（R）显示出来。真值（GT）仅显示在需要重定位的帧上。



图 8. 我们系统在重定位实验中成功找到的具有挑战性的重定位示例（严重尺度变化、动态物体）。

允许我们在不同视角和一些动态变化下，在同一个环境中进行终身运行。

在完全静态的场景中，我们的系统能够保持关键帧数量有限，即使相机从不同的视点观察场景也是如此。我们在一个自定义序列中展示了这一点，其中相机在 93 秒内观察同一桌子，但执行一个使视点始终变化的轨迹。我们在图 9 中比较了我们地图中关键帧数量的演变以及 PTAM 生成的那些。可以看到 PTAM 始终插入关键帧，而我们的冗余关键帧剪枝机制使其数量饱和。9。

虽然终身操作静态场景应该是任何 SLAM 系统的要求，但更有趣的情况是动态变化发生时。我们通过连续运行来自*fr3*的动态序列来分析我们的系统在这种场景下的行为：坐着 *xyz*，坐着 半球，坐着 *rpy*，

这可能是由于动态变化。最后图 10(c)显示了根据关键帧存活时间（相对于序列从创建时刻到剩余时间的比例）的直方图。可以看出，大多数关键帧在创建后不久就被剔除程序销毁，只有一小部分存活到实验结束。一方面，这表明我们的系统有一个慷慨的关键帧生成策略，这在执行探索中的突然运动时非常有用。另一方面，系统最终能够选择一小部分具有代表性的关键帧。

表IV 重定位实验结果

系统	初始地图		重定位		
	KFs	RMSE (cm)	召回率 (%)	RMSE (cm)	最大误差 (cm)
fr2_xyz。需要重新定位2769帧					
PTAM	37	0.19	34.9	0.26	1.52
ORB-SLAM	24	0.19	**78.4**	0.38	1.67
fr3行走xyz。需要重新定位859帧					
PTAM	34	0.83	0.0	-	-
ORB-SLAM	31	0.82	**77.9**	1.32	4.95

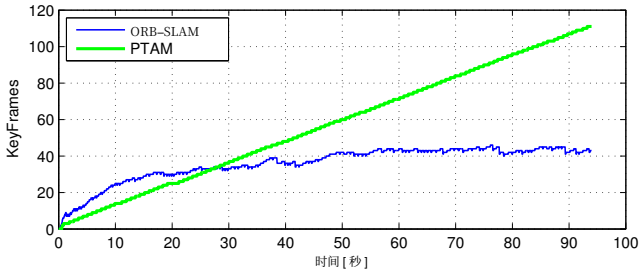


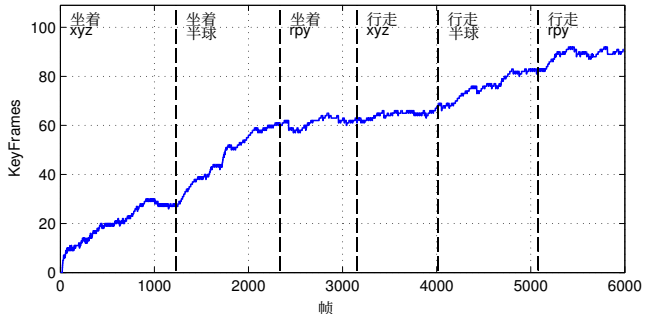
图9. 在静态环境中进行的终身实验，相机从不同视角始终注视同一位置。PTAM持续插入关键帧，而ORB-SLAM能够剪除冗余关键帧并维持有界大小的地图。

由于可能存在动态变化。最后图 10(c) 显示了根据关键帧存活时间（相对于序列从创建时刻到剩余时间的比例）的直方图。可以看出，大多数关键帧在创建后不久就被剔除程序销毁，只有一小部分存活到实验结束。一方面，这表明我们的系统有一个慷慨的关键帧生成策略，这在执行探索中的突然运动时非常有用。另一方面，系统最终能够选择一小部分具有代表性的关键帧。

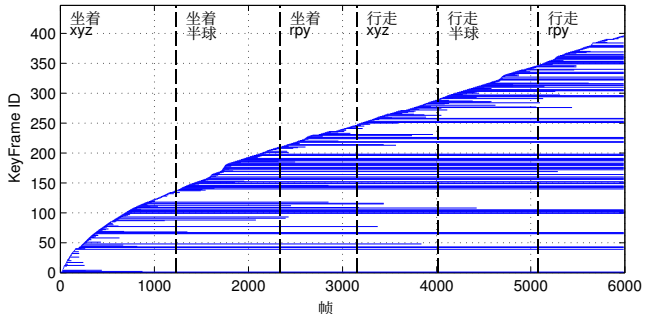
在这些终身实验中，我们证明地图的增长与场景内容相关而与时间无关，并且能够存储场景的动态变化，这对于通过积累环境经验来执行某些场景理解可能很有用。

*E. KITTI*数据集中的大规模与大回环闭合

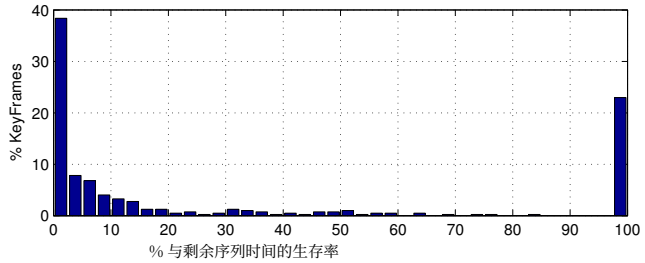
KITTI数据集的里程计基准 [40]包含11个序列，这些序列来自一辆在住宅区周围行驶的汽车，并具有来自GPS和Velodyne激光扫描仪的精确真值。这是一个对单目视觉非常具有挑战性的数据集，因为快速旋转、植被茂密的区域使得数据关联更加困难，且汽车速度相对较高，序列以10 fps录制。我们以实际帧率播放这些序列，ORB-SLAM能够处理所有序列，除了序列01，它是一条高速公路，可跟踪的近景物体很少。序列00、02、05、06、07、09包含回环，



(a) 地图中关键帧数量的演变



(b) 关键帧的创建与销毁。每条水平线对应于一个关键帧，从其创建帧到其销毁



(c) 所有生成的关键帧的生存时间直方图，相对于实验剩余时间

图10。图宾根RGB-D基准中的动态环境终身实验。

被我们的系统正确检测并闭合。序列09包含一个回环，只有在序列末尾的几帧才能被检测到，而我们的系统并不总是能检测到它（提供的结果是它被检测到的执行结果）。

我们的轨迹与真值的定性比较显示在图 11 和图。12。与图宾根RGB-D基准一样，我们将我们系统的关键帧轨迹与真值通过相似变换对齐。我们可以将图 11 和图 12 中的结果与Lim等人最近的单目SLAM方法为序列00、05、06、07和08提供的 [25] 结果进行比较。在他们的图10中。ORB-SLAM对所有这些序列产生的轨迹明显更准确，除了序列08，其中它们似乎漂移较小。

表 V 显示在每个序列中五次执行的关键帧轨迹的中位数均方根误差。我们还提供了地图的维度，以便将误差置于上下文中。结果表明，我们的系统非常精确

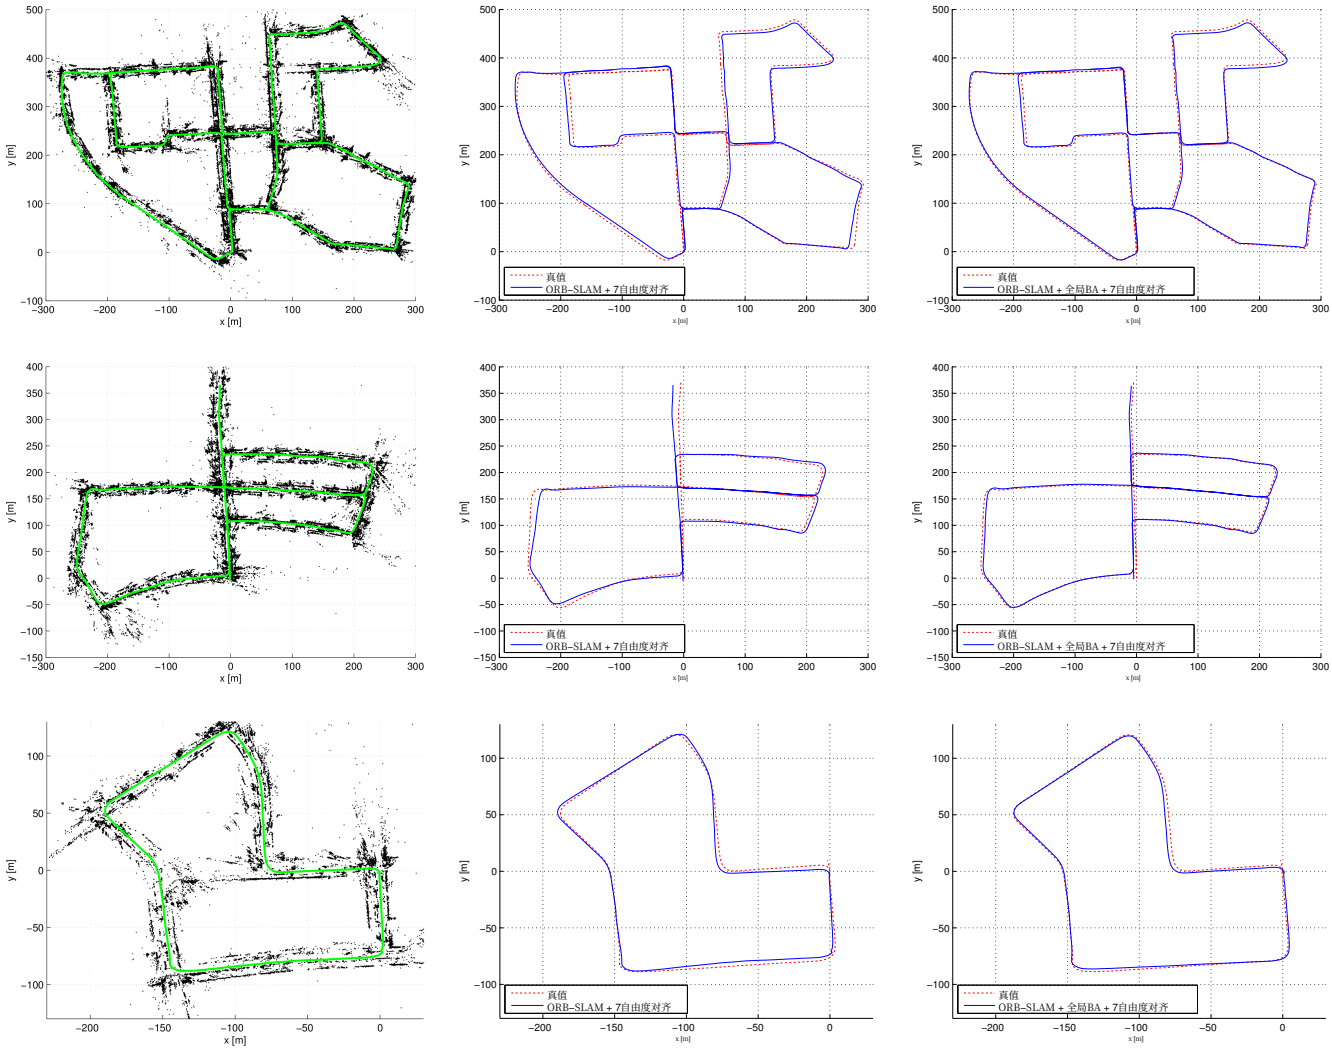
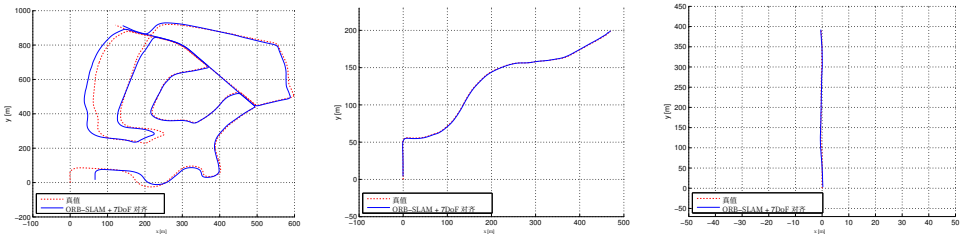
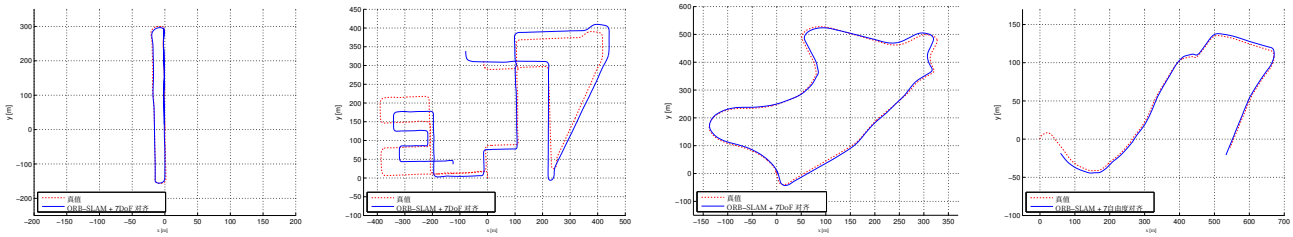


图11. KITTI数据集里程计基准中的序列00、05和07。左：点和关键帧轨迹。中：轨迹和真值。右：完整BA迭代20次后的轨迹。我们系统的输出相当准确，而通过一些BA迭代可以略微改进。



(a) 序列02 (b) 序列 03 (c) 序列 04



(d) 序列 06 (e) 序列 08 (f) 序列 09 (g) 序列 10

图12. KITTI数据集里程计基准中序列02、03、04、06、08、09和10的ORB-SLAM关键帧轨迹。序列08不包含回环，并且漂移（尤其是尺度）未进行校正。

表V KITTI数据集上我们系统的结果。

序列	维度 (m×m)	ORB-SLAM KFs	ORB-SLAM RMSE (m)	+ 全局BA（20次迭代） RMSE (m)	+ 全局BA（20次迭代） 时间BA (s)
KITTI 00	564 × 496	1391	6.68	5.33	24.83
KITTI 01	1157 × 1827	X	X	X	X
KITTI 02	599 × 946	1801	21.75	21.28	30.07
KITTI 03	471 × 199	250	1.59	1.51	4.88
KITTI 04	0.5 × 394	108	1.79	1.62	1.58
KITTI 05	479 × 426	820	8.23	4.85	15.20
KITTI 06	23 × 457	373	14.68	12.34	7.78
KITTI 07	191 × 209	351	3.36	2.26	6.28
KITTI 08	808 × 391	1473	46.58	46.68	25.60
KITTI 09	465 × 568	653	7.62	6.62	11.33
KITTI 10	671 × 177	411	8.68	8.80	7.64

轨迹误差通常约为其维度的1%，有时甚至更低，如在序列03中误差为0.3%，有时更高，如在序列08中误差达到5%。在序列08中不存在回环，漂移无法校正，这清楚地表明了回环闭合对于实现精确重建的必要性。

在本实验中，我们还检查了通过在每个序列结束时执行20次<样式 id='1'>完整BA</样式>迭代，重建效果能提升多少，详情请参见附录。我们注意到，对于存在回环的轨迹，<样式 id='3'>完整BA</样式>的某些迭代能略微提高精度，但在开放轨迹中效果可以忽略不计，这意味着我们系统的输出已经非常精确。在任何情况下，如果需要最精确的结果，我们的算法会提供一组匹配，这些匹配定义了一个强大的相机网络，并提供一个初始猜测，以便<样式 id='5'>完整BA</样式>在几次迭代内收敛。

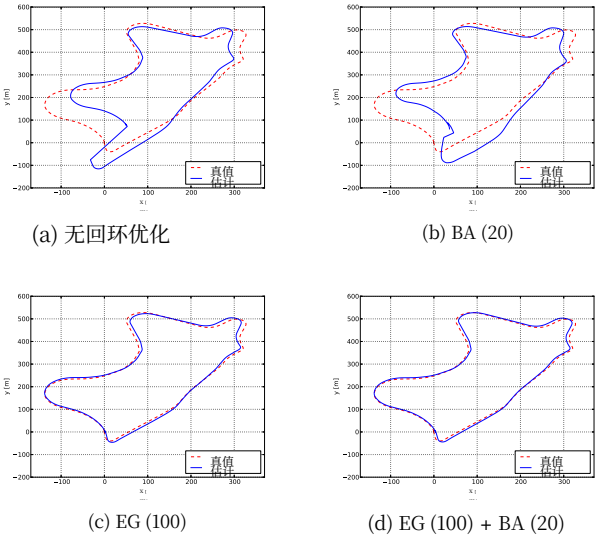
<样式 id='1'>最后我们想展示我们回环闭合方法的有效性以及</样式> $\theta_{\min}$ <样式 id='4'>用于在基本图中包含边的策略。我们选择了序列09（一个非常长的序列，在末尾有一个回环闭合），并在同一执行中评估了不同的回环闭合策略。在</样式><样式 id='6'>表VI</样式><样式 id='8'>中，我们展示了不同情况下关键帧轨迹RMSE和优化所花费的时间：没有回环闭合、直接应用</样式><样式 id='10'>完整BA</样式><样式 id='12'>(20或100次迭代)、仅应用位姿图优化（10次迭代，具有不同数量的边）以及应用位姿图优化和</样式><样式 id='14'>完整BA</样式><样式 id='16'>之后。结果清楚地表明，在回环闭合之前，解与最优解相差太远，导致BA存在收敛问题。甚至

在100次迭代后误差仍然很高。另一方面，关键图优化显示出快速收敛和更精确的结果。可以看出，$\theta_{\min}$ 的选择对精度没有显著影响，但减少边的数量可以显著减少时间。在位姿图优化后执行额外的BA可以略微提高精度，但会显著增加时间。

表 VI KITTI 09 中的回环关闭策略比较

方法	时间 (s)	位姿图边数	均方根误差 (m)
-	-	-	48.77
BA (20)	14.64	-	49.90
BA (100)	72.16	-	18.82
EG (200)	0.38	890	8.84
EG (100)	0.48	1979	8.36
EG (50)	0.59	3583	8.95
EG (15)	0.94	6663	8.88
EG (100) + BA (20)	13.40	1979	7.22

第一行显示未进行回环优化的结果。括号内的数字对于束调整（BA）表示Levenberg-Marquardt（LM）迭代次数，对于基本图（EG）则是构建基本图所需的 $\theta_{\min}$ 。所有基本图优化均执行10次LM迭代。



(a) 无回环优化 (b) BA (20)

(c) EG (100) (d) EG (100) + BA (20)

图13. KITTI 09中不同回环优化策略的比较。

IX. 结论与讨论

A. 结论

在这项工作中，我们介绍了一种新的单目SLAM系统，详细描述了其构建模块，并在公开数据集上进行了详尽的评估。我们的系统已证明能够处理来自室内和室外场景以及汽车、机器人和手持运动的序列。该系统的精度在小型室内场景中通常低于1厘米，在大型室外场景中为几米（一旦我们与真值对齐比例）。

目前，Klein 和 Murray 开发的 PTAM 被认为是实时从单目视频获取的最精确的 SLAM 方法。PTAM 的后端是束调整，众所周知，束调整是离线运动结构恢复问题的黄金标准方法，这一点并非巧合 [4] 。PTAM 的主要成功之一，以及 Mouragnon 早期的相关工作，是将这些知识引入机器人 SLAM 社区，并展示了其实时性能 [2]。

我们工作的主要贡献是扩展 PTAM 的通用性，使其能够处理该系统难以处理的场景。为此，我们从零开始设计了一个新的单目 SLAM 系统，其中包含一些新的思想和算法，但也结合了近年来开发的优秀成果，例如 Galvez-Lopez 和 Tardos 的回环检测´、Strasdat 等人的回环闭合程序和可观测性图´、Kuemmerle 等人的优化框架 g2o´以及 Rubble 等人的 ORB 特征 [5], 。据我们所知，没有其他系统能够在如此多种不同的场景中表现出如此高的精度。因此，我们的系统是目前最可靠和最完整的单目 SLAM 解决方案。我们新颖的关键帧生成和删除策略，允许每隔几帧创建关键帧，当这些关键帧被认为是冗余时最终会被删除。这种灵活的地图扩展在条件较差的探索轨迹中非常有用，即接近纯旋转或快速运动的情况。当在相同环境中重复运行时，地图仅当场景的视觉内容发生变化时才会增长，从而存储其不同的视觉外观历史记录。通过分析这段历史记录，可以提取出长期映射的有趣结果 [6], [7], 。

最后我们还有力地证明了ORB特征具有足够的识别能力，能够实现从严重视角变化下的位置识别。此外它们提取和匹配的速度非常快（无需多线程或GPU加速），因此能够实现实时精确跟踪和建图。

B. 稀疏/特征方法与密集/直接方法

近年来如DTAM [44] 和LSD-SLAM [10] 等实时单目SLAM算法能够对环境进行密集或半密集重建，同时通过直接优化图像像素强度来定位相机。这些直接方法无需特征提取，因此避免了相应的伪影。它们对模糊、低纹理环境和高频纹理（如沥青 [45]）也更为鲁棒。与我们的系统或PTAM的稀疏点云地图相比，它们的更密集重建对于除相机定位之外的其他任务可能更有用。

然而直接方法也有其自身的局限性。首先这些方法假设表面反射模型，在真实场景中会产生自身的伪影。光度一致性限制了匹配的基线，通常比特征允许的基线更窄。这对重建精度有很大影响，重建精度需要较宽的基线观测来减少深度不确定性。如果直接方法没有被正确建模，它们会受卷帘快门、自动增益和自动曝光伪影（如在图宾根RGB-D基准中）的严重影响。最后由于直接方法通常计算量很大，地图只是像DTAM那样逐步扩展，或者像LSD-SLAM那样将地图优化简化为位姿图，丢弃所有传感器测量数据。

相比之下，基于特征的方法能够匹配具有宽基线的特征，这得益于它们对视角和光照变化的良好不变性。束调整联合优化了相机位姿和点，以匹配传感器测量值。在结构和运动估计的背景下，Torr 和 Zisserman [46] 已经指出了基于特征方法相对于直接方法的优势。在这项工作中，我们提供了实验证据（见第 VIII-B节）表明，基于特征的方法在实时SLAM中具有更高的精度。我们认为，单目SLAM的未来应该结合这两种方法的最佳之处。

C. 未来工作

我们的系统精度仍可通过在跟踪中包含无穷远点来提升。这些点因视差不足而未被观察到，且我们的系统未将其包含在地图中，但它们对相机旋转提供了非常丰富的信息 [21]。

另一个开放方向是将我们系统的稀疏地图升级为更密集且更有用的重建。得益于我们的关键帧选择，关键帧构成了对环境的高度紧凑的总结，具有极高的位姿精度和丰富的共视信息。因此，ORB-SLAM稀疏地图可以作为一个极好的初始猜测和骨架，在此基础上可以构建出场景的密集且精确的地图。这方面的一项初步工作在 [47]中提出。

附录 非线性优化

- 束调整（BA） [1]:
  地图点的3D位置 $\mathbf{X}_{w,j} \in \mathbb{R}^3$ 以及关键帧位姿$\mathbf{T}_{iw} \in$ SE(3)，其中 w 表示世界参考系，通过最小化与匹配特征点 $\mathbf{x}_{i,j} \in \mathbb{R}^2$的重新投影误差来进行优化。在关键帧 i 中观测地图点 j 的误差项为:

$$\mathbf{e}_{i,j} = \mathbf{x}_{i,j} - \pi_i(\mathbf{T}_{iw}, \mathbf{X}_{w,j}) \tag{5}$$

  π_i 在哪里是投影函数:

$$\begin{aligned} \pi_i(\mathbf{T}_{iw}, \mathbf{X}_{w,j}) &= \begin{bmatrix} f_{i,u}\frac{x_{i,j}}{z_{i,j}} + c_{i,u} \\ f_{i,v}\frac{y_{i,j}}{z_{i,j}} + c_{i,v} \end{bmatrix} \\ \begin{bmatrix} x_{i,j} & y_{i,j} & z_{i,j} \end{bmatrix}^T &= \mathbf{R}_{iw}\mathbf{X}_{w,j} + \mathbf{t}_{iw} \end{aligned} \tag{6}$$

  其中 $\mathbf{R}_{iw} \in$ SO(3) 和 $\mathbf{t}_{iw} \in \mathbb{R}^3$ 分别是 $\mathbf{T}_{iw}$ 的旋转和平移部分，而 $(f_{i,u},f_{i,v})$ 和 $(c_{i,u},c_{i,v})$ 是与相机 i相关的焦距和主点。需要最小化的代价函数为:

$$C = \sum_{i,j} \rho_h(\mathbf{e}_{i,j}^T \mathbf{\Omega}_{i,j}^{-1} \mathbf{e}_{i,j}) \tag{7}$$

  在哪里 ρ_h 是Huber鲁棒代价函数，$\mathbf{\Omega}_{i,\ j} = \sigma_{i,\ j}^2 \mathbf{I}_{2\times 2}$ 是关键点检测时关联的协方差矩阵。在完整*BA*(用于在第四节中解释的地图初始化和在第八节E中的实验)的情况下，我们优化所有点和关键帧，第一个关键帧除外，它作为原点保持固定。在局部*BA*(参见第六节D)中，局部区域内的所有点都会被优化，而一部分关键帧保持固定。在位姿优化或仅运动*BA*中，(参见第五节)，所有点都保持固定，仅优化相机位姿。

- 在Sim(3)约束下的位姿图优化 [6]：给定一个具有二进制边的位姿图（参见第七节D），我们定义边的误差为：

$$\mathbf{e}_{i,j} = \log_{\mathrm{Sim}(3)}(\mathbf{S}_{ij}\,\mathbf{S}_{jw}\,\mathbf{S}_{iw}^{-1}) \tag{8}$$

其中 $\mathbf{S}_{ij}$ 是两个关键帧之间的相对Sim(3)变换，该变换基于位姿图优化之前计算的SE(3)位姿计算得出，并将比例因子设置为1。在回环检测边的情况下，此相对变换使用Horn的方法 [42]。 The $\log_{\mathrm{Sim}3}$ [48] 变换到切空间，因此误差是一个向量在 $\mathbb{R}^7$。目标是最小化Sim(3)关键帧位姿的成本函数：

$$C = \sum_{i,j}(\mathbf{e}_{i,j}^T \mathbf{\Lambda}_{i,j} \mathbf{e}_{i,j}) \tag{9}$$

其中 $\mathbf{\Lambda}_{i,j}$ 是边的信息矩阵，正如 [48], 中我们将其设置为单位矩阵。我们固定回环检测关键帧以固定7个测量自由度。尽管此方法是对 完整*BA*的粗略近似，但我们通过第 VIII-E部分实验证明，它比BA具有显著更快和更好的收敛性。

- 相对Sim(3)优化：
给定关键帧 1 和关键帧 2之间的 n 匹配 $i \Rightarrow j$ (关键点和其关联的3D地图点)，我们希望优化相对Sim(3)变换 $\mathbf{S}_{12}$ (见第 VII-B部分)以最小化两图像中的重投影误差：

$$\begin{aligned} \mathbf{e_1} &= \mathbf{x}_{1,i} - \pi_1(\mathbf{S}_{12}, \mathbf{X}_{2,j}) \\ \mathbf{e_2} &= \mathbf{x}_{2,j} - \pi_2(\mathbf{S}_{12}^{-1}, \mathbf{X}_{1,i}) \end{aligned} \tag{10}$$

以及需要最小化的代价函数是：

$$C = \sum_n \left(\rho_h(\mathbf{e}_1^T \mathbf{\Omega}_{1,i}^{-1} \mathbf{e}_1) + \rho_h(\mathbf{e}_2^T \mathbf{\Omega}_{2,j}^{-1} \mathbf{e}_2)\right) \tag{11}$$

其中 $\mathbf{\Omega}_{1,i}$ 和 $\mathbf{\Omega}_{2,i}$ 是与图像1和图像2中检测到的关键点的尺度相关的协方差矩阵。在此优化中，点被固定了。

参考文献

[1] B. Triggs, P. F. McLauchlan, R. I. Hartley, 和 A. W. Fitzgibbon, “束调整：现代综合方法，” 在 *视觉算法：理论与实践*, 2000, 第298–372页。[2] R. Hartley 和 A. Zisserman, *多视图几何学（计算机视觉）*, 第2版。剑桥大学出版社, 2004。[3] E. Mouragnon, M. Lhuillier, M. Dhome, F. Dekeyser, 和 P. Sayd, “实时定位与三维重建，” 在 *IEEE计算机学会计算机视觉与模式识别会议*, 第1卷, 2006, 第363–370页。[4] G. Klein 和 D. Murray, “用于小型增强现实工作空间的并行跟踪与映射，” 在 *IEEE与ACM国际混合现实与增强现实研讨会 (ISMAR)*, 日本奈良, 2007年11月, 第225–234页。[5] D. G´alvez-L´opez 和 J. D. Tard´os, “用于图像序列快速位置识别的二进制词包，” *机器人技术汇刊*, 第28卷, 第5期, 第 1188–1197 页 , 2012。[6] H. Strasdat, J. M. M. Montiel, 和 A. J. Davison, “尺度漂移感知的大规模单目SLAM。” 在 *机器人学：科学与系统 (RSS)*, 西班牙萨拉戈萨, 2010年6月。[7] H. Strasdat, A. J. Davison, J. M. M. Montiel, 和 K. Konolige, “双窗口优化用于恒定时间的视觉SLAM，” 在 *IEEE国际计算机视觉会议 (ICCV)*, 西班牙巴塞罗那, 2011年11月, 第2352–2359页。

[8] C. Mei、G. Sibley和P. Newman, “无需地点的回环检测，” 在 IEEE/RSJ 国际机器人与系统会议（ IROS ），台北，台湾，2010 年 10月，第3738–3744页。[9] E. Rublee、V. Rabaud、K. Konolige和 G. Bradski, “ORB：SIFT或SURF的有效替代方案，” 在IEEE国际计算机视觉会议（ICCV），巴塞罗那，西班牙，2011年11月，第2564–2571页。[10] J. Engel、T. Sch¨ops和D. Cremers, “LSD-SLAM：大规模直接单目SLAM，” 在欧洲计算机视觉会议（ECCV），苏黎世，瑞士，2014年9月，第834–849页。 R. Mur-Artal和J. D. Tard´os, [11] “基于关键帧的SLAM中的快速重定位和回环检测，” 在IEEE国际机器人与自动化会议（ICRA），香港，中国，2014年6月，第846–853页。 ——, [12] “ORB-SLAM：跟踪和映射可识别特征，” 在机器人科学与系统会议（RSS）的MVIGRO研讨会，伯克利，美国，2014年7月。[13] B. Williams、M. Cummins、J. Neira、P. Newman、I. Reid和J. D. Tard´os, “单目SLAM中回环检测技术的比较，” 机器人与自主系统, 第57卷，第12期，第1188–1197页，2009年。[14] D. Nister和H. Stewenius, “使用词汇树的可扩展识别，” 在IEEE计算机学会计算机视觉与模式识别会议（CVPR），第2卷，纽约市，美国，2006年6月，第2161–2168页。[15] M. Cummins和P. Newman, “使用FAB-MAP 2.0的大规模外观SLAM，” 国际机器人研究杂志，第30卷，第9期，第1100–1123页，2011年。[16] M. Calonder、V. Lepetit、C. Strecha和P. Fua, “BRIEF：二进制鲁棒独立基本特征，” 在欧洲计算机视觉会议（ECCV），赫罗诺索斯，希腊，2010年9月，第778–792页。[17] E. Rosten和T. Drummond, “用于高速角点检测的机器学习，” 在欧洲计算机视觉会议（ECCV），格拉茨，奥地利，2006年5月，第430–443页。[18] H. Bay、T. Tuytelaars和L. Van Gool, “SURF：加速鲁棒特征，” 在欧洲计算机视觉会议（ECCV），格拉茨，奥地利，2006年5月，第404–417页。[19] D. G. Lowe, “从尺度不变关键点获取独特图像特征，” 国际计算机视觉杂志，第60卷，110，2004年2月，第91页。[20] A. J. Davison、I. D. Reid、N. D. Molton和O. Stasse, “MonoSLAM：实时单相机SLAM，” IEEE模式分析与机器智能汇刊，第29卷，第6期，第1052–1067页，2007年。[21] J. Civera、A. J. Davison和J. M. M. Montiel, “单目SLAM的逆深度参数化，” IEEE机器人汇刊，第24卷，第5期，第932–945页，2008年。[22] C. Forster、M. Pizzoli和D. Scaramuzza, “SVO：快速半直接单目视觉里程计，” 在IEEE国际机器人与自动化会议论文集，香港，中国，2014年6月，第15–22页。[23] O. D. Faugeras和F. Lustman, “片状平面环境中的运动和运动结构恢复，” 国际模式识别与人工智能杂志，第2卷，第3期，第485–508页，1988年。[24] W. Tan、H. Liu、Z. Dong、G. Zhang和H. Bao, “动态环境中的鲁棒单目SLAM，” 在IEEE混合与增强现实国际会议（ISMAR），阿德莱德，澳大利亚，2013年10月，第209–218页。[25] H. Lim、J. Lim和H. J. Kim, “大规模环境中实时6-自由度单目视觉SLAM，” 在IEEE国际机器人与自动化会议（ICRA），香港，中国，2014年6月，第1532–1539页。[26] D. Nist´er, “五点相对位姿问题的有效解决方案，” IEEE模式分析与机器智能汇刊，第26卷，第6期，第756–770页，2004年。[27] H. Longuet-Higgins, “从两个透视投影重建平面表面，” 伦敦皇家学会哲学汇刊B。生物科学，第227卷，第1249期，第399–410页，1986年。[28] P. H. Torr、A. W. Fitzgibbon和A. Zisserman, “从未校准图像序列恢复结构和运动中的退化问题，” 国际计算机视觉杂志，第32卷，第1期，第27–44页，1999年。[29] A. Chiuso、P. Favaro、H. Jin和S. Soatto, “随时间因果集成的运动结构恢复，” IEEE模式分析与机器智能汇刊，第24卷，第4期，第523–535页，2002年。[30] E. Eade和T. Drummond, “可扩展单目SLAM，” 在IEEE计算机学会计算机视觉与模式识别会议（CVPR），第1卷，纽约市，美国，2006年6月，第469–476页。[31] H. Strasdat、J. M. M. Montiel和A. J. Davison, “视觉SLAM：为什么需要滤波器？” 图像与视觉计算，第30卷，第2期，第65–77页，2012年。

[32] G. Klein 和 D. Murray, “提高基于关键帧的 SLAM 的敏捷性,” 在 欧洲计算机视觉会议 *(ECCV)*, 马赛, 法国, 2008 年 10 月, pp. 802–815. [33] K. Pirker, M. Ruther, 和 H. Bischof, “CD SLAM-连续动态世界中的定位和地图构建,” 在 *IEEE/RSJ* 国际智能机器人与系统会议 *(IROS)*, 旧金山, 美国, 2011 年 9 月, pp. 3990–3997. [34] S. Song, M. Chandraker, 和 C. C. Guest, “并行、实时单目视觉里程计," 在 *IEEE* 国际机器人与自动化会议 *(ICRA)*, 2013, pp. 4698–4705. [35] P. F. Alcantarilla, J. Nuevo, 和 A. Bartoli, “非线性尺度空间中加速特征的快速显式扩散," 在 英国机器视觉会议 *(BMVC)*, 布里斯托, 英国, 2013. [36] X. Yang 和 K.-T. Cheng, “LDB: 一种用于可扩展移动设备增强现实的高速特征," 在 *IEEE* 国际混合与增强现实会议 *(ISMAR)*, 2012, pp. 49–57. [37] R. Kuemmerle, G. Grisetti, H. Strasdat, K. Konolige, 和 W. Burgard, “g2o: 一个通用的图优化框架 ," 在 *IEEE* 国际机器人与自动化会议 *(ICRA)*, 上海, 中国, 2011 年 5 月, pp. 3607–3613. [38] J. Sturm, N. Engelhard, F. Endres, W. Burgard, 和 D. Cremers, “ RGB-D SLAM 系统评估基准," 在 *IEEE/RSJ* 国际智能机器人与系统会议 *(IROS)*, 维拉莫拉, 葡萄牙, 2012 年 10 月, pp. 573–580. [39] M. S mith, I. Baldwin, W. Churchill, R. Paul, 和 P. Newman, “新的大学视觉和激光数据集," 国际机器人研究杂志, 第 28 卷, 第 5 期, pp. 595–599, 2009. [40] A. Geiger, P. Lenz, C. Stiller, 和 R. Urtasun, “视觉与机器人学相遇: KITTI 数据集," 国际机器人研究杂志, 第 32 卷, 第 11 期, pp. 1231–1237, 2013. [41] V. Lepetit, F. Moreno-Noguer, 和 P. Fua, “EPnP: PnP 问题的准确 O(n) 解," 国际计算机视觉杂志, 第 81 卷, 第 2 期 , pp. 155–166, 2009. [42] B. K. P. Horn, “ 使用单位四元数求解绝对姿态的闭式解," 美国光学学会 *A* 杂志, 第 4 卷, 第 4 期, pp. 629–642, 1987. [43] F. Endres, J. Hess, J. Sturm, D. Cremers, 和 W. Burgard, “使用 RGB-D 相机的三维地图构建," 机器人技术汇刊, 第 30 卷, 第 1 期, pp. 177–187, 2014. [44] R. A. Newcombe, S. J. Lovegrove, 和 A. J. Davison, “DTAM: 实时密集跟踪和地图构建," 在 *IEEE* 国际计算机视觉会议 *(ICCV)*, 巴塞罗那, 西班牙, 2011 年 11 月, pp. 2320–2327.[45] S. Lovegrove, A. J. Davison, 和 J. Ibanez-Guzm´an, “从后视摄像头获取精确的视觉里程计," 在 *IEEE* 智能车辆会议 *(IV)*, 2011, pp. 788–793. [46] P. H. Torr 和 A. Zisserman, “基于特征的结构和运动估计方法," 在 视觉算法: 理论与实践. Springer, 2000, pp. 278–294. [47] R. Mur-Artal 和 J. D. Tardos, “从高精度基于特征的单目 SLAM 获得概率半密集地图," 在 机器人学: 科学与系统 *(RSS)*, 罗马, 意大利, 2015 年 7 月. [48] H. Strasdat, “视觉 SLAM 的局部精度和全局一致性," 博士论文, 伦敦帝国学院, 2012 年 10 月.



Ra´ul Mur Artal 于1989年出生于西班牙萨拉戈萨。他于2012年获得工业工程学位（工业自动化与机器人技术方向），2013年获得系统工程与计算机工程理学硕士学位，均毕业于萨拉戈萨大学。目前，他在该校I3A机器人、感知与实时研究组攻读哲学博士学位。

他的研究方向包括视觉定位和长期地图构建。



J. M . M. Montiel 于1967年出生于西班牙阿尔内多。他于1992年和1996年分别获得西班牙萨拉戈萨大学的电气工程理学硕士和哲学博士学位。他目前是萨拉戈萨大学信息与系统工程系的正教授，负责感知与计算机视觉研究项目和课程。他当前的研究兴趣包括刚性及非刚性环境的实时视觉定位和语义地图构建，以及

这项技术已应用于机器人和非机器人应用领域。Mart´ınez Montiel教授是I3A机器人、感知与实时研究组成员。他获得多项西班牙MEC资助，用于在牛津大学（英国）和伦敦帝国学院（英国）进行科研。



Juan D. Tard´os 于1961年出生于西班牙胡尔卡。他于1985年和1991年分别获得电气工程理学硕士和哲学博士学位，均毕业于西班牙萨拉戈萨大学。他是萨拉戈萨大学Departamento de Inform´atica e Ingenier´ıa de Sistemas的教授，负责机器人、计算机视觉和人工智能课程。他的研究兴趣包括SLAM、感知与移动机器人。Tard´os教授是I3A机器人、感知与实时研究组成员