This ICCV paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

本文档由 funstory.ai 的开源 PDF 翻译库 BabelDOC v0.6.2 (https://github.com/funstory-ai/BabelDOC) 翻译，本仓库正在积极的建设当中，欢迎 star 和关注。

纹理场：在函数空间中学习纹理表示

迈克尔·奥克斯勒[1,2] 拉尔斯·梅施德[1] 迈克尔·尼迈耶尔[1] 蒂洛·施特劳斯[2†] 安德烈亚斯·盖格[1]自主视觉小组，智能系统研究所和蒂宾根大学·[2]ETAS股份公司，博世集团，斯图加特

[1]{firstname.lastname}@tue.mpg.de [†]{firstname.lastname}@etas.com

摘要

近年来，基于学习的三维物体重建取得了长足的进步。与此同时，人们提出了能够生成高度逼真图像的生成模型。然而，尽管在这些密切相关任务中取得了成功，三维物体的纹理重建却很少受到研究社区的关注，最先进的方法要么局限于相对较低的分辨率，要么受到实验设置的约束。这些限制的主要原因在于，常见的纹理表示方式效率低下或难以与现代深度学习技术兼容。在本文中，我们提出了纹理场（Texture Fields），这是一种基于回归连续三维函数的新型纹理表示方法，该函数由神经网络参数化。我们的方法绕过了形状离散化和参数化等限制因素，因为所提出的纹理表示与三维物体的形状表示无关。我们证明，纹理场能够表示高频纹理，并自然地与现代深度学习技术融合。实验表明，在条件纹理重建方面，纹理场与最先进方法相比具有优势，并能够学习用于纹理化未见过的三维模型的概率生成模型。我们相信，纹理场将成为下一代生成三维模型的重要构建模块。

1. 简介

三维重建是计算机视觉的一项宏伟目标。最近，视觉领域见证了单图像三维重建等重建任务上的显著进展 [6, 7, 9, 13, 23, 25, 43, 45] 以及生成三维物体 [4, 32, 46] 利用基于学习的技术，通过结合先验知识来解决歧义。然而，以往关于基于学习的三维重建的工作主要集中于几何形状重建问题。相比之下，三维物体的纹理重建从社区中得到的关注较少。

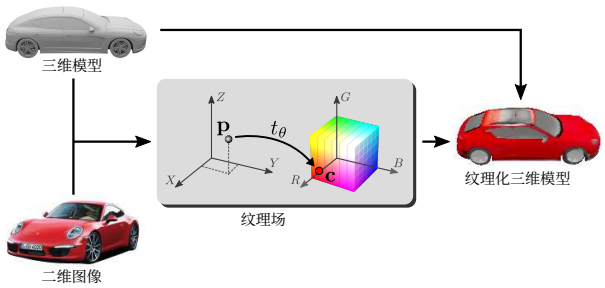


图1：纹理场接收一个三维形状（可选地）和一个对象的单个二维图像作为输入，学习一个连续函数 t_θ，该函数将任何三维点 p 映射到颜色值 c，从而能够预测精确纹理的三维模型。

从单图像进行纹理重建的先前方法在纹理信息的表示方式上有所不同。一些近期的工作 [39, 42] 提出了用于彩色三维重建的体素表示。不幸的是，然而，由于体素表示的计算成本随分辨率呈立方级增长，体素化通常限制在相对较低的分辨率（通常是 32^3 或 64^3），因此无法表示高频细节。纹理的另一种表示方式包括一个二维纹理贴图和一个参数化网格，使用UV映射将形状流形上的一个点映射到纹理贴图中的像素。然而，基于网格表示的当前方法通常假设拓扑已知和预定义的模板网格，这限制了这些方法只能应用于特定的物体类别，例如鸟类 [18] 或人脸 [8, 36]。在一般情况下，对于没有模板网格的任意形状预测纹理仍然是一个未解决的问题。

贡献：上述方法的主要限制因素在于它们的纹理表示，这些表示要么不允许进行高分辨率重建，要么严重依赖于特定任务的形状参数化，从而限制了这些方法的通用性。相比之下，理想的纹理表示应该独立于形状表示（体素、点云、网格等），并且能够表示高频细节。为了实现这一目标，我们

提出纹理场作为纹理的一种新表示方法。我们的核心思想是学习一个连续函数，用于在三维空间中表示纹理信息，见图1。通过使用深度神经网络对该函数进行参数化，我们能够将这种表示集成到用于三维纹理重建的深度学习管道中，该管道可以进行端到端训练。[1]

我们的实验在多种3D物体类别上表明，纹理场能够从单图像中预测高频纹理信息。我们将我们的方法与最先进的3D重建方法相结合[25], 产生了一种联合重建物体三维形状和纹理的方法。除了条件实验，我们还把我们的新型纹理表示扩展到生成设置，并展示了在给定3D形状模型和潜在纹理码的情况下进行纹理合成的初步结果。我们还进行了不同物体之间的纹理迁移实验以及潜在纹理空间中的插值实验，这些实验表明我们的生成模型学习到了有用的纹理表示。

2. 相关工作

我们现在简要讨论与单图像三维重建、使用3D知识的生成式图像建模以及连续表示学习最相关的工作。

2.1. 单图像重建

近年来，从单图像中进行形状三维重建取得了巨大进展 [6, 7, 9, 13, 23, 25, 43, 45]。

体素： Tulsiani 等人 [42] 提出了一种基于体素的纹理表示方法，用于学习基于射线一致性和多视图监督的彩色三维重建。最近，Sun 等人 [39] 结合了二维到三维的外观流估计和体素颜色回归，以监督方式学习重建彩色体素化。不幸的是，然而，由于计算和内存限制，体素表示在分辨率上受到严重限制。相比之下，我们的连续方法不需要离散化，因此在我们的第 4节实验评估中，与体素表示相比，结果产生了更多细节。

点云： 近年来，新视角合成[27, 31, 40, 48] 已被用于从单张图像中重建彩色点云。通过结合新视角合成和深度估计，所提出的方法将 [40]预测图像重新投影到彩色点云中。在[27], 点云是使用多视图立体算法从一组新视角重建的。不幸的是，基于点云的表示是稀疏的。虽然可以从点云中提取密集网格表示，但重建的形状通常无法与最先进的3D重建方法相媲美，并且推断缺失的纹理信息需要额外的后处理步骤。相反，我们的方法允许推断3D空间中任何位置的外观，并且可以与任意形状表示结合使用。

网格：基于网格的方法依赖于特定类别的模板模型和刚性纹理参数化 [8, 18, 36]。相比之下，我们的重建方法可以表示任意网格的纹理，而无需特定类别模板模型的 UV 纹理图。请注意，为任意网格模型确定适当的 UV 映射是一个非平凡问题，通常通过生成图集的各种启发式算法来解决。我们方法的优势在于，我们通过将纹理与形状表示分离来绕过网格参数化。

2.2. 生成模型

近期研究表明，图像生成方法 [3, 11, 19, 20, 24, 30, 47] 可以通过利用生成形状的3D知识[1, 2, 49]来改进。Alhaija等人 [2] 提出了一种模型，该模型学习将内在属性（深度、法线、材质）转换为RGB图像。Zhu等人[49] 通过在无监督设置中解耦形状、纹理和姿态，学习预测2D图像中的3D几何形状以及纹理信息。与这些基于图像的方法不同，我们直接预测整个3D物体的纹理。

2.3. 连续表示

最近，参数化连续函数因3D形状重建而受到欢迎。几项工作[6, 17, 25, 28] 提出将3D重建表述为学习一个参数化神经网络的3D空间中的连续占用函数或符号距离场。此外，在[10], 中，用于生成2D图像的颜色值的连续函数被使用。在本工作中，我们扩展了在函数空间中学习表示的概念，以重建和生成3D物体的纹理信息。

3. 方法

本节描述了所提出的纹理场表示方法，并展示了如何将其应用于条件和非条件纹理合成任务。

3.1. 纹理场

近年来，三维重建方法 [6, 25, 28] 将三维形状表示为占用概率或表面距离的连续函数。与基于点、体素或网格的表示方法不同，这些方法不依赖于固定的离散化，因此它们构成了表示外观信息的理想基础。

[1] 也参见 [35]，其中提出了类似的想法的并发工作。

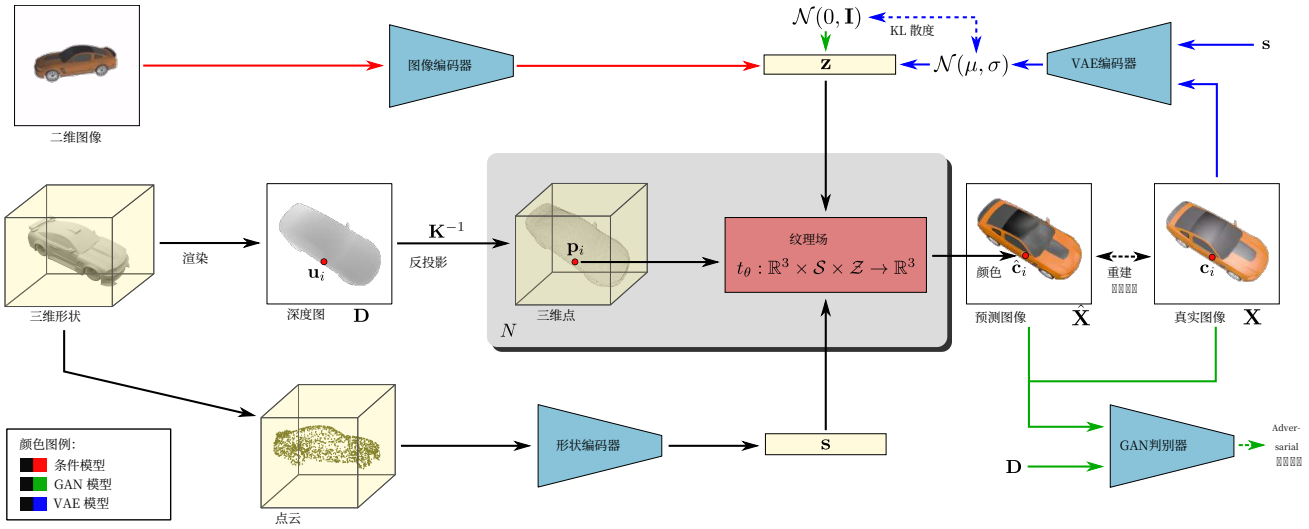


图 2：模型概述。彩色箭头显示了代表条件模型、GAN 模型和 VAE 模型的替代路径。蓝色和红色框表示我们模型的可训练组件，它们分别通过神经网络参数化。对象的 3D 形状被编码为固定长度的向量表示 s。此外，我们从随机选择的视点渲染深度图 D，并通过将所有 N 图像像素 u_i 逆投影到 3D 空间中，获得相应的 3D 点 p_i。重建损失最小化纹理场 $\hat{\mathrm{c}}_i = t_\theta(\mathrm{p}_i, \mathrm{s}, \mathrm{z})$ 预测的像素颜色与真实像素颜色 c_i 之间的差异。对于条件模型的训练，潜变量 z 编码有关输入图像的信息。在无条件的情形下（即对于 GAN 和 VAE），z 从高斯分布中采样。

我们通过将表面纹理嵌入为三维空间中的连续函数来探索这一想法。结合最先进的3D重建技术，这使我们能够从单个二维图像中重建一个纹理化三维模型。

令 $t(\cdot)$ 表示一个将三维点 $\mathrm{p} \in \mathbb{R}^3$ 映射到颜色值 $\mathrm{c} \in \mathbb{R}^3$ 的函数，从而通过三维向量场表示纹理信息：

$$t : \mathbb{R}^3 \to \mathbb{R}^3 \tag{1}$$

通过将函数 t 参数化为神经网络 t_θ 并具有可学习参数 θ，我们将问题简化为简单的回归任务。然而，如果没有进一步的约束，纹理生成问题仍然是不适定的。因此，为了提供 t_θ 关于物体输入形状的信息，我们对 t_θ 形状嵌入 $\mathrm{s} \in \mathcal{S}$进行条件化。这有助于纹理场将其预测引导至物体表面，并允许利用上下文几何信息，例如通常与图像边缘对齐的表面不连续性。作为输入形状，本文探索了三维 CAD 模型以及使用神经网络 [25] 进行的三维重建。

不幸的是，即使给定输入三维形状，仍然存在多种合理的纹理解释。以汽车为例，仅凭三维几何形状既不能确定颜色，也不能确定窗户或车灯的确切形状。然而，我们可以通过提供有关物体外观的信息来进一步约束任务。

更具体地说，我们将 t_θ 条件化于从任意视点获取的附加二维图像。请注意，图像仅提供部分外观信息，因为它仅从单个视角描绘对象。此外，我们将图像编码为视角不变的全球特征表示 $\mathrm{z} \in \mathcal{Z}$。因此，我们的方法不假设相对于对象的相机外参已知，因此能够使用“野外”图像对无纹理的三维形状进行纹理化。重要的是，输入图像不必描绘与3D模型完全相同形状的对象。这在实践中将是一个强烈的限制，因为通常只能从单个图像中检索到近似形状。

总之，我们将 Texture Field 定义为从三维点 p、形状嵌入 s 和条件 z 到颜色 c 的映射：

$$t_\theta : \mathbb{R}^3 \times \mathcal{S} \times \mathcal{Z} \to \mathbb{R}^3 \tag{2}$$

在以下内容中，我们将考虑条件情况和无条件情况。对于无条件情况，我们利用概率生成网络 [11, 22], 捕捉随机潜在代码 z 中的模糊性。

模型：我们对我们的纹理场模型进行了概述，如图2所示。彩色箭头表示代表条件、GAN和VAE 模型的不同路径。蓝色和红色框表示我们模型的可训练组件，这些组件由参数联合训练的神经网络参数化。我们现在将详细说明我们模型中的每个组件。

形状编码器：为了向纹理场 t_θ 告知物体的三维形状，我们从输入形状（通常以正多边形网格的形式提供）中均匀采样三维点，并将生成的点云传递给一个采用 [29], 网络架构的 [25]点云网络，从而得到一个固定维度的形状嵌入s。

图像编码器：对于条件情况（红色箭头在图2中），我们额外从输入图像中提取外观信息。更具体地说，我们使用一个标准的预训练残差网络$\mathbf{z}$ 将输入图像编码成一个固定维度的潜在码 [14]，该网络有18层。

纹理场：给定输入形状s和条件z，我们提出的纹理场模型能够为任何三维点p_i预测一个颜色值c_i 。因此，可以直接为三维网格上的每个点着色。不幸的是，基于网格的外观表示需要额外的UV映射来表示纹理。因此，我们在二维图像空间中训练我们的纹理模型，该空间提供了规则且高效的表示.[2]

为此目标，我们使用OpenGL从任意视点渲染深度图D和相应的彩色图像X。像素u_i 和深度 d_i 处的颜色预测为

$$\hat{\mathbf{c}}_i = t_\theta\left(d_i\,\mathbf{R}\,\mathbf{K}^{-1}\mathbf{u}_i + \mathbf{t}, \mathbf{s}, \mathbf{z}\right) \tag{3}$$

其中 i 表示具有有限深度值的像素的索引 $i \in \{1, \ldots, N\}$， N是指图像中的前景像素数量（即对象可见的像素）。在这里，相机内参和外参分别表示为$\mathrm{K} \in \mathbb{R}^{3\times3}$和($\mathrm{R} \in \mathbb{R}^{3\times3}, \mathrm{t} \in \mathbb{R}^3$)，像素$\mathrm{u}_i$ 以齐次坐标表示。为了训练我们的模型，我们将预测的颜色$\hat{}\mathrm{c}_i$ 与渲染图像X中相应像素c_i 的颜色进行比较。

3.2. 训练

本节描述了如何训练我们的条件模型和无条件模型。参见图 2 进行视觉说明。

条件设置：在条件情况下，我们将输入图像的嵌入z输入到我们的网络中。[3] 我们通过最小化预测图像X和渲染图像X之间的 ℓ_1-损失$\hat{}$来在有监督的情况下训练t_θ(p, s,z)：

$$\mathcal{L}_{cond} = \frac{1}{B}\sum_{b=1}^{B}\sum_{i=1}^{N_b}\left\|t_\theta(\mathbf{p}_{bi}, \mathbf{s}_b, \mathbf{z}_b) - \mathbf{c}_{bi}\right\|_1 \tag{4}$$

这里， B 表示小批量的大小。每个小批量中的元素代表一张包含 N_b 个前景像素的图像

[2]请注意，这并不限制我们的模型。在测试时，我们的模型可以对任意三维点进行评估。[3]重要的是要注意，训练期间用于监督模型的输入图像和图像X不必相同，因为我们学习的是视角不变的表示z。

(即，对象可见的像素)。请注意，形状编码 s_b 和输入编码 z_b 分别隐式依赖于形状编码器和图像编码器网络的参数。我们联合训练这三个网络（形状编码器、图像编码器、纹理场）的参数。

无条件生成模型： 在无条件设置中，我们只给出三维形状作为输入，但没有关于物体外观的附加信息。如上所述，这是一个高度不适定的问题，有许多 有效 解释。因此，我们利用概率生成模型，这些模型使用从高斯分布采样的潜在代码 $\mathbf{z}$ 来捕获输出中的歧义（见图 绿色 和蓝色 模型在图 2中）。具体来说，我们调整了两种最近深度潜在变量模型到我们的设置：一个生成对抗网络（GAN） [11]和一个变分自编码器（ VAE） [22]。这两种模型过去已应用于各种基于图像的任务 [11, 12, 19, 22, 30, 33]，因此在我们的基于图像的损失公式背景下非常适合。

让我们首先考虑对抗训练。给定三维形状，学习纹理信息生成模型的问题可以使用条件GAN [26] 来解决，其中生成器基于三维形状进行条件化。生成器表示为一个纹理场t_θ： $\mathbb{R}^3 \times \mathcal{S} \times \mathcal{Z} \to \mathbb{R}^3$，它将给定三维位置$\mathrm{p}_i$ 在形状嵌入条件下的潜在码z映射为RGB图像：

$$\hat{\mathbf{X}} = G_\theta(\mathbf{z}_b|\mathbf{D}_b, \mathbf{s}_b) = \{t_\theta(\mathbf{p}_{bi}, \mathbf{s}_b, \mathbf{z}_b)|i \in \{1, \ldots, N_b\}\} \tag{5}$$

如上所述， b 表示小批量中的一个元素，s_b取决于形状编码器的参数。我们使用一个基于图像的判别器 D_ϕ (X_b|D_b)，通过将其与输入深度图像D连接来对其进行条件化。为了训练模型，我们使用具有 R_1-正则化的非饱和GAN损失 [24]。

学习潜在变量模型的一种替代方法是条件VAE (cVAE) [37]。我们的cVAE模型包含一个编码器网络，它将彩色图像X映射到各向同性正态分布随机变量z的均值 $\boldsymbol{\mu}$ 和方差 $\boldsymbol{\sigma}$ ，其中z遵循分布q_ϕ(z|X,s)。我们的纹理场模型用作解码器，通过在形状嵌入s的条件下预测每个像素u_i 对应三维位置p_i 的颜色值$\hat{}\mathrm{c}_i$ 。随后 [22, 33], , 我们最小化变分下界

$$\mathcal{L}_{\text{VAE}} = \frac{1}{B}\sum_{b=1}^{B}\left[\beta\,\mathrm{KL}(q_\phi(\mathbf{z}|\mathbf{X}_b, \mathbf{s}_b)\,\|\,p_0(\mathbf{z}_b)) + \sum_{i=1}^{N_b}\left\|t_\theta(\mathbf{p}_{bi}, \mathbf{s}_b, \mathbf{z}_b) - \mathbf{c}_{bi}\right\|_1\right] \tag{6}$$

其中KL表示Kullback-Leibler散度，

$p_0(z) = \mathcal{N}(z|0, I)$表示标准正态分布，$z_b$ 是从后验分布$q_\phi(z|X_b, s_b)$中抽取的样本， β 是KL散度与重建损失 [16]之间的权衡参数。同样， b表示小批量中的一个元素，s_b 取决于形状分布的参数。在实践中，我们设置$\beta = 1$。在训练过程中，我们使用重参数化技巧 [22, 33]优化 $\mathcal{L}_{\text{VAE}}$ 。在测试时，我们通过从标准正态分布中采样z来获取所考虑3D物体的新纹理样本。

3.3. 实现细节

在我们的所有实验中，我们使用全连接ResNet [14]架构从 [25]，（参见补充材料以获取详细信息）实现纹理场$t_\theta(\cdot, s, z)$。对于图像编码器，我们使用在ImageNet上预训练的ResNet-18架构 [14]，。对于形状编码器，我们采用来自 [25]的PointNet [29] 架构。GAN判别器和VAE编码器基于来自 [24]的判别器。我们使用Adam [21]优化器并以学习率 10^{-4}端到端训练我们的监督模型和VAE模型。我们的GAN使用交替梯度下降法，并使用与相同学习率的RMSProp优化器 [41] 进行训练。

4. 实验评估

我们在三个不同的实验中评估我们的方法。在第一部分，我们通过分析在单个3D物体上训练时该方法表示高频纹理的能力来研究纹理场的表示能力。在第二部分，我们将我们的方法应用于具有挑战性的单视图纹理重建任务，其中我们仅给定3D形状和该物体的单个视图来预测3D物体的完整纹理。此外，我们将我们的方法与最先进的形状重建方法 [25] 结合，用于完整纹理的3D重建，该方法还包括重建3D物体的形状。在最后一个实验中，我们探索我们的表示是否也可以用于生成设置，其中目标是在仅给定3D物体的形状而没有进一步输入的情况下生成多种可能的纹理分布。

基线：仅有少数先前工作在一般情况下考虑了纹理重建，而没有预定义的模板网格或有关相机视图的信息。因此，我们构建了一个简单的第一个基线，通过将输入图像映射到网格上，将所有顶点投影到输入视图以确定它们的颜色。虽然这个简单的基线获得了有关输入视图相机的额外信息，但我们相信它仍然可以作为良好的合理性检查，以查看我们的方法是否实际上在学习有用的事物，以及它是否能够正确填充遮挡区域。作为第二个基线，我们考虑了一种新视图合成(NVS)方法，该方法使用与我们方法相同的图像编码器，但应用了UNet架构来将对象的深度渲染转换为RGB图像。虽然这种方法也可以生成所考虑对象的全新视图，但它需要额外的（有损的）后处理来生成对象的完整纹理图。特别是，对于这个基线，没有保证新生成的视图在视点变化时是一致的。最后，我们将Im2Avatar作为从单张图像进行完整纹理化三维重建的基线。据我们所知，这种方法目前是在所有基于体素的三维重建方法中分辨率最高的（预测颜色并产生最先进的结果）。我们使用Im2Avatar的官方实现。

方法[4] [34] 将其应用于将对象的深度渲染转换为RGB图像。虽然这种方法也可以生成所考虑对象的全新视图，但它需要额外的（有损的）后处理来生成对象的完整纹理图。特别是，对于这个基线，没有保证新生成的视图在视点变化时是一致的。最后，我们考虑Im2Avatar [39] 作为从单张图像进行完整纹理化三维重建的基线。据我们所知，这种方法目前是在所有基于体素的三维重建方法中分辨率最高的（预测颜色并产生最先进的结果）。我们使用Im2Avatar的官方实现[5] 。

数据集：除非另有说明，我们使用来自ShapeNet数据集的‘汽车’、‘椅子’、‘飞机’、‘桌子’、‘长凳’、‘柜子’、‘沙发’、‘灯’和‘容器’这些类别 [5]因为这些类别包含丰富的纹理信息，同时也提供了各种形状。请注意，数据集中的所有模型都是沿轴对齐的。对于我们的条件实验，我们使用Choy等人提供的渲染结果作为输入。为了训练我们的模型，我们从上半球体的随机视图中为每个对象渲染10张额外的图像和深度图。 [7]。

指标：为了评估，我们考虑了三个不同的图像空间指标来评估对象的随机视图。首先，为了评估我们的方法和基线在给定对象类别中捕获外观分布的程度，我们使用Fr´echet Inception距离（FID）[15]。这是一个在图像分布之间常用的指标，在GAN文献中广泛使用 [3, 15, 19, 20]。此外，为了更好地估计预测视图与真实视图之间的实例级距离，我们测量了结构相似性图像度量（SSIM） [44]。由于我们发现SSIM主要捕获图像的局部属性，我们额外引入了一个更全局的感知度量，我们称之为Feature-ℓ_1-度量。类似于FID，Feature-ℓ_1-度量是通过使用Inception网络将考虑的方法产生的图像和真实视图嵌入到特征空间中来计算的。然后，Feature-ℓ_1-度量计算预测图像和真实图像特征激活之间的平均绝对距离。

4.1. 表示能力

该实验的目标是探索我们的纹理场模型的表示能力。这个“过拟合”实验有助于将图像编码器的质量与纹理场表示本身区分开来，并为在将纹理场应用于更困难的任务时我们可以期望的重建质量提供了上限。

[4]详情请参见补充材料。 [5] https://github.com/syb7573330/im2avatar



真实纹理场体素化 (128^3)

图3：表示能力。将拟合到猫/人体三维模型的纹理场与基于体素的表示以及相应的真实模型进行比较。

任务[6], wrt. 512^2 像素渲染，来自500个视角

定性结果展示在图 3中，将我们的模型与固定分辨率的体素化进行比较 128^3 体素。我们观察到纹理场可以表示高频信息，而体素表示本质上仅限于粒度有限的曼哈顿世界。正如我们在补充材料中展示的，纹理场还可以同时表示多个物体的纹理。这些实验验证了纹理场是一种有前景的纹理表示方法。

4.2. 单图像纹理重建

我们现在将注意力转向具有挑战性的单图像纹理重建任务。为此目标，我们进行了给定三维模型以及从随机相机视角拍摄的物体二维图像的纹理重建实验。我们使用第 3.2 节描述的条件设置训练我们的方法。在测试时，我们在三种不同设置中应用训练好的模型。在第一种设置中，我们使用真实三维形状作为输入，并将我们的模型应用于物体的合成渲染。在第二种设置中，我们将我们的方法与最先进的形状重建方法 [25]结合，以获得形状和纹理的完整三维重建流程。最后，在

[6]3从free3d.com 和 turbosquid.com。

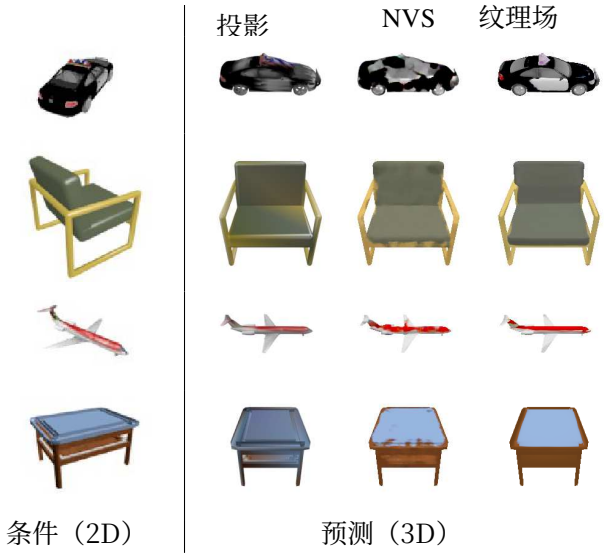


图4：纹理重建。展示了我们的方法（纹理场）与基线方法的定性比较。在这个实验中，我们使用GT形状作为输入。

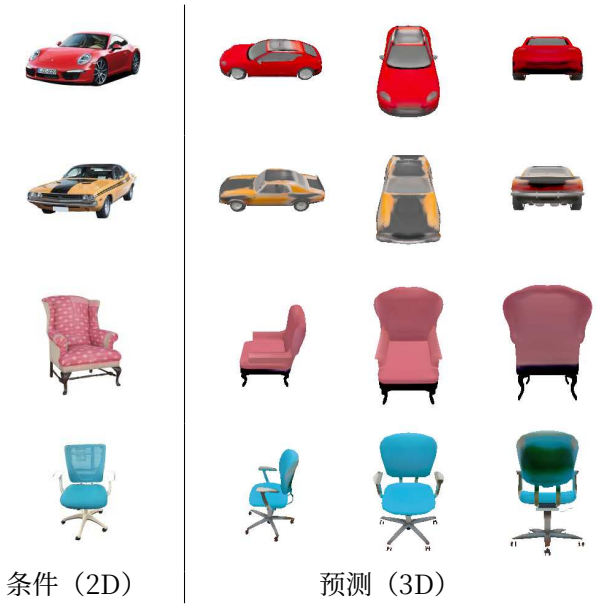


图5：从真实图像进行纹理重建。在这个实验中，我们的模型将纹理从先前未见过的真实图像迁移到未见过的3D CAD模型。

在第三个设置中，我们研究我们的模型是否也能迁移到真实数据。这里，我们使用真实汽车图像以及来自ShapeNet数据集的相似三维形状。

GT Shapes： 在使用真实形状时，我们的模型成功学会从物体单张图像中提取纹理，如图 4所示。特别是，我们的模型可以补全输入视图中不可见的纹理部分

	FID			SSIM			特征-ℓ_1		
	投影	NVS	纹理场	投影	NVS	纹理场	投影	NVS	纹理场
飞机	15.375	17.816	**9.236**	**0.970**	0.964	0.968	0.143	0.158	**0.136**
cars	70.070	72.209	**24.271**	0.840	**0.887**	0.885	0.236	0.238	**0.192**
椅子	8.045	8.788	**5.791**	0.931	**0.947**	0.941	0.127	0.125	**0.124**
桌子	10.254	9.311	**8.846**	0.934	**0.953**	0.943	0.123	**0.117**	0.123
长凳	16.527	17.484	**12.965**	0.921	0.936	**0.937**	0.144	0.142	**0.133**
柜子	**23.374**	44.753	24.251	0.895	**0.933**	0.932	0.158	0.166	**0.148**
沙发	17.151	20.187	**9.618**	0.898	**0.938**	**0.938**	0.167	0.152	**0.135**
灯具	19.214	20.324	**16.747**	0.954	**0.961**	0.960	0.162	0.168	**0.161**
器皿	30.400	44.461	**21.483**	0.928	**0.935**	0.929	0.194	0.209	**0.185**
mean	23.379	28.370	**14.801**	0.919	**0.939**	0.937	0.162	0.164	**0.149**

表1：单图像纹理重建。使用FID、SSIM和特征-ℓ_1 指标进行定量评估。

	FID	SSIM	特征-ℓ_1
投影	65.745	0.850	0.229
Im2Avatar	141.209	0.734	0.281
NVS	73.223	**0.870**	0.228
纹理场	**59.424**	**0.870**	**0.217**

表 2：完整流程。使用 FID、SSIM 和 Feature-ℓ_1 指标进行定量评估。每个类别的结果在补充材料的第 2 节中呈现。请注意，Im2Avatar 仅应用于汽车、椅子和桌子。

。同时，我们的模型成功将输入视图中可见的纹理区域迁移到形状上（例如汽车的车窗和轮胎）。相比之下，投影基线和NVS都显示出明显的伪影。投影基线将纹理错误地迁移到模糊区域，而NVS经常导致不真实的图像伪影，如粗糙的边缘和溢色的颜色。定量比较见表 1。虽然NVS实现了最佳的SSIM，但我们的方法在FID和Features- ℓ_1 距离方面表现最佳。这与图4中的定性结果一致，因为SSIM是一个局部指标，而FID和Features- ℓ_1 距离是全局指标，能更好地捕捉视觉相似性和真实性。

完整流程： 为了获得完整的单视图纹理 3D 重建流程，我们将纹理场与占用网络相结合 [25]。为了进行公平的比较，我们还将投影基线和 NVS 基线与来自 [25]的内容相结合。

我们在图 7 和图 9 中的定性结果表明，我们的方法仅需模型的单视图即可重建带有纹理的3D模型。与 Im2Avatar[7] [39], NVS和投影基线相比，我们观察到验证了我们的方法能够获得更一致且更逼真的输出。这一点也体现在表 2中的数值结果：虽然NVS和我们的方法都获得了最佳的SSIM，但我们的方法在FID和特征距离方面表现最佳。ℓ_1 。

真实图像： 在图 5中，我们最终研究了我们的方法是否也能够将纹理信息从真实输入图像转移到真实 CAD 模型。为此目标，我们将我们的方法应用于由 [38] 和 [49] 提供的图像，并选择与输入图像中显示的对象相似的 CAD 模型。我们观察到，尽管我们的模型仅在合成数据上训练，但它对真实数据泛化得相当好。

4.3. 无条件模型

在本节中，我们进行无条件实验，以探究纹理场是否也能以纯生成方式应用，即我们仅向网络提供物体的形状，而不提供二维图像。为此，我们在“汽车”类别上训练了 VAE 和 GAN 模型。在训练过程中，我们向网络提供目标图像和深度图，但不提供输入视图。在测试过程中，我们从标准正态分布中采样潜码 z，以获得给定 3D 物体的随机纹理样本。

GAN 和 VAE 模型的随机样本显示在图。8。虽然我们的无条件模型成功生成了逼真的纹理，但 VAE 和 GAN 样本都包含与将 VAE 和 GAN 应用于图像域时相似的伪影。例如，VAE 模型的样本全局上是一致的但略微模糊。相比之下，GAN 模型的样本更清晰但包含伪影。未来，我们希望探索 VAE 和 GAN 的组合以及更

[7]不幸的是，Sun 等人只提供了我们训练数据子集的训练数据。因此，我们在 Sun 等人提供的训练和测试分割上训练和评估 Im2Avatar。由于 Sun 等人提供的测试分割。

由于我们的测试集与“椅子”和“桌子”类别的训练集是互斥的，因此我们只能对“汽车”类别进行定性的比较。



图 6：潜在空间　高斯过程插值（VAE）。我们的生成模型学习一个有意义的潜在空间嵌入　.

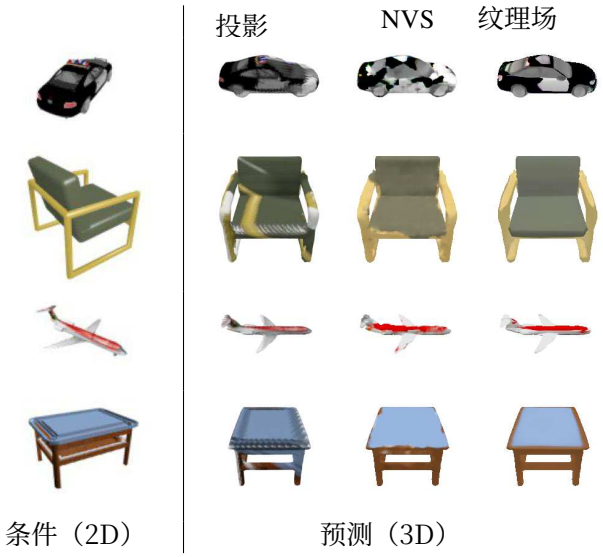


图7：完整流程。使用占用网络 [25] 进行三维重建，并结合投影、NVS和纹理场进行外观估计。

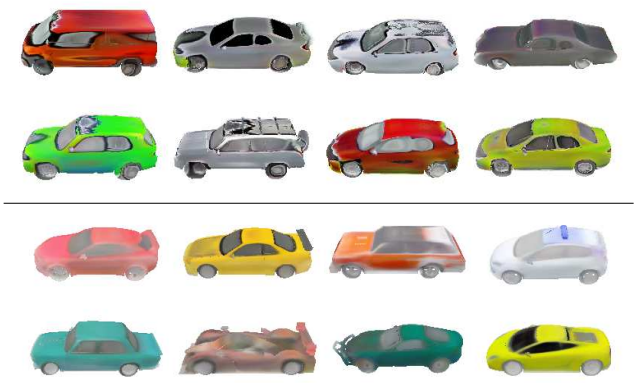


图8：生成模型。使用GAN（前两行）和VAE（后两行）模型生成的纹理。注意在此设置中未提供二维图像作为输入。

先进的模型和训练方法 [12, 20] 来改进这些初步结果。

图 6 展示了 VAE 模型在潜在空间中的插值。我们看到 VAE 学习到了一个有意义的潜在空间，因此可以在不同的纹理样本之间进行平滑插值。此外，在图 10中，我们展示了—

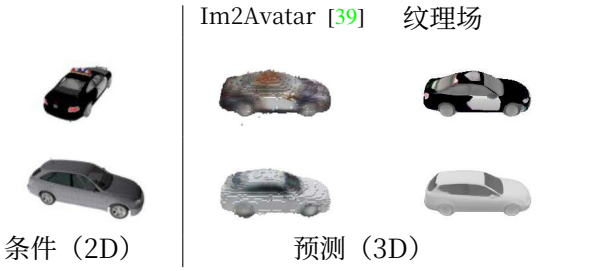


图9：体素与函数空间。我们将我们的完整流程与基于体素的重建方法 [39] 进行对比。

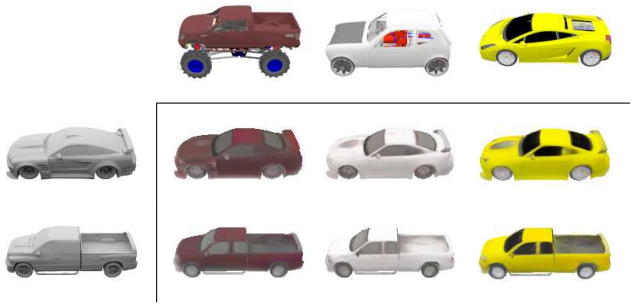


图10：纹理迁移（VAE）。我们的模型将外观信息（顶部）迁移到目标模型（左侧）。

明我们的 VAE 模型也允许成功地将纹理从一个模型迁移到另一个模型。

5. 结论

在本文中，我们介绍了纹理场（Texture Fields），一种用于三维形状纹理的新型连续表示方法。我们的实验表明，纹理场可以从单个物体视图中预测高频纹理。此外，我们还证明了纹理场也可以用于无条件的设置中，即我们仅给定三维物体的形状。因此，我们相信纹理场是一种有用的三维重建表示方法，并希望它们将成为下一代三维生成模型的重要组成部分。

致谢

这项工作得到了微软研究院通过其博士奖学金计划的资助，得到了英特尔智能系统网络的支持，以及得到了英伟达研究赠款的支持。

参考文献

[1] 哈桑·阿尔海贾、西瓦·穆斯蒂科韦拉、安德烈亚斯·盖格和卡sten·罗瑟。几何图像合成。在亚洲计算机视觉会议（ACCV）2018年会议录。2[2] 哈桑·阿尔海贾、西瓦·穆斯蒂科韦拉、拉尔斯·梅施德、安德烈亚斯·盖格和卡sten·罗瑟。增强现实与计算机视觉：城市驾驶场景的高效数据生成。国际计算机视觉杂志（IJCV），126(9):961–972，2018。2[3] 安德鲁·布罗克、杰夫·多纳胡和卡伦·西蒙尼安。大规模GAN训练用于高保真自然图像合成。在机器学习表示国际会议（ICLR）2019年会议录。2，5[4] 安德烈·布罗克、西奥多·林姆、詹姆斯·M·里奇和尼克·韦斯顿。生成和判别体素建模与卷积神经网络。arXiv.org，1608.04236，2016。1′安杰尔·X·张、托马斯·A·芬克豪泽、莱昂尼斯·J·基乌巴斯、帕特·汉拉汉、黄启兴、李子墨、西尔维奥·萨瓦雷塞、马诺利斯·萨夫瓦、宋舒然、苏浩、肖建雄、李丽和余飞。Shapenet：一个信息丰富的3D模型库。arXiv.org，1512.03012，2015。5[5]陈志琴和张浩。学习隐式场用于生成式形状建模。在IEEE计算机视觉与模式识别会议（CVPR）2019年会议录。1，2[6] 克里斯托弗·邦素·赵、丹飞·徐、金永国、陈凯和西尔维奥·萨瓦雷塞。3d-r2n2：一种用于单视图和多视图3D物体重建的统一方法。在欧洲计算机视觉会议（ECCV）2016年会议录。1，2，5[7] 邓建康、程世阳、薛念南、周宇翔和斯泰潘诺斯·扎菲里乌。UV-GAN：对抗性面部UV图补全用于姿态不变面部识别。在IEEE计算机视觉与模式识别会议（CVPR）2018年会议录。1，2[8] 范浩强、苏浩和莱昂尼斯·J·基乌巴斯。一个用于从单张图像重建3D物体的点集生成网络。IEEE计算机视觉与模式识别会议（CVPR）2017年会议录。1，2[9] 玛尔塔·加莱洛、乔纳森·施瓦茨、丹·罗森鲍姆、Fabio·维奥拉、丹尼尔·J·雷泽内德、S·M·阿里·埃斯拉米和叶惠怡。神经过程。在机器学习国际会议（ICML）工作坊会议录，2018年。2[10] 伊恩·J·古德费洛、让·普热塔-阿巴迪、梅赫迪·米尔扎、徐冰、大卫·沃德-法莱、谢吉尔·奥扎伊尔、亚伦·C·库尔维和约书亚·本吉奥。生成对抗网络。在神经信息处理系统进展（NIPS）2014年会议录。2，3，4[11] 卡罗尔·格雷戈尔、伊沃·达尼埃尔卡、亚历克斯·格雷夫斯、丹尼尔·吉梅内斯·雷泽内德和达安·威斯特拉。DRAW：一个用于图像生成的循环神经网络。在机器学习国际会议（ICML）2015年会议录。4，8[12] 蒂博·格鲁埃克斯、马修·费希尔、弗拉基米尔·G·金、布莱恩·C·拉塞尔和马蒂厄·奥布里。AtlasNet：一种基于纸张的方法来学习3D表面生成。在IEEE计算机视觉与模式识别会议（CVPR）2018年会议录。1，2

[14] 何恺明、张翔宇、陈喆清和孙剑。图像识别的深度残差学习。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2016年。4, 5[15]马丁·海塞尔、Hubert拉姆斯auer、Thomas乌特宾纳、Bernhard内斯勒和Sepp霍克雷特。使用双时间尺度更新规则训练的GAN收敛到局部纳什均衡。在神经信息处理系统进展（NIPS）论文集，2017年。5[16] 伊琳娜·希金斯、Loic马蒂、Arka帕尔、Christopher伯格、Xavier格洛托、Matthew博特维尼克、Shakir穆罕默德和Alexander勒希纳。beta-VAE：使用约束变分框架学习基本视觉概念。在机器学习国际会议（ICML）论文集，2017年。5[17] 黄增、李天野、陈伟凯、赵亚杰、邢俊、Chloe勒格伦德、罗林杰、马崇阳和Li浩。从稀疏多视图性能捕获的深度体积视频。在欧洲计算机视觉会议（ECCV）论文集，第351-369页，2018年。2[18] Angjoo卡纳扎瓦、Shubham图尔西阿尼、Alexei A.叶夫罗西莫夫和Jitendra马利克。从图像集合中学习特定类别的网格重建。在欧洲计算机视觉会议（ECCV）论文集，2018年。1, 2[19] Tero卡拉斯、Timo艾拉、Samuli莱内和Jaakko莱赫蒂宁。GAN的渐进式增长，以提高质量、稳定性和多样性。在机器学习表示国际会议（ICLR）论文集，2018年。2, 4, 5[20] Tero卡拉斯、Samuli莱内和Timo艾拉。基于风格的生成对抗网络生成器架构。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2019年。2, 5, 8[21] Diederik P.金马和Jimmy巴。Adam：一种随机优化方法。在机器学习表示国际会议（ICLR）论文集，2015年。5[22] Diederik P.金马和Max韦林。自编码变分贝叶斯。机器学习表示国际会议（ICLR）论文集，2014年。3, 4, 5[23] 廖依伊、Simon邓恩和安德烈亚斯·盖格。深度Marching Cubes：学习显式表面表示。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2018年。1, 2[24] 拉尔斯·梅施德、安德烈亚斯·盖格和Sebastian诺沃津。GAN的训练方法实际上是否收敛？在机器学习国际会议（ICML）论文集，2018年。2, 4, 5[25] 拉尔斯·梅施德、迈克尔·奥克斯勒、迈克尔·尼迈耶尔、Sebastian诺沃津和安德烈亚斯·盖格。占用网络：在函数空间中学习三维重建。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2019年。1, 2, 3, 4, 5, 6, 7, 8[26] Mehdi米尔扎和Simon奥斯因德罗。条件生成对抗网络。arXiv.org，1411.1784，2014年。4[27] 朴恩冰、杨继美、Ersin尤默、Duygu切兰和Alexander C伯格。基于变换的图像生成网络，用于新三维视图合成。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2017年。2

[28] 朴正俊、彼得·弗洛伦斯、朱利安·施特劳布、理查德·纽科姆和Steven洛夫格罗夫。DeepSDF：学习用于形状表示的连续符号距离函数。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2019年。2[29] 齐尔·R·齐、苏浩、莫凯春和Guibas莱昂达斯·J。PointNet：用于三维分类和分割的点集深度学习。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2017年。4, 5[30] Alec拉夫福德、Luke梅茨和Soumith钦塔拉。使用深度卷积生成对抗网络的无监督表示学习。在机器学习表示国际会议（ICLR）论文集，2016年。2, 4[31] Konstantinos雷马塔斯、Nguyen楚昂·H、Tobias里斯切尔、Mario弗里茨和Tinne图耶拉尔斯。从单张图像中获取物体的新视图。IEEE模式分析与管理智能汇刊，39(8):1576-1590，2017年。2[32] 丹尼尔·希门内斯雷桑德、S.M.阿里·埃斯拉米、Shakir穆罕默德、彼得·巴塔利亚、Max贾德伯格和Nicolas海斯。从图像中无监督学习三维结构。在神经信息处理系统进展（NIPS）论文集，2016年。1[33] 丹尼尔·希门内斯雷桑德、Shakir穆罕默德和Daan韦斯特拉。深度生成模型中的随机反向传播和近似推理。在机器学习国际会议（ICML）论文集，2014年。4, 5[34] 奥拉夫·罗内伯格、菲利普·费舍尔和托马斯·布罗克斯。U-net：用于生物医学图像分割的卷积网络。在医学图像计算与计算机辅助干预（MICCAI）论文集，2015年。5[35] 斋藤俊介、黄增、夏目隆太、森岛茂、Angjoo卡纳扎瓦和Li浩。Pifu：用于高分辨率着衣人体数字化的像素对齐隐式函数。arXiv.org，1905.05172，2019年。2[36] 斋藤俊介、魏凌宇、胡立文、长野公和Li浩。使用深度神经网络进行逼真的面部纹理推断。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2017年。1, 2[37] 孙基宇、李洪岩和严新辰。使用深度条件生成模型学习结构化输出表示。神经信息处理系统进展（NIPS），2015年。4[38]孙兴远、吴嘉俊、张修明、张卓彤、张成凯、薛天凡、Joshua B Tenenbaum和William T弗里曼。Pix3d：用于单图像三维形状建模的数据集和方法。在IEEE计算机视觉与模式识别会议（CVPR）论文集，2018年。7[39] 孙永斌、刘子伟、王越和Sanjay E.萨拉马。Im2avatar：从单张图像进行彩色三维重建。arXiv.org，1804.06375，2018年。1, 2, 5, 7, 8[40] Max塔塔尔琴科、Alexey多索夫伊斯基和Thomas布罗克斯。从单图像中通过卷积网络获取多视图三维模型。在欧洲计算机视觉会议（ECCV）论文集，2016年。2[41] Tijmen蒂尔曼和Geoffrey Hinton。第6.5-rmsprop课：将梯度除以其最近幅度的运行平均值。Coursera：机器学习的神经网络，2012年。5

[42] Shubham Tulsiani、Tinghui Zhou、Alexei A Efros 和 Ji- tendra Malik。基于可微射线路径一致性的多视角监督单视角重建。在 IEEE 计算机视觉与模式识别会议 (CVPR) 2017 年论文集。1, 2[43] Nanyang Wang、Yinda Zhang、Zhuwen Li、Yanwei Fu、Wei Liu 和 Yu-Gang Jiang。Pixel2Mesh：从单张 RGB 图像生成三维网格模型。在 欧洲计算机视觉会议 (ECCV) 2018 年论文集。1, 2[44] Zhou Wang、Alan C. Bovik、Hamid R. Sheikh 和 Eero P. Simoncelli。图像质量评估：从错误可见性到结构相似性。IEEE 图像处理汇刊 (TIP)，13(4):600–612，2004。5[45] Jiajun Wu、Yifan Wang、Tianfan Xue、Xingyuan Sun、Bill Freeman 和 Josh Tenenbaum。MarrNet：通过 2.5D 描绘进行三维形状重建。在 神经信息处理系统大会 (NIPS) 2017 年论文集。1, 2[46] Jiajun Wu、Chengkai Zhang、Tianfan Xue、Bill Freeman 和 Josh Tenenbaum。通过三维生成对抗建模学习物体形状的概率潜在空间。在 神经信息处理系统大会 (NIPS) 2016 年论文集。1[47] Wenqi Xian、Patsorn Sangkloy、Varun Agra wal、Amit Raj、Jingwan Lu、Chen Fang、Fisher Yu 和 James Hays。TextureGAN：使用纹理块控制深度图像合成。在 IEEE 计算机视觉与模式识别会议 (CVPR) 2018 年论文集。2[48] Tinghui Zhou、Shubham Tulsiani、Weilun Sun、Jitendra Ma- lik 和 Alexei A Efros。基于外观流的视图合成。在 欧洲计算机视觉会议 (ECCV) 2016 年论文集。2[49] Jun-Yan Zhu、Zhoutong Zhang、Chengkai Zhang、Jiajun Wu、Antonio Torralba、Joshua B. Tenenbaum 和 William T. Freeman。视觉对象网络：具有解耦三维表示的图像生成。神经信息处理系统大会 (NIPS)，2018。2, 7